AI 輔助內容：Claude Code 對話紀錄

學號 7115064191 ｜ 工具：Claude Code（Anthropic，Claude Opus 5.5），桌面版 Code 分頁 ｜ 日期：2026-10-07 – 2026-10-22

說明：本作業使用的 AI 輔助工具是 **Claude Code**（Anthropic），以下為對話過程整理（工具執行的細節已省略）。原始完整紀錄另由 Claude 桌面版「Export」匯出。作業分八段完成：建立分析 → 依評分標準補強 → 對照課程講義 → 對照作業頁建議 → 做成網站 → 補上加分項目並部署 → 增加網站內容豐富度 → 補上離群值與影響點分析。只收錄和作業內容有關的對話。

第一段：建立完整分析

學生

（貼上 HW2 作業說明的兩張截圖）HW2 要延伸自我的 HW1。

AI

整理 HW2 的要求：Kaggle 資料集要有 10–20 個特徵、CRISP-DM 六個步驟、特徵選擇、模型評估、含預測區間的預測圖。查看 HW1「HW1-CWA-Weather」（台灣六大區域天氣預報：CWA API + SQLite + Streamlit）後，因為 HW1 不是回歸題目，提出兩個方向：(1) 天氣資料集，主題比較連貫；(2) 經典資料集，例如房價。

學生

主題選房價預測。

AI

建議用 Kaggle「House Sales in King County, USA」（21,613 筆、18 個特徵，目標 price）。因為沒有 Kaggle 金鑰，詢問下載方式和學號。

學生

從 GitHub 鏡像下載；學號 7115064191。

AI

下載 `kc_house_data.csv`，寫好並執行主程式 `7115064191_hw2.py`：

- **資料理解**：沒有缺失值、有 177 筆重複成交；價格右偏（偏態 4.02），取 log 後變成 0.43；sqft_basement = sqft_living − sqft_above，完全共線。
- **資料準備**：清理後剩 21,419 筆；建立 log_price、house_age、is_renovated、has_basement，面積取 log；zipcode 改為 one-hot；訓練/測試切 80/20。
- **特徵選擇**：用了相關係數、VIF、Backward Elimination、RFECV、LassoCV。

第一次執行時發現 VIF 修剪的邏輯把最重要的 log_sqft_living 刪掉了，AI 自己找出問題並修正為「每次取 VIF 最高的特徵和它最相關的夥伴，刪掉其中和目標相關性較弱的那個」。最後選出 12 個特徵。

AI

模型結果（測試集）：

模型	R^2(log)	MAPE
M1 單純線性回歸	0.453	33.1%
M2 MLR 全部 17 個特徵	0.775	19.8%
M3 MLR 選出的 12 個特徵	0.761	20.3%
M4 M3 + zipcode	0.878	13.7%
HistGradientBoosting（對照）	0.905	11.6%

95% 預測區間在測試集的實際覆蓋率是 94.4%（M3）/ 94.0%（M4）。總共產出 11 張圖（含 CI/PI 預測圖）、`predict.py` 部署程式，以及 PDF 報告。另外發現模型檔有 34 MB（statsmodels 會存訓練資料），用 `remove_data()` 縮到 60 KB。

學生

在 NotebookLM 研究網路上同主題的解法，寫一份 100 字以上的摘要貼進報告。

AI

在 NotebookLM（Gemini Notebook）建立筆記本，加入 7 個網路來源（Kaggle 資料集頁、多個 GitHub / nbviewer 上的 King County 房價 Notebook、AI Planet 上的 Notebook、ITM Conferences 2025 的論文），請它整理主流解法並寫摘要，再把摘要貼進報告第 9 節。

第二段：依評分標準補強

學生

（貼上評分標準截圖）評分標準越完整越好，讓分數盡可能高。

AI

先在另一台電腦（Windows）重新執行主程式，數字和原本完全相同，確認結果可以重現；並修正 Windows 主控台印不出「²」的編碼問題，讓程式在 macOS 與 Windows 都能直接執行。

AI

對照評分標準逐項補強（不改變原本的特徵選擇與模型數字）：

- **特徵選擇與評估**：新增 Forward Stepwise（AIC/BIC）佐證圖：前 12 名有 9 個和我們的子集相同，差異的 3 個都是共線的面積欄位。新增 Breusch-Pagan、Jarque-Bera、條件數檢定；Breusch-Pagan 顯示有異質變異，所以改用 HC3 穩健標準誤重新檢定，12 個係數中 11 個仍顯著（只有 log_sqft_lot 變成 p = 0.078）。補上 Random Forest 的 5-fold CV（0.889 ± 0.004）。
- **結果說服力**：新增預測區間校準圖（50%–99% 六種水準，90–95% 幾乎與理想線重合），以及殘差地圖：M3 在市區有明顯的低估群聚，加入 zipcode 後群聚消失，殘差標準差從 0.258 降到 0.185。
- **Auto Regression**：用每週中位房價做 AR(3)，預測最後 8 週的 MAPE 是 4.6%，比 naive 預測（4.3%）還差。報告如實說明：橫斷面資料不適合用 AR，所以 AR 只當補充。
- **報告**：加上 CRISP-DM 流程圖、欄位字典、利害關係人表、成功標準檢核表（M4 全部達成，M3 的 MAPE 20.3% 差一點沒達到）、網路解法 R^2 對照表（此資料集在 Kaggle 是 Dataset，沒有排行榜）、結論與限制。

第三段：對照課程講義補強

學生

（打開課程 Notion 頁面）查看有關這次作業的相關東西，看看有沒有需要修正；「GPT 輔助內容」改成「AI 輔助內容」，填 Claude Code。

AI

讀了課程 L4-2（CRISP-DM、資料型態）、L5（Simple LR 到 Auto Regression）、L6（Multiple Linear Regression、50 Startup）以及老師的「50 STARTUP Kaggle Report」範例報告，對照後找出要補的地方：

- 範例報告把每一種特徵選擇方法**分開**訓練，用測試集的 MSE 與 R^2 比較；L6 Part 2 要列出選 1 到 N 個特徵的 RMSE / R^2 表。
- L6 Step 4 要用 training / test 曲線判斷 overfit / underfit，並用 **Optuna** 優化模型；Step 5 部署要用 **gzip + pickle**。
- L6 Part 4 列出多元回歸的五大假設（線性、變異數同質、常態、誤差獨立、無共線性）；Part 5 介紹 Score selection（暴力搜尋所有特徵組合）與 dummy variable trap。
- L5 列出多項式回歸、Elastic Net 等線性回歸形式；L4-2 要區分名目 / 順序 / 區間 / 比例四種資料型態。

AI

依講義補強（原本的 M1–M4 數字不變）：

- **特徵選擇比較**：新增暴力搜尋（$2^{17} - 1 = 131{,}071$ 組，用 Gram 矩陣約 3 秒算完）。Backward、Forward、RFECV、Lasso、暴力搜尋五種方法全部收斂到同一組 16 個特徵（只刪 long），測試 R^2 0.775，但最大 VIF 19.6；M3 加上 VIF ≤ 5 後只用 12 個特徵，R^2 0.761、VIF 4.4。另外發現 long 的 Lasso 係數其實是 −0.0002（接近 0，不是剛好 0），報告的說法跟著修正。
- **Overfit / Underfit**：1–4 個特徵時 underfit；每一步的 training 與 test R^2 差距都小於 0.004，沒有 overfit。學習曲線顯示 M5 在小樣本時有輕微 overfit，資料變多後消失。
- **Optuna**：對 Elastic Net 的 alpha 與 l1_ratio 搜尋 40 次，最佳結果 CV R^2 0.8789，和 OLS 完全相同，確認不需要正則化。第一次執行時一次訓練要 18 秒以上，改用預先計算 Gram 矩陣後降到 0.04 秒。
- **多項式回歸 M5**：12 個特徵的二次項與交互作用（87 項）加 zipcode，測試 R^2 0.887，美元 RMSE $134,921，比 HistGradientBoosting 還低。
- **報告**：加入 MSE 與各指標的定義、五大假設檢查表（補上線性假設）、資料型態欄位、dummy variable trap 說明、gzip 部署（57 KB → 39 KB）、CRISP-DM 總結表；「GPT 輔助內容」改為「AI 輔助內容（Claude Code）」。

第四段：對照作業頁新增的建議

學生

（貼上 iLearning 作業頁截圖，頁面下方新增了「Kaggle Multiple Linear Regression Problems（14–39 Features）」與「Suggested Assignment: CRISP-DM + Feature Selection」）看看要怎麼整理，處理好。

AI

對照作業頁新增的建議逐項檢查：

- **特徵數 14–39 個**：本資料集 18 個特徵，同時符合原本的 10–20 個，不用換資料集。
- **Evaluation 要比較 MAE、MSE、RMSE、R^2、Adjusted R^2，並檢查五大假設**：已經有了。
- **還缺三項**：(1) Feature Selection 要比較 SelectKBest、RFE、Sequential Feature Selection、Lasso、permutation importance，選不同數量的特徵，只用訓練資料；(2) Modeling 要同時訓練 LinearRegression、Ridge 和 Lasso，原本缺 Lasso；(3) Deployment 要預測新樣本並解釋模型。

AI

補上這三項（原本的模型數字不變）：

- **五種方法 × k = 5、8、12、14**：SelectKBest 最差（k = 12 時 R^2 0.738），因為只看單變量相關，會挑進一堆共線的面積欄位。其他四種方法到 k = 8 就有 R^2 0.76，k ≥ 12 後停在 0.77。共線性是關鍵差別：k = 12 時只有 Sequential FS 的最大 VIF 接近 5（5.2，R^2 0.774），其餘都在 17.8–19.4。Sequential FS 選出的 12 個特徵和 Forward Stepwise 前 12 名完全相同。報告如實寫出它比 M3 準 0.013，以及仍選 M3 的理由（嚴格 VIF ≤ 5、不用鄰居平均面積）。
- **Lasso 模型**：LassoCV 在 M4 設計上 R^2 0.877，81 個係數中 79 個非零，和 OLS 幾乎相同。
- **預測並解釋新樣本**：`predict.py` 加上 `--explain`，把預測價精確拆成「一般房子 $465,592 × 每個特徵的百分比影響」。以 Mercer Island 臨水豪宅為例：預測 $2,615,671，主要來自臨水 +62%、地段 +50%、面積 +34%、等級 +30%、景觀 +28%。報告另列三間新房子的預測與 95% 預測區間。第一次執行時，因為 `remove_data()` 之後係數失去欄位名稱而出錯，改成在 `remove_data()` 之前先算好 zipcode 平均效果。

第五段：部署成網站

學生

README 最上面記得放網站的截圖。

AI

參考 HW1 的 README（最上面是 Streamlit 網站截圖），HW2 原本只有命令列工具，所以延續 HW1 的架構，把 M4 模型做成 Streamlit 網站 `app.py`：

- 左側輸入房屋條件；選 zipcode 時自動帶入該區的緯度，使用者不用自己查經緯度。
- 右側即時顯示預測價、95% 預測區間與信賴區間，並用長條圖逐項解釋各條件對價格的影響，以及各 zipcode 的位置與中位房價。
- 修正兩個顯示問題：金額裡有兩個「$」時，Streamlit 會把中間的文字當成數學公式，所以把「$」跳脫；線上地圖在截圖時無法載入，改用 Altair 畫各區位置圖。

截圖放在 README 最上面，並加入報告 6.3 節。

第六段：依老師更新的要求補上加分項目並部署

學生

（貼上更新後的作業說明截圖）老師作業要求有改，主要繳交改成「跟 DIC2 一樣 github and web」，另外有加分：下拉視窗呈現兩種 problem（+1）、可任意輸入 Dataset（+2）。

AI

對照新要求：資料集 18 個特徵符合「大於 13 個」；報告、對話、圖表改為選繳但都已具備；缺的是兩個加分項目與公開網站。網站改成左側下拉選單切換三種 problem：① King County 房價（主模型 M4）、② 50 Startups 利潤（老師提供的 CSV 網址）、③ 自行輸入資料集（CSV 網址或上傳）。②③ 共用新寫的 `generic_mlr.py`：自動補缺值、one-hot 編碼（避開 dummy trap）、只用訓練資料做特徵選擇（SelectKBest、RFE、Sequential FS、Lasso、permutation importance）、OLS、MAE / MSE / RMSE / R^2 / Adjusted R^2、含 95% 預測區間的預測圖與新樣本預測。用 King County 原始資料測試時，發現 date 欄位會被展開成 386 個虛擬變數、id 也被當成特徵，因此預設排除 id 欄位和類別值超過 30 種的文字欄位。

學生

（登入 Streamlit Community Cloud）幫我填，按 Deploy。

AI

部署到 https://hw2-mlr-yenkai.streamlit.app/。雲端裝的是 pandas 3.0，文字欄位的型態從 object 改成新的字串型態，導致 50 Startups 的 State 沒有被當成類別；改成「非數值就視為類別」後兩個版本都正確。Problem ① 雲端與本機的預測值完全相同（$555,052）。README 最上面放上網站連結與截圖。

第七段：增加網站內容豐富度

學生

看看可不可以增加內容豐富度，能越高分越好。

AI

主要繳交是 GitHub 與網站，所以把分析成果搬進網站：Problem ① 改成五個分頁（估價、資料探索、特徵選擇、模型評估、報告與 AI 輔助），資料探索的圖表都可以互動，報告分頁可以直接下載報告與對話 PDF；Problem ②③ 補上與目標的相關係數圖、相關係數熱圖、殘差圖、五大假設檢查、所有特徵選擇方法的自動比較，以及預測結果 CSV 下載。另外寫了截圖腳本，README 放上六張網站截圖。

AI

雲端更新後 Problem ②③ 出現「Pipeline 沒有 diagnostics」錯誤：Streamlit Cloud 拉了新程式，但記憶體裡還是舊版模組，快取裡存了舊物件。改成每次執行都重新載入自己的模組，並把模組雜湊值放進快取鍵，重新啟動一次後，雲端七個頁面全部檢查通過。

第八段：補上離群值與影響點分析

學生

資料分析總體量、豐富度足夠嗎？你覺得要補嗎？

AI

分量已經足夠，再增加模型或方法只會讓重點模糊；唯一的缺口是課程 L5「線性回歸 + Outlier」提到、而本作業還沒做的離群值與影響點分析，建議補上。對 M3 計算 Cook's distance、槓桿值與學生化殘差：998 間 Cook's D 超過 4/n，但最大值只有 0.0148（遠小於 1），沒有任何單點主導模型；槓桿值最高的 123 間中有 122 間正是全部的臨水房屋；價格 IQR 離群值有 65% 是臨水或建築等級 ≥ 10 的豪宅。敏感度測試：移除影響點後測試 R^2 0.761 → 0.760、95% 預測區間覆蓋率 94.4% → 90.5%，主要係數變化都在 ±3.2% 以內，因此結論是保留所有資料。結果加進報告 5.4 節與網站「模型評估」分頁。