

GPT 輔助內容：AI 對話紀錄

學號 7115064191 | 工具：Claude Code (Anthropic · Claude Opus 5.5) · 桌面版 Code 分頁 | 日期：2026-10-07

說明：本作業的 AI 協助是用 Claude Code 完成的 (不是 ChatGPT) · 以下為對話過程整理 (工具執行的細節已省略) 。原始完整紀錄另由 Claude 桌面版「Export」匯出。作業分兩段完成：第一段建立完整分析，第二段依評分標準補強。只收錄和作業內容有關的對話。

第一段：建立完整分析

學生

(貼上 HW2 作業說明的兩張截圖) HW2 要延伸自我的 HW1 。

AI

整理 HW2 的要求：Kaggle 資料集要有 10–20 個特徵、CRISP-DM 六個步驟、特徵選擇、模型評估、含預測區間的預測圖。查看 HW1「HW1-CWA-Weather」(台灣六大區域天氣預報：CWA API + SQLite + Streamlit) 後，因為 HW1 不是回歸題目，提出兩個方向：(1) 天氣資料集，主題比較連貫；(2) 經典資料集，例如房價。

學生

主題選房價預測。

AI

建議用 Kaggle「House Sales in King County, USA」(21,613 筆、18 個特徵，目標 price)。因為沒有 Kaggle 金鑰，詢問下載方式和學號。

學生

從 GitHub 鏡像下載；學號 7115064191。

AI

下載 `kc_house_data.csv`，寫好並執行主程式 `7115064191_hw2.py`：

- **資料理解**：沒有缺失值、有 177 筆重複成交；價格右偏 (偏態 4.02)，取 log 後變成 0.43；
`sqft_basement = sqft_living - sqft_above`，完全共線。
- **資料準備**：清理後剩 21,419 筆；建立 `log_price`、`house_age`、`is_renovated`、`has_basement`，面積取 log；`zipcode` 改為 one-hot；訓練/測試切 80/20。
- **特徵選擇**：用了相關係數、VIF、Backward Elimination、RFECV、LassoCV。

第一次執行時發現 VIF 修剪的邏輯把最重要的 `log_sqft_living` 刪掉了，AI 自己找出問題並修正為「每次取 VIF 最高的特徵和它最相關的夥伴，刪掉其中和目標相關性較弱的那個」。最後選出 12 個特徵。

AI

模型結果（測試集）：

模型	R ² (log)	MAPE
M1 單純線性回歸	0.453	33.1%
M2 MLR 全部 17 個特徵	0.775	19.8%
M3 MLR 選出的 12 個特徵	0.761	20.3%
M4 M3 + zipcode	0.878	13.7%
HistGradientBoosting（對照）	0.905	11.6%

95% 預測區間在測試集的實際覆蓋率是 94.4%（M3）/ 94.0%（M4）。總共產出 11 張圖（含 CI/PI 預測圖）、`predict.py` 部署程式，以及 PDF 報告。另外發現模型檔有 34 MB（`statsmodels` 會存訓練資料），用 `remove_data()` 縮到 60 KB。

學生

在 NotebookLM 研究網路上同主題的解法，寫一份 100 字以上的摘要貼進報告。

AI

在 NotebookLM（Gemini Notebook）建立筆記本，加入 7 個網路來源（Kaggle 資料集頁、多個 GitHub / nbviewer 上的 King County 房價 Notebook、AI Planet 上的 Notebook、ITM Conferences 2025 的論文），請它整理主流解法並寫摘要，再把摘要貼進報告第 9 節。

第二段：依評分標準補強

學生

（貼上評分標準截圖）評分標準越完整越好，讓分數盡可能高。

AI

先在另一台電腦（Windows）重新執行主程式，數字和原本完全相同，確認結果可以重現；並修正 Windows 主控台印不出「²」的編碼問題，讓程式在 macOS 與 Windows 都能直接執行。

AI

對照評分標準逐項補強（不改變原本的特徵選擇與模型數字）：

- **特徵選擇與評估**：新增 Forward Stepwise (AIC/BIC) 佐證圖：前 12 名有 9 個和我們的子集相同，差異的 3 個都是共線的面積欄位。新增 Breusch-Pagan、Jarque-Bera、條件數檢定；Breusch-Pagan 顯示有異質變異，所以改用 HC3 穩健標準誤重新檢定，12 個係數中 11 個仍顯著（只有 log_sqft_lot 變成 $p = 0.078$ ）。補上 Random Forest 的 5-fold CV (0.889 ± 0.004)。
- **結果說服力**：新增預測區間校準圖（50%–99% 六種水準，90–95% 幾乎與理想線重合），以及殘差地圖：M3 在市區有明顯的低估群聚，加入 zipcode 後群聚消失，殘差標準差從 0.258 降到 0.185。
- **Auto Regression**：用每週中位房價做 AR(3)，預測最後 8 週的 MAPE 是 4.6%，比 naive 預測（4.3%）還差。報告如實說明：橫斷面資料不適合用 AR，所以 AR 只當補充。
- **報告**：加上 CRISP-DM 流程圖、欄位字典、利害關係人表、成功標準檢核表（M4 全部達成，M3 的 MAPE 20.3% 差一點沒達到）、網路解法 R^2 對照表（此資料集在 Kaggle 是 Dataset，沒有排行榜）、結論與限制。