

HW2 : King County 房價預測 — 多元線性回歸

學號 7115064191 | 依循 CRISP-DM 流程 | 主程式 7115064191_hw2.py | GitHub : [A0966411725-png/HW2-Multiple-Linear-regression](#)

資料集來源：House Sales in King County, USA (Kaggle · 作者 harlfoxem · 授權 CC0 公眾領域)
連結：<https://www.kaggle.com/datasets/harlfoxem/housesalesprediction>
內容：2014/05–2015/05 美國華盛頓州 King County (含西雅圖) 21,613 筆房屋成交紀錄，18 個特徵，目標變數 price 。 (因為沒有 Kaggle API 金鑰，檔案改從 GitHub 鏡像 Shreyas3108/house-price-prediction 下載，筆數與欄位都和 Kaggle 原檔相同。)
研究脈絡：本作業延伸自 HW1 (台灣天氣預報資料管線，[GitHub](#)) 。HW1 著重「資料取得與呈現」，HW2 進一步進入「建模與評估」：用線性回歸量化各因素對房價的影響，並給出帶有不確定性的預測。選房價是因為它是回歸的經典題目，網路上有大量公開解法可以對照 (第 7、9 節) 。

重點結果

模型	特徵數	Test R ² (log)	5-fold CV R ²	RMSE (USD)	MAPE	95% PI 覆蓋率
M1 單純線性回歸	1	0.453	0.455	296,181	33.1%	–
M2 多元線性回歸 (全部)	17	0.775	0.772	187,262	19.8%	–
M3 多元線性回歸 (特徵選擇後)	12	0.761	0.761	195,199	20.3%	94.4%
M4 = M3 + zipcode one-hot	12+69	0.878	0.879	142,491	13.7%	94.0%
HistGradientBoosting (主流解法對照)	18	0.905	0.903	137,215	11.6%	–

目錄

1. Business Understanding

2. Data Understanding

3. Data Preparation

4. Modeling (特徵選擇、模型、Auto Regression 補充)


5. Evaluation (指標、統計檢定、預測區間校準、成功標準檢核)
6. Deployment

7. 網路主流解法比較與說明

8. GPT 輔助內容

9. NotebookLM 摘要

10. 結論與限制



1. Business Understanding (商業理解)

問題：買方、賣方與仲介都需要一個「合理成交價」的參考。單一點估計不夠，決策者還需要知道價格可能落在哪個範圍，才能判斷開價是否偏高、議價空間多大。

利害關係人	需求	模型提供的資訊
買方	判斷開價是否合理	預測價與 95% 預測區間；高於區間上限代表可能買貴
賣方 / 仲介	訂定開價、說明房屋價值來源	各因素的百分比影響（係數解讀），例如等級 +1 級約 +21%
估價 / 貸款機構	估價要可解釋、可稽核	線性模型的係數、p 值、信賴區間都可以逐項檢查

目標：以線性回歸建立可解釋的房價模型，回答：(1) 哪些因素最影響房價、影響多大？(2) 給定一間房子的條件，預測價格與 95% 預測區間。

成功標準（在第 5.4 節逐項檢核）：測試集 $R^2 \geq 0.75$ 、 $MAPE \leq 20\%$ ；95% 預測區間的實際覆蓋率在 93–97% 之間；5-fold CV 與測試集結果一致（不過擬合）；係數方向符合常識。

2. Data Understanding (資料理解)

2.1 欄位字典 (18 個特徵 + 目標)

欄位	意義	型態 / 範圍
price (目標)	成交價 (美元)	連續，\$75K – \$7.7M，中位數 \$450K
bedrooms / bathrooms	臥室數 / 衛浴數 (0.5 = 只有馬桶洗手台)	離散，0–33 / 0–8
sqft_living / sqft_lot	室內面積 / 土地面積 (平方英尺)	連續，290–13,540 / 520–1.65M
sqft_above / sqft_basement	地上面積 / 地下室面積 (兩者相加 = sqft_living)	連續
sqft_living15 / sqft_lot15	最近 15 戶鄰居的平均室內 / 土地面積	連續
floors	樓層數	1–3.5
waterfront	是否臨水	0/1 (0.75% 為 1)
view	景觀評分	序數 0–4
condition	屋況	序數 1–5
grade	King County 建築品質等級	序數 1–13
yr_built / yr_renovated	建造年 / 翻修年 (0 = 未翻修)	1900–2015
zipcode / lat / long	郵遞區號 / 緯度 / 經度	70 個 zipcode；名目 / 連續

2.2 觀察

- 無缺失值；有 177 筆同一房屋重複成交 (id 重複)；有 33 房、0 衛浴等明顯錯誤資料。
- 價格嚴重右偏 (偏態 4.02)，取 log 後接近常態 (偏態 0.43)，因此以 `log(price)` 為建模目標。
- 與價格相關最高的是 `sqft_living` (0.70)、`grade` (0.67)、`sqft_above` (0.61)、`sqft_living15` (0.59)、`bathrooms` (0.53)。
- `sqft_basement = sqft_living - sqft_above` 為完全共線，需處理多重共線性。
- `zipcode` 雖然是數字，但大小沒有意義 (名目變數)，不能直接當數值放進回歸。




圖1 價格分佈：原始值右偏，取 log 後接近常態




圖2 18 個特徵與價格的相關係數矩陣




圖 3 與價格相關最高的 6 個特徵散佈圖

3. Data Preparation (資料準備)

1. 清理：同一房屋只保留最新一次成交；移除 bedrooms = 0 或 ≥ 15 、bathrooms = 0 的錯誤資料 (21,613 $\rightarrow$ 21,419 筆)。
2. 目標轉換： $\log_price = \log(price)$ ，讓殘差較接近常態、變異數較穩定，係數可解讀為「百分比變化」。
3. 特徵工程： $house_age = 成交年 - yr_built$ ； $is_renovated = yr_renovated > 0$ ； $has_basement = sqft_basement > 0$ ；面積欄位全部取 $\log$ 。
4. 類別變數：zipcode 在 M4 改為 69 個 one-hot 虛擬變數 (70 區去掉 1 個基準區，代表地段固定效果)。
5. 切分：80% 訓練 (17,135) / 20% 測試 (4,284)， $random_state = 42$ ；所有特徵選擇只在訓練集上進行，避免資料洩漏。

處理後共有 17 個數值候選特徵：bedrooms, bathrooms, $\log_sqft_living$, $\log_sqft_lot$, floors, waterfront, view, condition, grade, $\log_sqft_above$, has_basement, house_age, is_renovated, lat, long, $\log_sqft_living15$, $\log_sqft_lot15$ 。

4. Modeling (建模)

4.1 特徵選擇 (Feature Selection)

對 17 個候選特徵使用五種方法交叉驗證：

方法	做法	結果
相關分析	$ r $ 與 $\log_price$	grade、 $\log_sqft_living$ 、 $\log_sqft_living15$ 最強
VIF	變異數膨脹因子 > 5 代表共線	$\log_sqft_living / \log_sqft_above$ (≈ 19.6)、 $\log_sqft_lot / lot15$ (≈ 6.9)
Backward Elimination	OLS 逐步移除 $p > 0.05$	移除 long ($p = 0.81$)
RFECV	遞迴特徵消除 + 5-fold CV	最佳 16 個；12 個以後 CV R^2 幾乎不再增加
LassoCV	L1 正則化 ($\alpha = 0.00037$)	long 係數被壓到 0
Forward Stepwise (佐證)	每步加入讓 AIC 最低的特徵	前 4 名 grade $\rightarrow$ lat $\rightarrow$ $\log_sqft_living$ $\rightarrow$ house_age；第 12 個之後 Adj R^2 只再增加 0.002

決策規則：三種方法 (Backward、RFECV、Lasso) 中至少 2 票保留 $\rightarrow$ 再以 $VIF \leq 5$ 迭代修剪：每次取 VIF 最高的特徵與其最相關的夥伴，刪掉與目標相關較弱者。Forward Stepwise 不參與投票，只用來檢查「留多少個特徵才划算」。

最終 12 個特徵：bedrooms, log_sqft_living, log_sqft_lot, floors, waterfront, view, condition, grade, has_basement, house_age, is_renovated, lat

刪除：long (不顯著)、log_sqft_above (與 living 共線)、bathrooms、log_sqft_living15 (與 living 高度相關)、log_sqft_lot15 (與 lot 共線)




圖 4 左：RFECV 特徵數 vs CV R²；右：Lasso 標準化係數 (藍 = 最終保留)




圖 5 Forward Stepwise：左為 AIC/BIC，右為 Adjusted R² 隨特徵加入的變化。12 個特徵之後曲線已經平了

和 Forward Stepwise 的比較：Forward Stepwise 挑出的前 12 個特徵裡有 9 個和我們的子集相同；差別在它選了 bathrooms、log_sqft_living15、log_sqft_lot15，這三個都和已選的面積欄位高度相關。它的 12 特徵模型訓練集 Adj R² 是 0.770，我們的 M3 是 0.761，只差 0.009，但 M3 的最大 VIF 只有 4.4，係數比較穩定、也比較好解讀。我們選擇犧牲一點點擬合度，換取可解釋性。

4.2 模型

- M1 單純線性回歸：log(price) ~ log(sqft_living)，作為基準。
- M2 多元線性回歸 (全部 17 特徵)：檢查特徵選擇是否損失太多。
- M3 多元線性回歸 (12 特徵)：主要的可解釋模型，所有變數 $p < 0.05$ 、 $VIF \leq 5$ 。
- M4 = M3 + zipcode one-hot：加入地段固定效果，仍是線性回歸。
- 對照：Ridge (同 M4 設計)、Random Forest、HistGradientBoosting (Kaggle 上常見的樹模型解法)。

4.3 M3 係數解讀 (log-linear)

特徵	係數	解讀
log_sqft_living	0.460	室內面積 +10% → 房價約 +4.5% (彈性)
grade	0.191	建築等級每 +1 級 → 房價約 +21%
waterfront	0.397	臨水 → 房價約 +49%
lat	1.337	緯度 +0.1° (往北、接近西雅圖市區) → 約 +14%
view	0.071	景觀評分每 +1 → 約 +7%
floors	0.069	每多一層樓 → 約 +7%
condition	0.060	屋況每 +1 → 約 +6%
is_renovated	0.074	曾翻修 → 約 +8%
house_age	0.0032	控制品質後，老屋略貴 (多位於成熟市區)
bedrooms	-0.018	面積固定下房間越多 → 每間越小，價格略降




圖 6 M3 標準化係數與 95% 信賴區間 (所有區間皆不跨 0)

4.4 補充：Auto Regression 試驗

作業允許嘗試 Auto Regression，所以我們也做了測試。不過 AR 是時間序列模型，用變數自己過去的值預測未來；本資料是「每間房子一筆」的橫斷面資料，AR 沒辦法預測個別房屋，只能預測整體市場的價格走勢。做法：把成交價彙總成每週中位數（55 週），用前 47 週訓練、AIC 選出落後階數 $p = 3$ ，預測最後 8 週。




圖 7 AR(3) 預測每週中位房價：MAPE 4.6%，比「直接沿用上週值」的 naive 預測（4.3%）還差；95% 預測區間只涵蓋 8 週中的 6 週（75%）

結論：每週中位數的波動主要是雜訊，加上 2015 年 4 月的春季旺季跳升，這種季節性只有 55 週的資料學不出來，所以 AR 贏不了 naive 預測。房價主要由房屋本身的條件決定，因此主模型採用多元線性回歸，AR 只作為補充。

5. Evaluation (評估)

5.1 評估指標

測試集 R^2 (log 與還原為美元兩種尺度) 、 Adjusted R^2 、 5-fold CV R^2 、 RMSE 、 MAE 、 MAPE ， 以及 95% 預測區間覆蓋率 。

模型	$R^2(\log)$	Adj R^2	CV R^2 (mean±sd)	$R^2(\text{USD})$	RMSE	MAE	MAPE
M1 Simple LR	0.453	0.453	0.455±0.008	0.420	296,181	173,926	33.1%
M2 MLR all (17)	0.775	0.774	0.772±0.006	0.768	187,262	110,553	19.8%
M3 MLR selected (12)	0.761	0.760	0.761±0.006	0.748	195,199	113,288	20.3%
M4 MLR + zipcode	0.878	0.876	0.879±0.003	0.866	142,491	76,678	13.7%
Ridge (M4 design)	0.878	–	0.879±0.003	0.866	142,496	76,681	13.7%
Random Forest	0.892	–	0.889±0.004	0.861	144,842	70,493	12.3%
HistGradientBoosting	0.905	–	0.903±0.002	0.876	137,215	64,868	11.6%

- 特徵選擇有效：M3 用 12 個特徵 (少 5 個) ， R^2 只比 M2 低 0.014 ， 但所有係數顯著、無共線性，可解釋性大幅提高 。
- 地段是最大缺口：加入 zipcode 後 R^2 從 0.761 升到 0.878 、 MAPE 從 20.3% 降到 13.7% ， 「Location, location, location」 (圖 13 的殘差地圖可以直接看到) 。
- 穩定性：CV R^2 的標準差 ≤ 0.008 ， 且 CV 與測試集結果一致，沒有過擬合 。
- 美元尺度上 M4 的 RMSE 比 Random Forest 還低 (142,491 vs 144,842) ， 只輸給 HistGradientBoosting 。




圖 8 M1 單純線性回歸：擬合線、95% 信賴區間 (橘，平均價格的不確定性) 與 95% 預測區間 (綠，單一房屋的不確定性)




圖 9 M3 預測圖：隨機 120 間測試房屋，依預測值排序；× 為落在 95% PI 外的房屋




圖 10 M4 (加 zipcode) 預測圖：預測區間明顯變窄 (中位寬度 \$474K → \$330K)




圖 11 實際 vs 預測 (虛線為完美預測)

5.2 迴歸假設的統計檢定 (M3 · 訓練集)

檢查項目	方法	結果	判讀
多重共線性	VIF / 標準化條件數	最大 VIF 4.44 ; 條件數 4.4	通過 (VIF < 5 、 條件數 < 30)
殘差自相關	Durbin-Watson	1.99	通過 (接近 2 = 無自相關)
殘差常態性	Jarque-Bera	JB = 796 · p < 0.001 ; 偏態 0.15 、 峰度 4.0	尾部略厚 ; 樣本 17,135 筆 , 依中央極限定理係數推論仍可靠
變異數同質性	Breusch-Pagan	LM = 605 · p < 0.001	有異質變異 → 改用 HC3 穩健標準誤重新檢定
穩健性檢查	HC3 robust SE	12 個係數中 11 個仍 p < 0.05	只有 log_sqft_lot 變成 p = 0.078 ; 結論不受影響




圖 12 M3 殘差診斷：殘差無明顯趨勢、近似常態 (尾部略厚，峰度 4.0)




圖 13 測試集殘差地圖：M3 (左) 在西雅圖市區與 Bellevue、Mercer Island 一帶系統性低估 (紅色群聚)，在北邊 Shoreline 與南邊郊區高估 (藍色群聚)；加入 zipcode 後 (右) 群聚消失，殘差標準差從 0.258 降到 0.185

5.3 預測區間校準

只看 95% 一個點不夠，所以再檢查 50%、68%、80%、90%、95%、99% 六種信賴水準下，測試集實際落在預測區間內的比例：

名目水準	50%	68%	80%	90%	95%	99%
M3 實際覆蓋率	52.6%	71.1%	81.7%	90.2%	94.4%	98.1%
M4 實際覆蓋率	57.4%	73.5%	83.4%	90.5%	94.0%	97.6%




圖 14 預測區間校準圖：越接近虛線越準。90–95% 幾乎完全吻合；低水準時略為保守、99% 略不足，這和殘差「中間尖、尾部厚」（峰度 4.0）一致




圖 15 模型比較（藍＝線性回歸家族，灰＝樹模型對照）

5.4 成功標準檢核 (回到 Business Understanding)

成功標準	M3 (12 特徵)	M4 (+ zipcode)
測試集 $R^2 \geq 0.75$	✓ 0.761	✓ 0.878
MAPE $\leq 20\%$	✗ 20.3% (差 0.3 個百分點)	✓ 13.7%
95% PI 覆蓋率在 93–97%	✓ 94.4%	✓ 94.0%
CV 與測試一致 (不過擬合)	✓ 0.761 vs 0.761	✓ 0.879 vs 0.878
係數方向符合常識	✓ 面積、等級、臨水、景觀皆為正	✓

結論：M4 達成全部成功標準，作為部署模型；M3 用來解釋「哪些因素影響房價」。

6. Deployment (部署)

- 執行主程式後，M4 模型 (含特徵清單與 zipcode 類別) 存成 `model/house_price_mlr.pkl` (用 `remove_data()` 去掉訓練資料，34 MB → 約 60 KB)。
- `predict.py` 提供 `predict_price()` 函式與命令列介面，輸入房屋條件即輸出預測價與 95% CI / PI：

```
$ python predict.py --sqft_living 2000 --grade 8 --zipcode 98052 --lat 47.68
Predicted price : $553,994
95% CI (mean)   : $544,004 - $564,168
95% PI (house)  : $388,300 - $790,393
```

- 解讀：同條件房屋的平均價格約 \$544K–\$564K (CI，窄)；單一一間房子的成交價有 95% 機率落在 \$388K–\$790K (PI，寬，因為包含個別房屋的差異)。
- 程式在 macOS (python3) 與 Windows (python) 都測試過可以直接執行，執行紀錄會自動寫入 `results/run_log.txt`。
- 後續可沿用 HW1 的 Streamlit 架構做成網頁表單；並應定期以新成交資料重訓 (本資料只涵蓋 2014–2015，房價已大幅變動)。

7. 網路主流解法比較與說明

此資料集在 Kaggle 是 Dataset (不是 Competition)，沒有排行榜名次，所以改和網路上公開的解法 (Kaggle Notebook、GitHub、論文，見第 9 節 NotebookLM 的 7 個來源) 回報的 R^2 對照：

常見做法	網路上回報的 R^2	本作業對應結果
單純線性回歸 (price ~ sqft_living)	≈ 0.49	M1 : 0.453 (log 尺度，已移除錯誤資料)
多元線性回歸 (原始 price、未處理共線性)	$\approx 0.65\text{--}0.70$	M2 : 0.775、M3 : 0.761
多項式 + Ridge 正則化	$\approx 0.70\text{--}0.75$	Ridge : 0.878 (與 OLS 幾乎相同，表示共線性已處理)
log 轉換 + zipcode 虛擬變數	—	M4 : 0.878、MAPE 13.7%
樹模型 (Random Forest、XGBoost、LightGBM)	$\approx 0.85\text{--}0.87$	RF : 0.892、HistGradientBoosting : 0.905

面向	多元線性回歸 (M4)	梯度提升樹 (HGB)
準確度	R^2 0.878、MAPE 13.7%	R^2 0.905、MAPE 11.6%
可解釋性	每個係數都可以讀成「百分比影響」，有 p 值與信賴區間	黑盒，需要 SHAP 等工具輔助
預測區間	理論公式直接給出，實測覆蓋率 94%，校準良好	需要額外的 quantile regression 或 conformal prediction
非線性、交互作用	需要人工設計 (log、zipcode one-hot)	自動學習

比較結論：樹模型準確度最高，但 M4 線性回歸只差約 2–3 個百分點 (R^2 0.878 vs 0.905)，而且已經超過網路上常見的樹模型成績 (0.85–0.87)。線性回歸能做到這個程度，關鍵是三件事：log 轉換、系統化的特徵選擇、zipcode 地段固定效果。若目標是解釋與估價範圍，線性回歸更合適；若只求點預測準確度，則選梯度提升樹。

8. GPT 輔助內容 (AI 對話過程)

學號 7115064191 | 工具：Claude Code (Anthropic · Claude Opus 5.5) · 桌面版 Code 分頁 | 日期：2026-10-07

說明：本作業的 AI 協助是用 Claude Code 完成的 (不是 ChatGPT) · 以下為對話過程整理 (工具執行的細節已省略) 。完整對話紀錄另附 7115064191_ai_conversation.pdf 。作業分兩段完成：第一段在 Mac 上建立分析，第二段在 Windows 電腦上透過 GitHub 同步後補強。

第一段 (Mac)：建立完整分析

學生

(貼上 HW2 作業說明的兩張截圖) HW1 在我的 GitHub (幫我在側邊欄打開)

AI

在側邊欄瀏覽器開了 GitHub，不過當時還找不到你的帳號，所以請你提供 repo 連結或使用者名稱。也先整理了 HW2 的要求：Kaggle 資料集要有 10–20 個特徵、CRISP-DM 六個步驟、特徵選擇、模型評估、含預測區間的預測圖。

學生

這台電腦都設定好了

AI

在 ~/.local/bin/gh 找到 GitHub CLI，帳號是 A0966411725-png，在側邊欄打開了 HW1 repo「HW1-CWA-Weather」（台灣六大區域天氣預報：CWA API + SQLite + Streamlit）。

因為 HW1 不是回歸題目，提出兩個方向：(1) 天氣資料集，主題比較連貫；(2) 經典資料集，例如房價。

學生

主題選房價預測，HW2 放在現在資料夾 (告訴我現在資料夾位置)，之後要在 GitHub 建立一個新的

AI

建議用 Kaggle「House Sales in King County, USA」（21,613 筆、18 個特徵，目標 price）。因為沒有 Kaggle 金鑰，詢問下載方式和學號。

學生

從 GitHub 鏡像下載；學號 7115064191。(之後補充：下載資料放在目前資料夾)

AI

下載 `kc_house_data.csv`，寫好並執行主程式 `7115064191_hw2.py`：

- **資料理解**：沒有缺失值、有 177 筆重複成交；價格右偏（偏態 4.02），取 `log` 後變成 0.43；
`sqft_basement = sqft_living - sqft_above`，完全共線。
- **資料準備**：清理後剩 21,419 筆；建立 `log_price`、`house_age`、`is_renovated`、`has_basement`，面積取 `log`；`zipcode` 改為 one-hot；訓練/測試切 80/20。
- **特徵選擇**：用了相關係數、VIF、Backward Elimination、RFECV、LassoCV。

第一次執行時發現 VIF 修剪的邏輯把最重要的 `log_sqft_living` 刪掉了，AI 自己找出問題並修正為「每次取 VIF 最高的特徵和它最相關的夥伴，刪掉其中和目標相關性較弱的那個」。最後選出 12 個特徵。

AI

模型結果（測試集）：

模型	R ² (log)	MAPE
M1 單純線性回歸	0.453	33.1%
M2 MLR 全部 17 個特徵	0.775	19.8%
M3 MLR 選出的 12 個特徵	0.761	20.3%
M4 M3 + zipcode	0.878	13.7%
HistGradientBoosting（對照）	0.905	11.6%

95% 預測區間在測試集的實際覆蓋率是 94.4%（M3）/ 94.0%（M4）。總共產出 11 張圖（含 CI/PI 預測圖）、`predict.py` 部署程式，以及 PDF 報告。另外發現模型檔有 34 MB（`statsmodels` 會存訓練資料），用 `remove_data()` 縮到 60 KB。

學生

然後這個任務設定可在其他電腦也能對話；不行的話就自動重開一個任務，然後告訴我你現在資料夾在哪。

AI

開啟了 Remote Control，可以從 `claude.ai/code` 或手機 App 繼續這個對話。

學生

（截圖）檔案夾用 HW2 那一個資料夾

AI

把所有檔案搬到 `~/本地/ HW2- Multiple Linear regression`。因為資料夾名稱頭尾有空格，對話的工作目錄沒辦法切換過去，所以改用完整路徑處理。也補上 `README.md`、`requirements.txt`，並壓縮成 `7115064191_hw2.zip`。

學生

把和你的對話匯出成 PDF；在 NotebookLM 研究網路上同主題的解法，寫一份 100 字以上的摘要貼進報告。做給我。

AI

在 NotebookLM (Gemini Notebook) 建立筆記本，加入 7 個網路來源 (Kaggle 資料集頁、多個 GitHub / nbviewer 上的 King County 房價 Notebook、AI Planet 上的 Notebook、ITM Conferences 2025 的論文)，請它整理主流解法並寫摘要，再把摘要貼進報告第 9 節，同時產出這份對話紀錄 PDF。

第二段 (Windows)：依評分標準補強

學生

(貼上評分標準截圖) 我的 GitHub 已有這份作業，因為我會用不同電腦做作業，所以如果有更改或是要提醒另外一個 Claude，要寫在 CLAUDE.md (也在 GitHub)。評分標準越完整越好，讓分數盡可能高。

AI

從 GitHub 取得最新版本，把本機資料夾接上 GitHub repo。在 Windows 上安裝套件時，最新版 pandas / scikit-learn 的 DLL 被 Windows「應用程式控制原則」封鎖，改用虛擬環境安裝 pandas 2.2.3 + scikit-learn 1.5.2 後成功執行，且重新執行的數字和 Mac 版完全一致 (可重現)。另外修正 Windows 主控台無法印出「²」的編碼問題。

AI

對照評分標準逐項補強：

- **特徵選擇與評估 (25%)**：新增 Forward Stepwise (AIC/BIC) 佐證；新增 Breusch-Pagan、Jarque-Bera 檢定，發現有異質變異，改用 HC3 穩健標準誤確認 12 個係數中 11 個仍顯著；補上 Random Forest 的 5-fold CV。
- **結果說服力 (15%)**：新增預測區間校準圖 (6 種信賴水準) 與殘差地圖，直接看出 zipcode 消除了地段造成的系統性誤差。
- **作業選項**：補做 Auto Regression (每週中位房價 AR(3))，並如實說明它贏不了 naive 預測、不適合當主模型的原因。
- **文件 (50%)**：加上 CRISP-DM 流程圖、欄位字典、利害關係人表、成功標準檢核表、網路解法 R^2 對照表、結論與限制。

9. NotebookLM 摘要

工具：Google NotebookLM (Gemini Notebook)，筆記本「King County House Price Prediction Models」，2026-10-07。

來源 (7 個)：Kaggle 資料集頁面；nbviewer christopherbrunner/house-prices；GitHub raxshah/Simple-Linear-Regression-Python、ShamGit123/Predicting-House-Price-using-machine-learning-concepts、codewithchirag18/House-Sale-Analysis-EDA-Regression-Python；AI Planet「Predict the House Prices King County」；ITM Conferences KEIS 2025 論文 (itmconf_keis2025_01023)。

常見資料前處理與特徵工程：主流解法多先處理缺失值 (以中位數或平均值補值)、刪除不相關的 ID 欄位，並用 IQR 剔除極端離群值。房價呈右偏分布，會先做對數轉換與標準化；地理位置特徵 (zipcode、lat、long) 對價格影響很大，需要分組或類別編碼；也必須篩掉高度共線的面積欄位 (如 sqft_living 與 sqft_above)。

使用模型與成效 (R^2)：單純線性回歸只能解釋約 49% 的變異 ($R^2 \approx 0.49$)；多元線性回歸可提升到 $R^2 \approx 0.65$ – 0.70 ；加入二次多項式和 Ridge 正則化後約 0.70 – 0.75 ；樹狀集成模型 (隨機森林、XGBoost/LightGBM) 表現最好， R^2 可達 0.85 – 0.87 。

線性模型與樹模型比較：線性模型結構簡單、計算快、可解釋性高，也能直接算出統計預測區間，但無法自動捕捉非線性交互作用和地理空間的差異。樹模型能擬合非線性關係與特徵交互作用，對共線性也較不敏感，但屬於黑盒模型 (需搭配 SHAP 解釋)，也很難直接輸出傳統的參數式預測區間。

對本作業的啟示：多元線性回歸是建構預測區間最直接的工具。要縮小和樹模型的準確度差距，前處理必須對房價做 log 轉換以符合殘差常態假設，用 VIF 或逐步回歸排除共線性變數，並對 zipcode 等區域特徵適當編碼，才能在保有區間估計優勢的同時達到最好的預測成效。

與本作業結果對照：NotebookLM 整理的網路解法中，多元線性回歸 R^2 約 0.65 – 0.70 、樹模型約 0.85 – 0.87 。本作業依照這些建議做了 log 轉換、VIF + 多種方法的特徵選擇，以及 zipcode one-hot，線性模型 M4 達到 R^2 0.878 ，已追平網路上常見的樹模型水準；而且 95% 預測區間實測覆蓋率 94%，正好補上樹模型「難以給出預測區間」的缺點。

10. 結論與限制

結論

1. **影響房價最大的因素**依序是建築等級、室內面積、地段 (緯度 / zipcode)、臨水與景觀；所有係數方向都符合常識。
2. **特徵選擇**用 5 種方法交叉驗證，從 17 個候選特徵選出 12 個， R^2 只損失 0.014，卻消除了共線性。
3. **地段固定效果** (zipcode one-hot) 是線性模型最大的進步來源： R^2 $0.761 \rightarrow 0.878$ ，殘差地圖上的地段群聚因此消失。
4. **預測區間可信**：95% PI 實測覆蓋 94%，校準曲線在 90–95% 幾乎與理想線重合，可以直接用於估價範圍。

限制與未來改進

- 資料只涵蓋 2014/05–2015/05，現在的房價水準已經不同，實際使用前必須用新資料重訓。
- 殘差有異質變異 (Breusch-Pagan $p < 0.001$)，高價房的預測區間可能偏窄；可以改用加權最小平方法 (WLS) 或 conformal prediction 修正。
- 線性模型沒有納入交互作用 (例如「臨水 $\times$ 面積」) ；可以加入交互項或樣條 (spline) 函數，進一步縮小和樹模型的差距。