

HW2：King County 房價預測 — 多元線性回歸

學號 7115064191 | 依循 CRISP-DM 流程 | 主程式 7115064191_hw2.py

資料集來源：House Sales in King County, USA (Kaggle，作者 harlfoxem)
連結：<https://www.kaggle.com/datasets/harlfoxem/housesalesprediction>
內容：2014/05–2015/05 美國華盛頓州 King County (含西雅圖) 21,613 筆房屋成交紀錄，18 個特徵，目標變數 price。
研究脈絡：本作業延伸自 HW1 (台灣天氣預報資料管線，[GitHub](#))。HW1 著重「資料取得與呈現」，HW2 進一步進入「建模與評估」，以線性回歸量化各因素對房價的影響並給出含不確定性的預測。

重點結果

模型	特徵數	Test R ² (log)	5-fold CV R ²	RMSE (USD)	MAPE	95% PI 覆蓋率
M1 單純線性回歸	1	0.453	0.455	296,181	33.1%	—
M2 多元線性回歸 (全部)	17	0.775	0.772	187,262	19.8%	—
M3 多元線性回歸 (特徵選擇後)	12	0.761	0.761	195,199	20.3%	94.4%
M4 = M3 + zipcode one-hot	12+69	0.878	0.879	142,491	13.7%	94.0%
HistGradientBoosting (主流解法對照)	18	0.905	0.903	137,215	11.6%	—

1. Business Understanding (商業理解)

問題：買方、賣方與仲介都需要一個「合理成交價」的參考。單一的點估計不夠，決策者還需要知道價格可能落在哪個範圍。

目標：以線性回歸建立可解釋的房價模型，回答：(1) 哪些因素最影響房價、影響多大？(2) 給定一間房子的條件，預測價格與 95% 預測區間。

成功標準：測試集 $R^2 \geq 0.75$ 、 $MAPE \leq 20\%$ (可解釋模型)；95% 預測區間的實際覆蓋率接近 95%；模型係數方向符合常識。

2. Data Understanding (資料理解)

類別	特徵 (共 18 個)
面積	sqft_living, sqft_lot, sqft_above, sqft_basement, sqft_living15, sqft_lot15
房屋結構	bedrooms, bathrooms, floors
品質/景觀	grade (1–13), condition (1–5), view (0–4), waterfront (0/1)
時間	yr_built, yr_renovated
位置	zipcode, lat, long

- 無缺失值；有 177 筆同一房屋重複成交 (id 重複)；有 33 房、0 衛浴等明顯錯誤資料。

- 價格嚴重右偏（偏態 4.02），取 log 後接近常態（偏態 0.43），因此以 `log(price)` 為建模目標。
- 與價格相關最高的是 `sqft_living` (0.70)、`grade` (0.67)、`sqft_above` (0.61)、`sqft_living15` (0.59)、`bathrooms` (0.53)。
- `sqft_basement = sqft_living - sqft_above` 為完全共線，需處理多重共線性。




圖 1 價格分佈：原始值右偏，取 log 後接近常態




圖 2 18 個特徵與價格的相關係數矩陣




圖 3 與價格相關最高的 6 個特徵散佈圖

3. Data Preparation（資料準備）

- 1. 清理：同一房屋只保留最新一次成交；移除 bedrooms = 0 或 ≥ 15、bathrooms = 0 的錯誤資料 (21,613 → 21,419 筆)。
- 2. 目標轉換：`log_price = log(price)`，讓殘差較接近常態、變異數較穩定，係數可解讀為「百分比變化」。
- 3. 特徵工程：`house_age = 成交年 - yr_built`；`is_renovated = yr_renovated > 0`；`has_basement = sqft_basement > 0`；面積欄位全部取 log。
- 4. 類別變數：zipcode 是名目變數，不能當數值用，在 M4 改為 69 個 one-hot 虛擬變數（地段固定效果）。
- 5. 切分：80% 訓練 (17,135) / 20% 測試 (4,284)，random_state = 42；所有特徵選擇只在訓練集上進行，避免資料洩漏。

4. Modeling（建模）

4.1 特徵選擇（Feature Selection）

對 17 個候選特徵使用四種方法交叉驗證：

方法	做法	結果
相關分析	r 與 log_price	grade、log_sqft_living、log_sqft_living15 最強
VIF	變異數膨脹因子 > 5 代表共線	log_sqft_living / log_sqft_above (≈19.6)、log_sqft_lot / lot15 (≈6.9)
Backward Elimination	OLS 逐步移除 p > 0.05	移除 long (p = 0.81)
RFECV	遞迴特徵消除 + 5-fold CV	最佳 16 個；12 個以後 CV R ² 幾乎不再增加
LassoCV	L1 正則化 (α = 0.00037)	long 係數被壓到 0

決策規則：三種方法（Backward、RFECV、Lasso）中至少 2 票保留 → 再以 VIF ≤ 5 迭代修剪：每次取 VIF 最高的特徵與其最相關的夥伴，刪掉與目標相關較弱者。

最終 12 個特徵：bedrooms, log_sqft_living, log_sqft_lot, floors, waterfront, view, condition, grade, has_basement, house_age, is_renovated, lat

刪除：long（不顯著）、log_sqft_above（與 living 共線）、bathrooms、log_sqft_living15（與 living 高度相關）、log_sqft_lot15（與 lot 共線）




圖 4 左：RFECV 特徵數 vs $CV R^2$ ；右：Lasso 標準化係數（藍＝最終保留）

4.2 模型

- M1 單純線性回歸： $\log(\text{price}) \sim \log(\text{sqft_living})$ ，作為基準。
- M2 多元線性回歸（全部 17 特徵）：檢查特徵選擇是否損失太多。
- M3 多元線性回歸（12 特徵）：主要的可解釋模型，所有變數 $p < 0.05$ 、 $VIF \leq 5$ 。
- M4 = M3 + zipcode one-hot：加入地段固定效果，仍是線性回歸。
- 對照：Ridge、Random Forest、HistGradientBoosting（Kaggle 上常見的樹模型解法）。

4.3 M3 係數解讀（log-linear）

特徵	係數	解讀
log_sqft_living	0.460	室內面積 +10% → 房價約 +4.5%（彈性）
grade	0.191	建築等級每 +1 級 → 房價約 +21%
waterfront	0.397	臨水 → 房價約 +49%
lat	1.337	緯度 +0.1°（往北、接近西雅圖市區）→ 約 +14%
view	0.071	景觀評分每 +1 → 約 +7%
condition	0.060	屋況每 +1 → 約 +6%
is_renovated	0.074	曾翻修 → 約 +8%
house_age	0.0032	控制品質後，老屋略貴（多位於成熟市區）
bedrooms	-0.018	面積固定下房間越多 → 每間越小，價格略降




圖 5 M3 標準化係數與 95% 信賴區間 (所有區間皆不跨 0)

5. Evaluation (評估)

評估指標：測試集 R^2 (log 與還原為美元兩種尺度)、Adjusted R^2 、5-fold CV R^2 、RMSE、MAE、MAPE，以及 95% 預測區間覆蓋率。

模型	$R^2(\log)$	Adj R^2	CV R^2 (mean±sd)	$R^2(\text{USD})$	RMSE	MAE	MAPE
M1 Simple LR	0.453	0.453	0.455±0.008	0.420	296,181	173,926	33.1%
M2 MLR all (17)	0.775	0.774	0.772±0.006	0.768	187,262	110,553	19.8%
M3 MLR selected (12)	0.761	0.760	0.761±0.006	0.748	195,199	113,288	20.3%
M4 MLR + zipcode	0.878	0.876	0.879±0.003	0.866	142,491	76,678	13.7%
Ridge (M4 design)	0.878	—	0.879±0.003	0.866	142,496	76,681	13.7%
Random Forest	0.893	—	—	0.862	144,690	70,425	12.3%
HistGradientBoosting	0.905	—	0.903±0.002	0.876	137,215	64,868	11.6%

- **特徵選擇有效**：M3 用 12 個特徵 (少 5 個)， R^2 只比 M2 低 0.014，但所有係數顯著、無共線性，可解釋性大幅提高。
- **地段是最大缺口**：加入 zipcode 後 R^2 從 0.761 升到 0.878、MAPE 從 20.3% 降到 13.7%，「Location, location, location」。
- **穩定性**：CV R^2 的標準差 ≤ 0.008 ，且 CV 與測試集結果一致，沒有過擬合。Ridge 與 OLS 幾乎相同，也表示共線性已處理好。
- **預測區間可信**：M3 / M4 的 95% PI 在測試集實際覆蓋 94.4% / 94.0%，接近理論值 95%。




圖 6 M1 單純線性回歸：擬合線、95% 信賴區間（橘，平均價格的不確定性）與 95% 預測區間（綠，單一房屋的不確定性）




圖 7 M3 預測圖：隨機 120 間測試房屋，依預測值排序；× 為落在 95% PI 外的房屋




圖 8 M4 (加 zipcode) 預測圖：預測區間明顯變窄 (中位寬度 \$474K → \$330K)




圖 9 實際 vs 預測 (虛線為完美預測)




圖 10 M3 殘差診斷：殘差無明顯趨勢、近似常態（尾部略厚，峰度 4.0），Durbin-Watson = 1.99 無自相關




圖 11 模型比較（藍＝線性回歸家族，灰＝樹模型對照）

6. Deployment（部署）

- 執行主程式後，M4 模型（含特徵清單與 zipcode 類別）存成 `model/house_price_mlr.pkl`。
- `predict.py` 提供 `predict_price()` 函式與命令列介面，輸入房屋條件即輸出預測價與 95% CI / PI：

```
$ python3 predict.py --sqft_living 2000 --grade 8 --zipcode 98052 --lat 47.68
Predicted price : $553,994
95% CI (mean)   : $544,004 - $564,168
95% PI (house)  : $388,300 - $790,393
```

- 後續可沿用 HW1 的 Streamlit 架構做成網頁表單；並應定期以新成交資料重訓（本資料只涵蓋 2014—2015，房價已大幅變動）。

7. 網路主流解法比較與說明

常見做法	說明	本作業對應結果
直接對原始 price 做線性回歸	最常見的入門做法，未處理右偏與共線性	本作業改用 $\log(\text{price})$ ，殘差較常態、PI 才有意義
$\log$ 轉換 + zipcode 虛擬變數	進階線性解法，把地段效果納入	M4： R^2 0.878、MAPE 13.7%
Ridge / Lasso 正則化	處理共線性與特徵選擇	與 OLS 幾乎相同，表示共線性已被特徵選擇處理
樹模型 (Random Forest、XGBoost、LightGBM)	Kaggle 上準確度最高的主流解法，可自動捕捉非線性與交互作用	HistGradientBoosting： R^2 0.905、MAPE 11.6%

比較結論：樹模型準確度最高，但 M4 線性回歸只差約 2–3 個百分點 (R^2 0.878 vs 0.905)，卻有三個優點：(1) 每個係數都可解讀成「百分比影響」；(2) 有統計推論 (p 值、係數信賴區間)；(3) 能直接給出理論上正確且實測覆蓋率 94% 的預測區間，樹模型則需要額外的 quantile regression 或 conformal prediction。若目標是解釋與估價範圍，線性回歸更合適；若只求點預測準確度，則選梯度提升樹。

8. GPT 輔助內容 (AI 對話過程)

學號 7115064191 | 工具：Claude Code (Anthropic, Claude Opus 5.5), 桌面版 Code 分頁 | 日期：2026-10-07

說明：本作業的 AI 協助是用 Claude Code 完成的 (不是 ChatGPT)，以下為對話過程整理 (工具執行的細節已省略)。原始完整紀錄另由 Claude 桌面版「Export」匯出。

學生

(貼上 HW2 作業說明的兩張截圖) HW1 在我的 GitHub (幫我在側邊欄打開)

AI

在側邊欄瀏覽器開了 GitHub，不過當時還找不到你的帳號，所以請你提供 repo 連結或使用者名稱。也先整理了 HW2 的要求：Kaggle 資料集要有 10-20 個特徵、CRISP-DM 六個步驟、特徵選擇、模型評估、含預測區間的預測圖。

學生

這台電腦都設定好了

AI

在 `~/local/bin/gh` 找到 GitHub CLI，帳號是 A0966411725-png，在側邊欄打開了 HW1 repo「HW1-CWA-Weather」(台灣六大區域天氣預報：CWA API + SQLite + Streamlit)。因為 HW1 不是回歸題目，提出兩個方向：(1) 天氣資料集，主題比較連貫；(2) 經典資料集，例如房價。

學生

主題選房價預測，HW2 放在現在資料夾 (告訴我現在資料夾位置)，之後要在 GitHub 建立一個新的

AI

建議用 Kaggle「House Sales in King County, USA」(21,613 筆、18 個特徵，目標 price)。因為沒有 Kaggle 金鑰，詢問下載方式和學號。

學生

從 GitHub 鏡像下載；學號 7115064191。(之後補充：下載資料放在目前資料夾)

AI

下載 `kc_house_data.csv`，寫好並執行主程式 `7115064191_hw2.py`：

- **資料理解**：沒有缺失值、有 177 筆重複成交；價格右偏（偏態 4.02），取 `log` 後變成 0.43；
`sqft_basement = sqft_living - sqft_above`，完全共線。
- **資料準備**：清理後剩 21,419 筆；建立 `log_price`、`house_age`、`is_renovated`、`has_basement`，面積取 `log`；`zipcode` 改為 one-hot；訓練/測試切 80/20。
- **特徵選擇**：用了相關係數、VIF、Backward Elimination、RFECV、LassoCV。

第一次執行時發現 VIF 修剪的邏輯把最重要的 `log_sqft_living` 刪掉了，AI 自己找出問題並修正為「每次取 VIF 最高的特徵和它最相關的夥伴，刪掉其中和目標相關性較弱的那個」。最後選出 12 個特徵。

AI

模型結果（測試集）：

模型	$R^2(\log)$	MAPE
M1 單純線性回歸	0.453	33.1%
M2 MLR 全部 17 個特徵	0.775	19.8%
M3 MLR 選出的 12 個特徵	0.761	20.3%
M4 M3 + zipcode	0.878	13.7%
HistGradientBoosting（對照）	0.905	11.6%

95% 預測區間在測試集的實際覆蓋率是 94.4%（M3） / 94.0%（M4）。總共產出 11 張圖（含 CI/PI 預測圖）、`predict.py` 部署程式，以及 PDF 報告。另外發現模型檔有 34 MB（`statsmodels` 會存訓練資料），用 `remove_data()` 縮到 60 KB。

學生

然後這個任務設定可在其他電腦也能對話；不行的話就自動重開一個任務，然後告訴我你現在資料夾在哪。

AI

開啟了 Remote Control，可以從 `claude.ai/code` 或手機 App 繼續這個對話。

學生

（截圖）檔案夾用 HW2 那一個資料夾

AI

把所有檔案搬到 `~/本地/ HW2- Multiple Linear regression`。因為資料夾名稱頭尾有空格，對話的工作目錄沒辦法切換過去，所以改用完整路徑處理。也補上 `README.md`、`requirements.txt`，並壓縮成 `7115064191_hw2.zip`。

學生

把和你的對話匯出成 PDF；在 NotebookLM 研究網路上同主題的解法，寫一份 100 字以上的摘要貼進報告。做給我。

AI

在 NotebookLM (Gemini Notebook) 建立筆記本，加入 7 個網路來源 (Kaggle 資料集頁、多個 GitHub / nbviewer 上的 King County 房價 Notebook、AI Planet 上的 Notebook、ITM Conferences 2025 的論文)，請它整理主流解法並寫摘要，再把摘要貼進報告第 9 節，同時產出這份對話紀錄 PDF。

9. NotebookLM 摘要

工具：Google NotebookLM (Gemini Notebook)，筆記本「King County House Price Prediction Models」，2026-10-07。

來源 (7 個)：Kaggle 資料集頁面；nbviewer christopherbronner/house-prices；GitHub raxshah/Simple-Linear-Regression-Python、ShamGit123/Predicting-House-Price-using-machine-learning-concepts、codewithchirag18/House-Sale-Analysis-EDA-Regression-Python；AI Planet「Predict the House Prices King County」；ITM Conferences KEIS 2025 論文 (itmconf_keis2025_01023)。

常見資料前處理與特徵工程：主流解法多先處理缺失值（以中位數或平均值補值）、刪除不相關的 ID 欄位，並用 IQR 剔除極端離群值。房價呈右偏分布，會先做對數轉換與標準化；地理位置特徵 (zipcode、lat、long) 對價格影響很大，需要分組或類別編碼；也必須篩掉高度共線的面積欄位（如 sqft_living 與 sqft_above）。

使用模型與成效 (R^2)：單純線性回歸只能解釋約 49% 的變異 ($R^2 \approx 0.49$)；多元線性回歸可提升到 $R^2 \approx 0.65-0.70$ ；加入二次多項式和 Ridge 正則化後約 0.70-0.75；樹狀集成模型（隨機森林、XGBoost/LightGBM）表現最好， R^2 可達 0.85-0.87。

線性模型與樹模型比較：線性模型結構簡單、計算快、可解釋性高，也能直接算出統計預測區間，但無法自動捕捉非線性交互作用和地理空間的差異。樹模型能擬合非線性關係與特徵交互作用，對共線性也較不敏感，但屬於黑盒模型（需搭配 SHAP 解釋），也很難直接輸出傳統的參數式預測區間。

對本作業的啟示：多元線性回歸是建構預測區間最直接的工具。要縮小和樹模型的準確度差距，前處理必須對房價做 log 轉換以符合殘差常態假設，用 VIF 或逐步回歸排除共線性變數，並對 zipcode 等區域特徵適當編碼，才能在保有區間估計優勢的同時達到最好的預測成效。

與本作業結果對照：NotebookLM 整理的網路解法中，多元線性回歸 R^2 約 0.65-0.70、樹模型約 0.85-0.87。本作業依照這些建議做了 log 轉換、VIF + 多種方法的特徵選擇，以及 zipcode one-hot，線性模型 M4 達到 R^2 0.878，已追平網路上常見的樹模型水準；而且 95% 預測區間實測覆蓋率 94%，正好補上樹模型「難以給出預測區間」的缺點。