HW2：King County 房價預測 — 多元線性回歸

學號 7115064191 ｜ 依循 CRISP-DM 流程 ｜ 主程式 `7115064191_hw2.py` ｜ GitHub：A0966411725-png/HW2-Multiple-Linear-regression

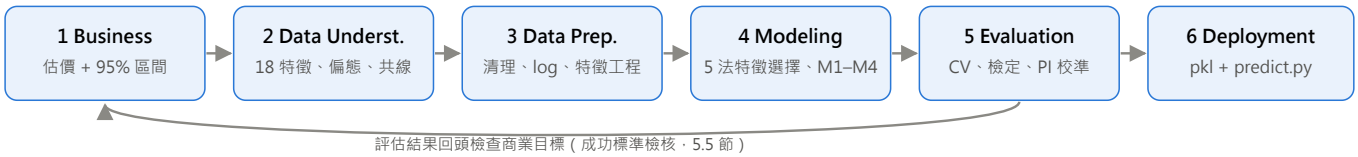
> **資料集來源**：House Sales in King County, USA（Kaggle，作者 harlfoxem，授權 CC0 公眾領域）
> 連結：https://www.kaggle.com/datasets/harlfoxem/housesalesprediction
> 內容：2014/05–2015/05 美國華盛頓州 King County（含西雅圖）21,613 筆房屋成交紀錄，**18 個特徵**，目標變數 `price`。（因為沒有 Kaggle API 金鑰，檔案改從 GitHub 鏡像 Shreyas3108/house-price-prediction 下載，筆數與欄位都和 Kaggle 原檔相同。）
> **研究脈絡**：本作業延伸自 HW1（台灣天氣預報資料管線，GitHub）。HW1 著重「資料取得與呈現」，HW2 進一步進入「建模與評估」：用線性回歸量化各因素對房價的影響，並給出帶有不確定性的預測。選房價是因為它是回歸的經典題目，網路上有大量公開解法可以對照（第 7、9 節）。

重點結果

模型	特徵數	Test R^2(log)	5-fold CV R^2	RMSE (USD)	MAPE	95% PI 覆蓋率
M1 單純線性回歸	1	0.453	0.455	296,181	33.1%	–
M2 多元線性回歸（全部）	17	0.775	0.772	187,262	19.8%	–
M3 多元線性回歸（特徵選擇後）	**12**	**0.761**	**0.761**	**195,199**	**20.3%**	**94.4%**
M4 = M3 + zipcode one-hot	**12+69**	**0.878**	**0.879**	**142,491**	**13.7%**	**94.0%**
M5 = 多項式回歸（二次項）+ zipcode	87+69	0.887	0.889	134,921	13.1%	–
HistGradientBoosting（主流解法對照）	18	0.905	0.903	137,215	11.6%	–

目錄

1. Business Understanding
2. Data Understanding
3. Data Preparation
4. Modeling（特徵選擇、方法比較、Optuna、多項式回歸、Auto Regression）
5. Evaluation（指標、overfit 判斷、五大假設、預測區間校準、成功標準）
6. Deployment
7. 網路主流解法比較與說明
8. AI 輔助內容（Claude Code）
9. NotebookLM 摘要
10. 結論與限制



1. Business Understanding（商業理解）

問題：買方、賣方與仲介都需要一個「合理成交價」的參考。單一的點估計不夠，決策者還需要知道價格可能落在哪個範圍，才能判斷開價是否偏高、議價空間多大。

利害關係人	需求	模型提供的資訊
買方	判斷開價是否合理	預測價與 95% 預測區間；高於區間上限代表可能買貴
賣方 / 仲介	訂定開價、說明房屋價值來源	各因素的百分比影響（係數解讀），例如等級 +1 級約 +21%
估價 / 貸款機構	估價要可解釋、可稽核	線性模型的係數、p 值、信賴區間都可以逐項檢查

目標：以線性回歸建立可解釋的房價模型，回答：(1) 哪些因素最影響房價、影響多大？(2) 給定一間房子的條件，預測價格與 95% 預測區間。

成功標準（在第 5.5 節逐項檢核）：測試集 $R^2 \geq 0.75$、MAPE $\leq 20\%$；95% 預測區間的實際覆蓋率在 93–97% 之間；5-fold CV 與測試集結果一致（不過擬合）；係數方向符合常識。

2. Data Understanding（資料理解）

2.1 欄位字典（18 個特徵 + 目標）

欄位	意義	資料型態（L4-2 量尺）	範圍
price（目標）	成交價（美元）	比例（ratio）	$75K – $7.7M，中位數 $450K
bedrooms / bathrooms	臥室數 / 衛浴數（0.5 = 只有馬桶洗手台）	比例（離散計數）	0–33 / 0–8
sqft_living / sqft_lot	室內面積 / 土地面積（平方英尺）	比例	290–13,540 / 520–1.65M
sqft_above / sqft_basement	地上面積 / 地下室面積（兩者相加 = sqft_living）	比例	290–9,410 / 0–4,820
sqft_living15 / sqft_lot15	最近 15 戶鄰居的平均室內 / 土地面積	比例	399–6,210 / 651–871,200
floors	樓層數	比例（離散）	1–3.5
waterfront	是否臨水	名目（nominal，二元）	0/1（0.75% 為 1）
view	景觀評分	順序（ordinal）	0–4
condition	屋況	順序	1–5
grade	King County 建築品質等級	順序	1–13
yr_built / yr_renovated	建造年 / 翻修年（0 = 未翻修）	區間（interval，年份可加減、不可乘除）	1900–2015
zipcode	郵遞區號	**名目**（數字大小沒有意義 → 需 one-hot）	70 個區
lat / long	緯度 / 經度	區間	47.16–47.78 / −122.52 – −121.315

2.2 觀察

- 無缺失值；有 177 筆同一房屋重複成交（id 重複）；有 33 房、0 衛浴等明顯錯誤資料。

- 價格嚴重右偏（偏態 4.02），取 log 後接近常態（偏態 0.43），因此以 `log(price)` 為建模目標。
- 與價格相關最高的是 `sqft_living`(0.70)、`grade`(0.67)、`sqft_above`(0.61)、`sqft_living15`(0.59)、`bathrooms`(0.53)。
- `sqft_basement = sqft_living − sqft_above` 為完全共線，需處理多重共線性。
- zipcode 雖然是數字，但大小沒有意義（名目變數），不能直接當數值放進回歸。

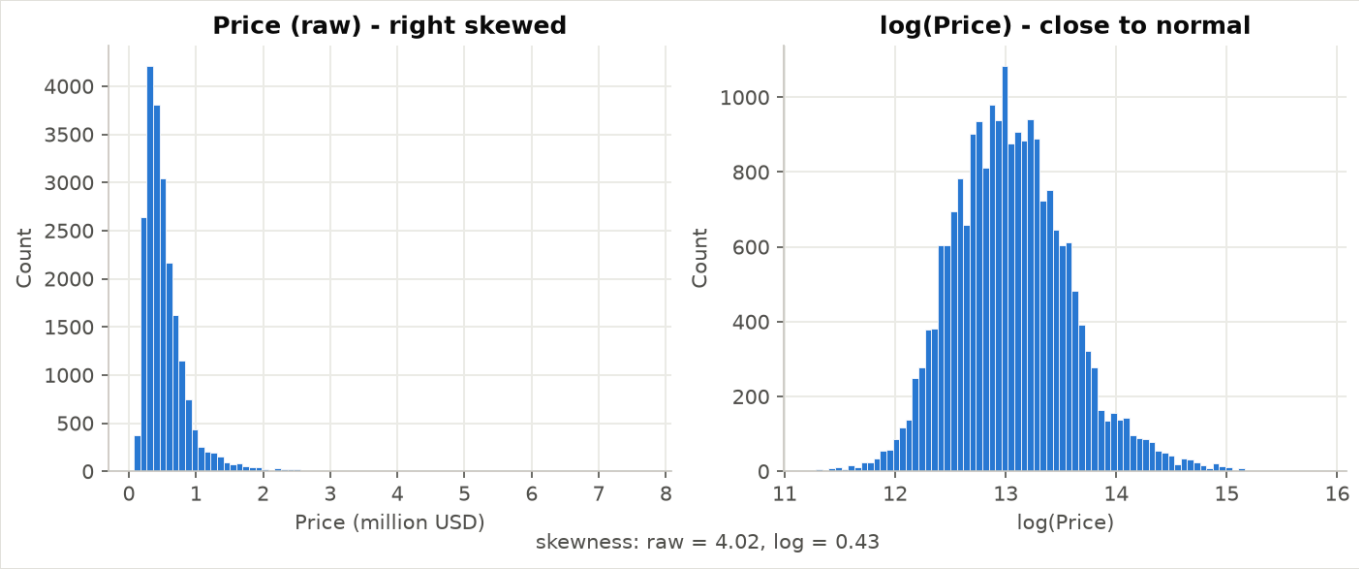


圖 1　價格分佈：原始值右偏，取 log 後接近常態

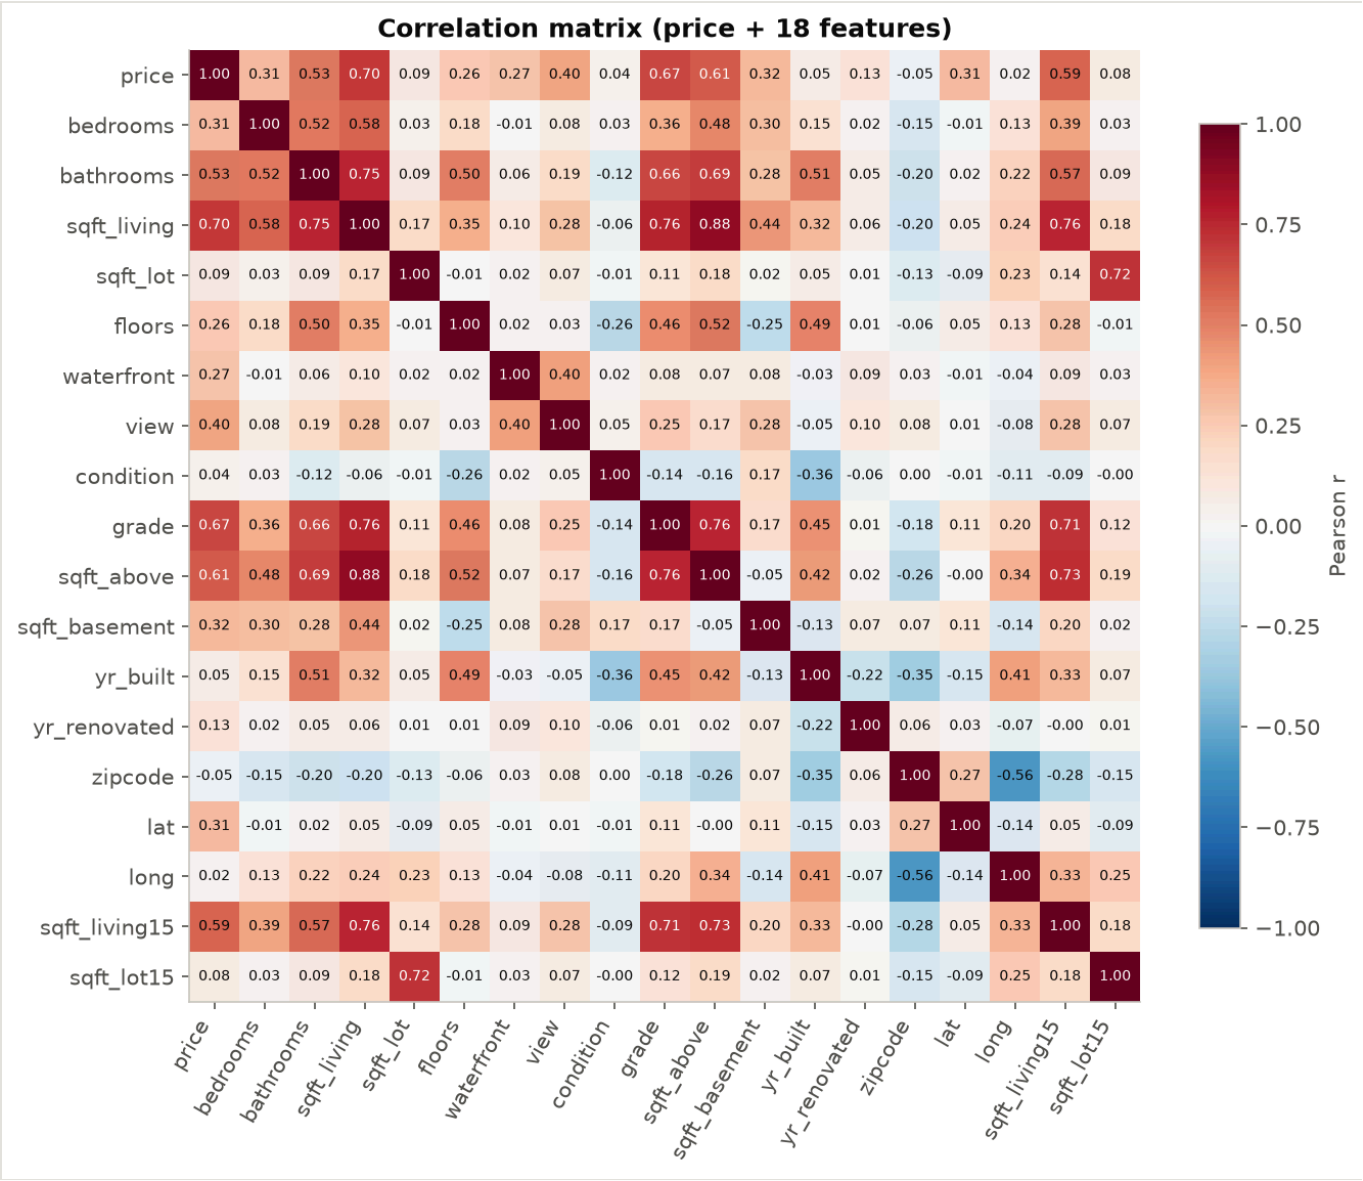


圖 2　18 個特徵與價格的相關係數矩陣

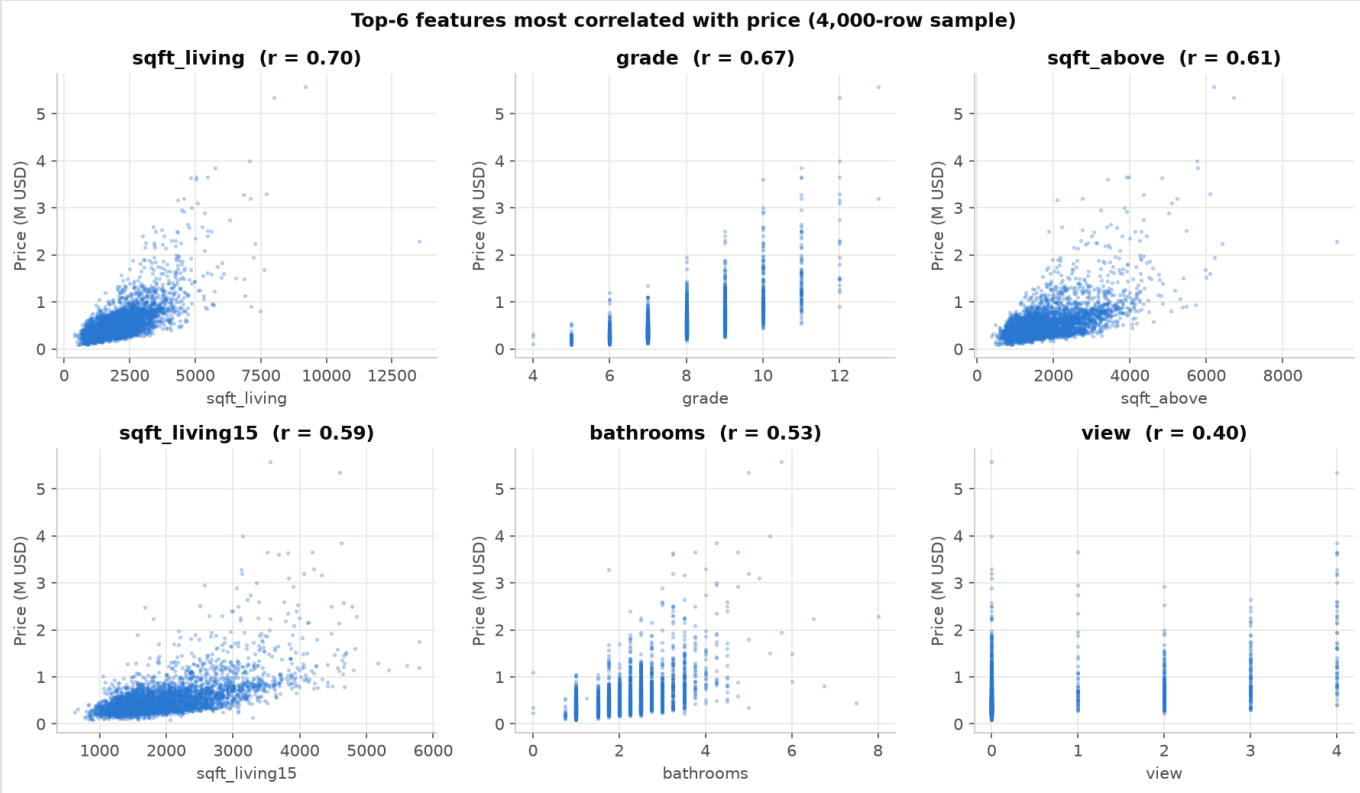


圖 3　與價格相關最高的 6 個特徵散佈圖

3. Data Preparation（資料準備）

1. **清理**：同一房屋只保留最新一次成交；移除 bedrooms = 0 或 ≥ 15、bathrooms = 0 的錯誤資料（21,613 → 21,419 筆）。
2. **目標轉換**：`log_price = log(price)`，讓殘差較接近常態、變異數較穩定，係數可解讀為「百分比變化」。
3. **特徵工程**：`house_age = 成交年 − yr_built`；`is_renovated = yr_renovated > 0`；`has_basement = sqft_basement > 0`；面積欄位全部取 log。
4. **類別變數**：zipcode 是名目變數，在 M4 改為 one-hot 虛擬變數。70 個區只放 69 個（`drop_first=True`），避開 **dummy variable trap**：若 70 個都放，最後一個會等於 1 減去其他所有虛擬變數，和截距完全共線。順序變數（grade、condition、view）保留數值，因為大小有意義。
5. **切分**：80% 訓練（17,135）/ 20% 測試（4,284），random_state = 42；所有特徵選擇只在訓練集上進行，避免資料洩漏。

處理後共有 17 個數值候選特徵：bedrooms, bathrooms, log_sqft_living, log_sqft_lot, floors, waterfront, view, condition, grade, log_sqft_above, has_basement, house_age, is_renovated, lat, long, log_sqft_living15, log_sqft_lot15。

4. Modeling（建模）

4.1 特徵選擇（Feature Selection）

對 17 個候選特徵，使用課程 L6 介紹的各類方法（All-in、Stepwise、Score selection、Lasso）交叉驗證：

方法	做法	結果
相關分析	|r| 與 log_price	grade、log_sqft_living、log_sqft_living15 最強
VIF	變異數膨脹因子 > 5 代表共線	log_sqft_living / log_sqft_above (≈19.6)、log_sqft_lot / lot15 (≈6.9)
Backward Elimination	OLS 逐步移除 p > 0.05	移除 long（p = 0.81）
RFECV	遞迴特徵消除 + 5-fold CV	最佳 16 個；12 個以後 CV R^2 幾乎不再增加
LassoCV	L1 正則化（α = 0.00037）	long 係數被壓到接近 0（−0.0002）
Forward Stepwise（佐證）	每步加入讓 AIC 最低的特徵	前 4 名 grade → lat → log_sqft_living → house_age；第 12 個之後 Adj R^2 只再增加 0.002
Best subset（Score selection，佐證）	暴力搜尋：$2^{17} - 1$ = 131,071 組特徵全部用 OLS 擬合，選 BIC 最低	BIC 最佳為 16 個（只刪 long）；用 Gram 矩陣求解，131,071 次擬合約 3 秒

決策規則：三種方法（Backward、RFECV、Lasso）中至少 2 票保留 → 再以 VIF ≤ 5 迭代修剪：每次取 VIF 最高的特徵與其最相關的夥伴，刪掉與目標相關較弱者。Forward Stepwise 與 Best subset 不參與投票，只用來檢查「留多少個特徵才划算」。

> **最終 12 個特徵**：bedrooms, log_sqft_living, log_sqft_lot, floors, waterfront, view, condition, grade, has_basement, house_age, is_renovated, lat
> **刪除**：long（不顯著）、log_sqft_above（與 living 共線）、bathrooms、log_sqft_living15（與 living 高度相關）、log_sqft_lot15（與 lot 共線）

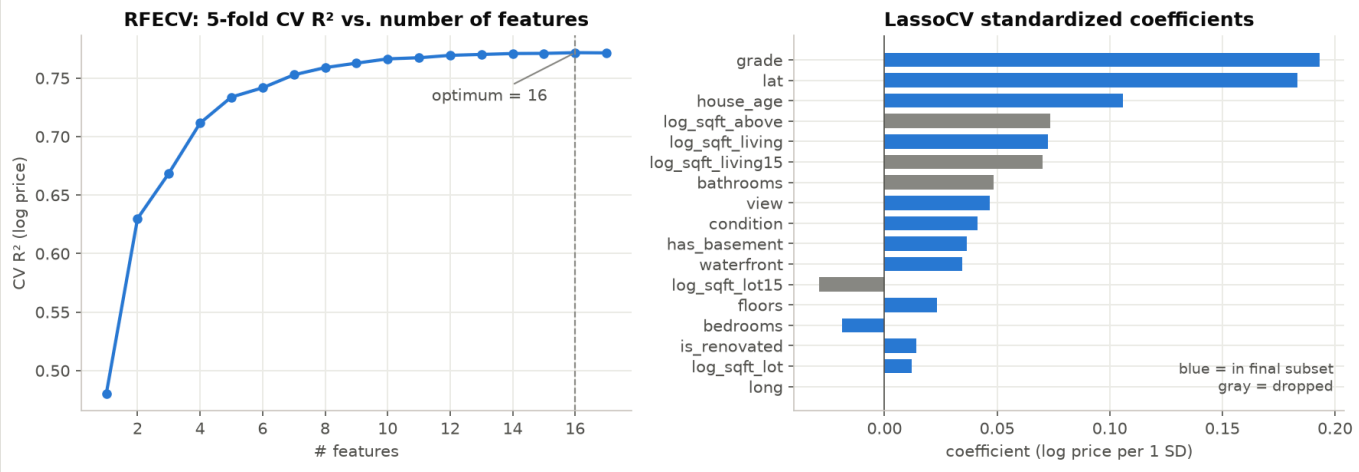


圖 4　左：RFECV 特徵數 vs CV R²；右：Lasso 標準化係數（藍 = 最終保留）

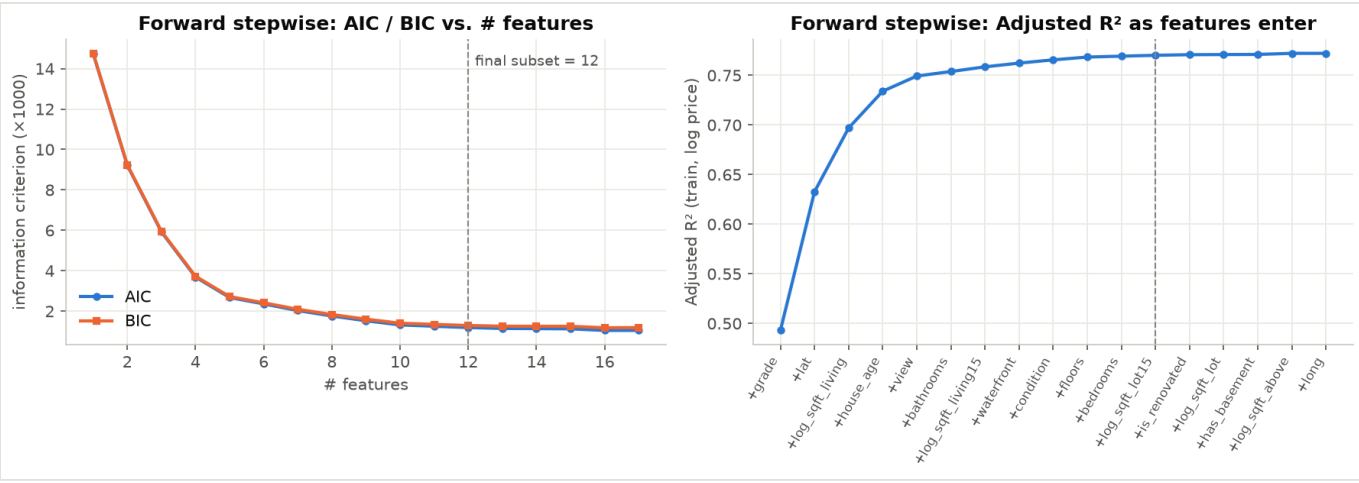


圖 5　Forward Stepwise：左為 AIC/BIC，右為 Adjusted R² 隨特徵加入的變化。12 個特徵之後曲線已經平了

和 Forward Stepwise 的比較：Forward Stepwise 挑出的前 12 個特徵裡有 9 個和我們的子集相同；差別在它選了 bathrooms、log_sqft_living15、log_sqft_lot15，這三個都和已選的面積欄位高度相關。它的 12 特徵模型訓練集 Adj R² 是 0.770，我們的 M3 是 0.761，只差 0.009，但 M3 的最大 VIF 只有 4.4，係數比較穩定、也比較好解讀。我們選擇犧牲一點點擬合度，換取可解釋性。

4.2 各特徵選擇方法在測試集上的比較

參考課程「50 Startup」範例報告的格式，把每一種方法選出的特徵**分別**訓練線性回歸，用同一份測試集比較 MSE 與 R²：

方法	刪除的特徵	特徵數	MSE (log)	RMSE (USD)	R^2 (log)	最大 VIF
All-in（不做選擇）	-	17	0.0630	187,262	0.775	19.6
Backward Elimination（$p < 0.05$）	long	16	0.0630	187,284	0.775	19.6
Forward Selection（BIC 最佳）	long	16	0.0630	187,284	0.775	19.6
RFECV	long	16	0.0630	187,284	0.775	19.6
LassoCV（|係數| > 0.01）	long	16	0.0630	187,284	0.775	19.6
Best subset（暴力搜尋，BIC 最佳）	long	16	0.0630	187,284	0.775	19.6
投票 + VIF ≤ 5（本作業 M3）	**bathrooms, log_sqft_above, long, log_sqft_living15, log_sqft_lot15**	**12**	**0.0668**	**195,199**	**0.761**	**4.4**

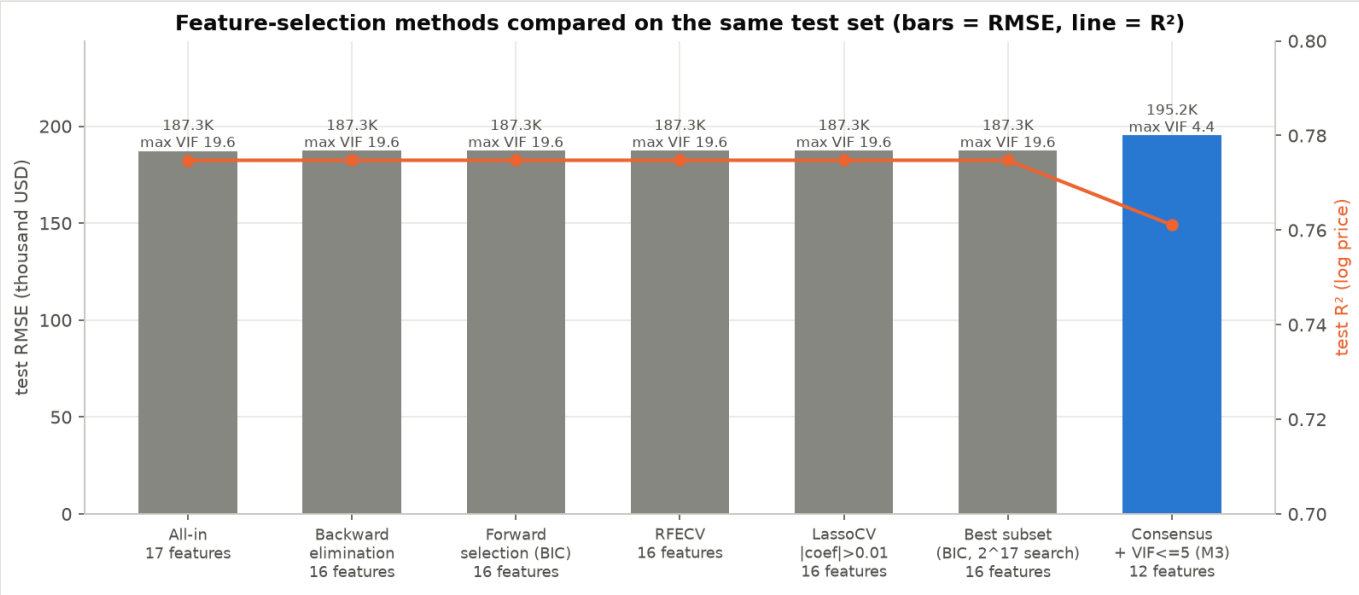


圖 6　各特徵選擇方法在測試集上的 RMSE（長條）與 R^2（折線），上方標註最大 VIF

解讀：五種「純資料導向」的方法（Backward、Forward、RFECV、Lasso、暴力搜尋）全部收斂到**同一組 16 個特徵**（只刪掉 long），測試 R^2 0.775；但它們都同時保留 log_sqft_living 與 log_sqft_above 這類共線組合，最大 VIF 高達 19.6，係數無法單獨解讀。M3 多加了 VIF ≤ 5 的限制，只用 12 個特徵，R^2 少 0.014（RMSE 多約 $7.9K），換來每個係數都穩定、可解讀。準確度的缺口則靠加入 zipcode（M4，R^2 +0.117）補回來，效果遠大於這 0.014。

下表依 L6 Part 2 的格式，列出 Forward Selection 依序加入 1 到 17 個特徵時的訓練 / 測試結果：

特徵數	加入的特徵	Train R^2	Test R^2	Test RMSE (USD)
1	+ grade	0.4930	0.4972	276,099
2	+ lat	0.6327	0.6313	261,097
3	+ log_sqft_living	0.6970	0.6980	242,637
4	+ house_age	0.7341	0.7314	219,473
5	+ view	0.7494	0.7497	202,827
6	+ bathrooms (不在 M3)	0.7539	0.7542	195,379
7	+ log_sqft_living15 (不在 M3)	0.7587	0.7612	194,863
8	+ waterfront	0.7624	0.7657	188,809
9	+ condition	0.7657	0.7689	187,501
10	+ floors	0.7686	0.7706	189,245
11	+ bedrooms	0.7695	0.7723	188,634
12	+ log_sqft_lot15 (不在 M3)	0.7704	0.7739	188,007
13	+ is_renovated	0.7710	0.7740	187,911
14	+ log_sqft_lot	0.7711	0.7742	188,113
15	+ has_basement	0.7713	0.7742	188,326
16	+ log_sqft_above (不在 M3)	0.7724	0.7748	187,284
17	+ long (不在 M3)	0.7724	0.7748	187,262

前 5 個特徵（grade、lat、面積、屋齡、景觀）測試 R^2 就到 0.750；第 12 個之後測試 R^2 只再增加 0.001，RMSE 幾乎不變。訓練與測試 R^2 在每一步都幾乎相同，代表沒有 overfit（見 5.2 節）。

4.3 模型

- **M1 單純線性回歸**：log(price) ~ log(sqft_living)，作為基準。
- **M2 多元線性回歸（全部 17 特徵）**：檢查特徵選擇是否損失太多。
- **M3 多元線性回歸（12 特徵）**：主要的可解釋模型，所有變數 $p < 0.05$、VIF ≤ 5。
- **M4 = M3 + zipcode one-hot**：加入地段固定效果，仍是線性回歸。
- **正則化**：Ridge（RidgeCV 自動選 α）與 Elastic Net（用 **Optuna** 調參，4.5 節），設計與 M4 相同。
- **M5 多項式回歸**：M3 的 12 個特徵加上二次項與兩兩交互作用，再加 zipcode（4.6 節）。
- **對照**：Random Forest、HistGradientBoosting（Kaggle 上常見的樹模型解法）。

4.4 M3 係數解讀（log-linear）

特徵	係數	解讀
log_sqft_living	0.460	室內面積 +10% → 房價約 +4.5%（彈性）
grade	0.191	建築等級每 +1 級 → 房價約 +21%
waterfront	0.397	臨水 → 房價約 +49%
lat	1.337	緯度 +0.1°（往北、接近西雅圖市區）→ 約 +14%
view	0.071	景觀評分每 +1 → 約 +7%
floors	0.069	每多一層樓 → 約 +7%
condition	0.060	屋況每 +1 → 約 +6%
is_renovated	0.074	曾翻修 → 約 +8%
house_age	0.0032	控制品質後，老屋略貴（多位於成熟市區）
bedrooms	−0.018	面積固定下房間越多 → 每間越小，價格略降

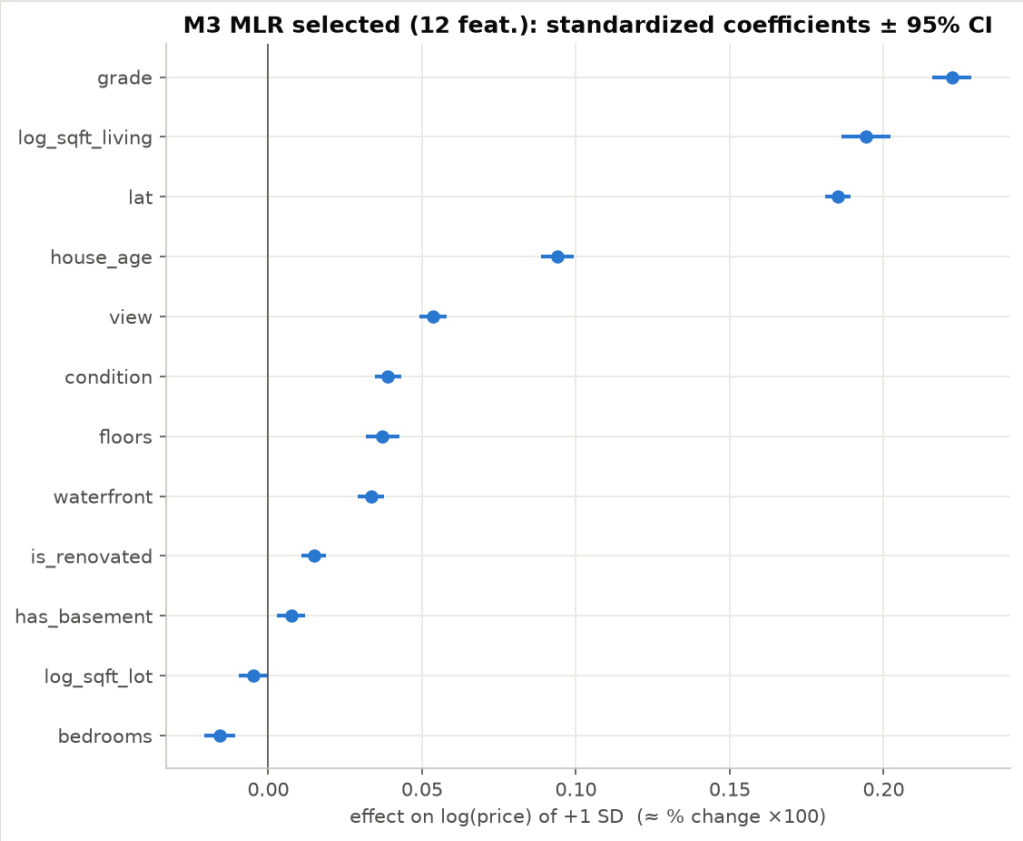


圖 7　M3 標準化係數與 95% 信賴區間（所有區間皆不跨 0）

4.5 用 Optuna 優化模型（Elastic Net）

課程 L6 Step 4 要求用 Optuna 優化模型。線性回歸本身沒有超參數，所以對 M4 的設計改用 **Elastic Net**（同時含 L1 與 L2 懲罰），讓 Optuna 的 TPE 演算法在 40 次試驗中搜尋兩個參數，目標是 5-fold CV R^2 最大：

- `alpha`（正則化強度）：10^{-5} – 10^{-1}，對數尺度
- `l1_ratio`：0（純 Ridge）– 1（純 Lasso）

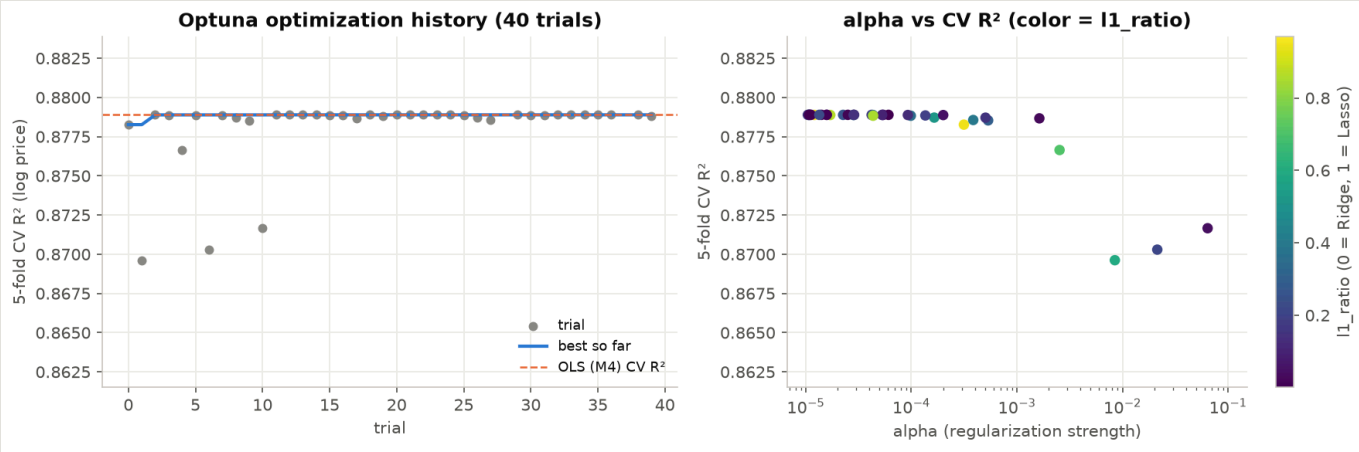


圖 8　Optuna 搜尋過程：左為 40 次試驗的 CV R^2（藍線 = 目前最佳，橘色虛線 = OLS），右為 alpha 與 CV R^2 的關係

結果：最佳參數為 alpha = 1.1×10^{-5}、l1_ratio ≈ 0，CV R^2 0.8789，和不加懲罰的 OLS（0.8789）完全相同；alpha 越大 R^2 越低。也就是說，**Optuna 確認 M4 不需要正則化**：資料有 17,135 筆、特徵已經過 VIF 篩選，OLS 本身就沒有 overfit。（技術細節：Elastic Net 預先計算 Gram 矩陣後，每次訓練從約 18.7 秒降到 0.04 秒，整個主程式約 75 秒跑完。）

4.6 多項式回歸（M5）

課程 L5 列出的線性回歸形式還包含**多項式回歸**。M5 把 M3 的 12 個特徵（先減去平均值）展開成二次項：12 個一次項 + 9 個平方項 + 66 個兩兩交互項（3 個 0/1 變數的平方等於自己，已去除），共 87 項，再加 69 個 zipcode 虛擬變數。模型對「參數」仍是線性的，所以仍屬於線性回歸，用 OLS 求解。

結果：測試 R^2 0.887、CV R^2 0.889、RMSE $134,921、MAPE 13.1%。比 M4 再進步（R^2 +0.009、RMSE −$7.6K），而且**美元尺度的 RMSE 比 HistGradientBoosting（$137,215）還低**。代價是 156 個係數難以逐一解讀，所以部署仍選 M4，M5 用來證明「線性模型加上交互作用後，可以追上樹模型」。

4.7 補充：Auto Regression 試驗

作業允許嘗試 Auto Regression，所以我們也做了測試。不過 AR 是時間序列模型，用變數自己過去的值預測未來；本資料是「每間房子一筆」的橫斷面資料，AR 沒辦法預測個別房屋，只能預測整體市場的價格走勢。做法：把成交價彙總成**每週中位數**（55 週），用前 47 週訓練、AIC 選出落後階數 p = 3，預測最後 8 週。

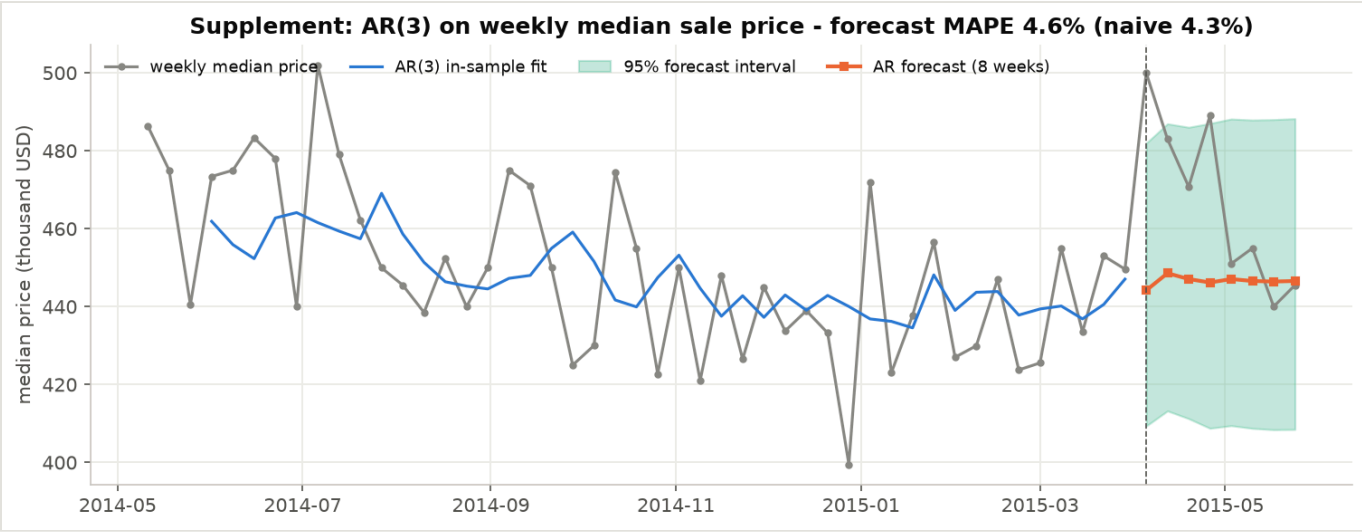


圖 9　AR(3) 預測每週中位房價：MAPE 4.6%，比「直接沿用上週值」的 naive 預測（4.3%）還差；95% 預測區間只涵蓋 8 週中的 6 週（75%）

結論：每週中位數的波動主要是雜訊，加上 2015 年 4 月的春季旺季跳升，這種季節性只有 55 週的資料學不出來，所以 AR 贏不了 naive 預測。房價主要由房屋本身的條件決定，因此主模型採用多元線性回歸，AR 只作為補充。

5. Evaluation（評估）

5.1 評估指標

指標	意義	解讀
MSE	平均平方誤差 = mean((y − ŷ)²)	越小越好；誤差平方，對大誤差特別敏感
RMSE	√MSE，和目標同單位（美元）	越小越好；「典型」預測誤差的大小
MAE	平均絕對誤差 = mean(|y − ŷ|)	越小越好；不受少數極端值影響
MAPE	平均絕對百分比誤差	越小越好；不同價位的房子可以公平比較
R^2 / Adj R^2	模型解釋的變異比例；Adj R^2 會扣除特徵數的影響	越接近 1 越好；Adj R^2 避免「特徵越多 R^2 越高」的假象
5-fold CV R^2	訓練集切 5 份輪流驗證的平均 R^2	和測試 R^2 接近 → 結果穩定、沒有 overfit

模型以 log(price) 訓練，所以 R^2 與 MSE 同時報告 log 尺度，RMSE、MAE、MAPE 則還原成美元。

模型	R^2(log)	Adj R^2	CV R^2 (mean±sd)	MSE(log)	R^2(USD)	RMSE	MAE	MAPE
M1 Simple LR	0.453	0.453	0.455±0.008	0.1530	0.420	296,181	173,926	33.1%
M2 MLR all (17)	0.775	0.774	0.772±0.006	0.0630	0.768	187,262	110,553	19.8%
M3 MLR selected (12)	**0.761**	**0.760**	**0.761±0.006**	**0.0668**	**0.748**	**195,199**	**113,288**	**20.3%**
M4 MLR + zipcode	**0.878**	**0.876**	**0.879±0.003**	**0.0341**	**0.866**	**142,491**	**76,678**	**13.7%**
Ridge (M4 design)	0.878	–	0.879±0.003	0.0341	0.866	142,496	76,681	13.7%
Elastic Net（Optuna）	0.878	–	0.879±0.003	0.0341	0.866	142,493	76,679	13.7%
M5 多項式 + zipcode	0.887	0.882	0.889±0.003	0.0317	0.880	134,921	73,295	13.1%
Random Forest	0.892	–	0.889±0.004	0.0301	0.861	144,842	70,493	12.3%
HistGradientBoosting	0.905	–	0.903±0.002	0.0265	0.876	137,215	64,868	11.6%

- **特徵選擇有效**：M3 用 12 個特徵（少 5 個），R^2 只比 M2 低 0.014，但所有係數顯著、無共線性，可解釋性大幅提高。
- **地段是最大缺口**：加入 zipcode 後 R^2 從 0.761 升到 0.878、MAPE 從 20.3% 降到 13.7%，「Location, location, location」（圖 16 的殘差地圖可以直接看到）。
- **穩定性**：CV R^2 的標準差 ≤ 0.008，且 CV 與測試集結果一致，沒有過擬合。Ridge、Optuna 調出的 Elastic Net 與 OLS 幾乎相同，也表示共線性已處理好、不需要正則化。
- **多項式回歸再進一步**：M5 的 R^2 0.887，美元尺度的 RMSE（$134,921）與 R^2(USD)（0.880）是所有模型中最好的，連樹模型都贏；log 尺度的 R^2 與 MAPE 則仍是 HistGradientBoosting 最好。
- **美元尺度上 M4 的 RMSE 比 Random Forest 還低**（142,491 vs 144,842），只輸給 M5 和 HistGradientBoosting。

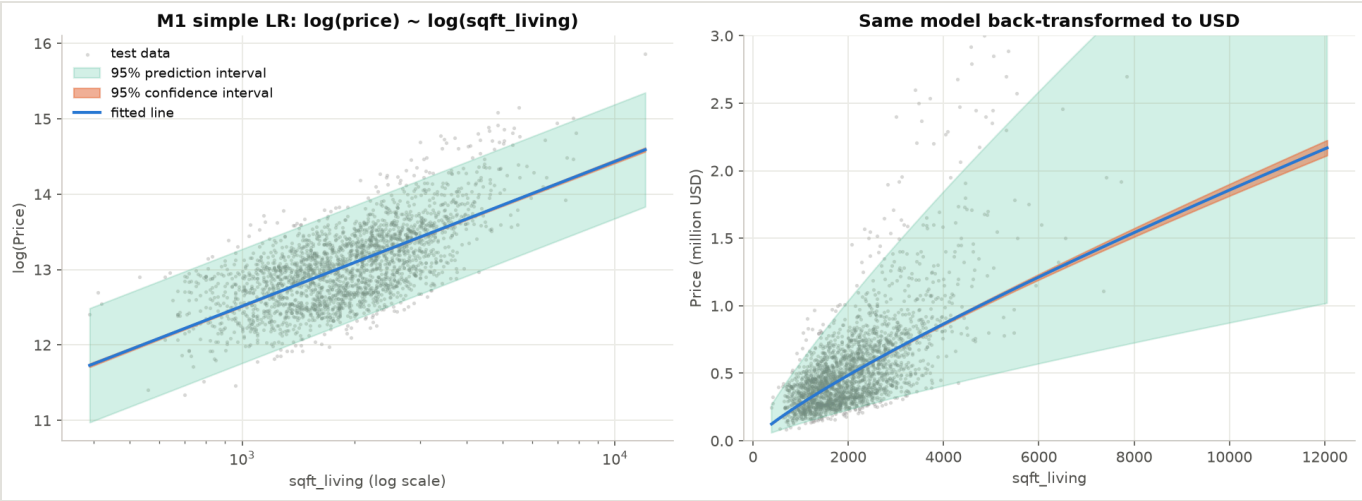


圖 10　M1 單純線性回歸：擬合線、95% 信賴區間（橘，平均價格的不確定性）與 95% 預測區間（綠，單一房屋的不確定性）

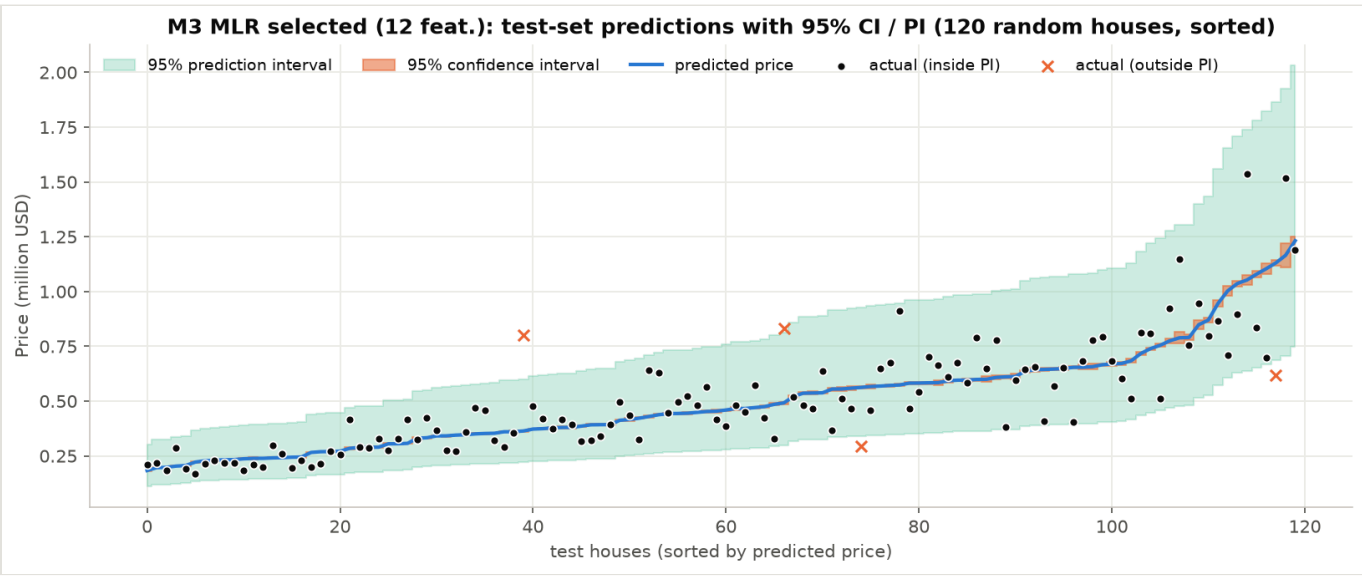


圖 11　M3 預測圖：隨機 120 間測試房屋，依預測值排序；× 為落在 95% PI 外的房屋

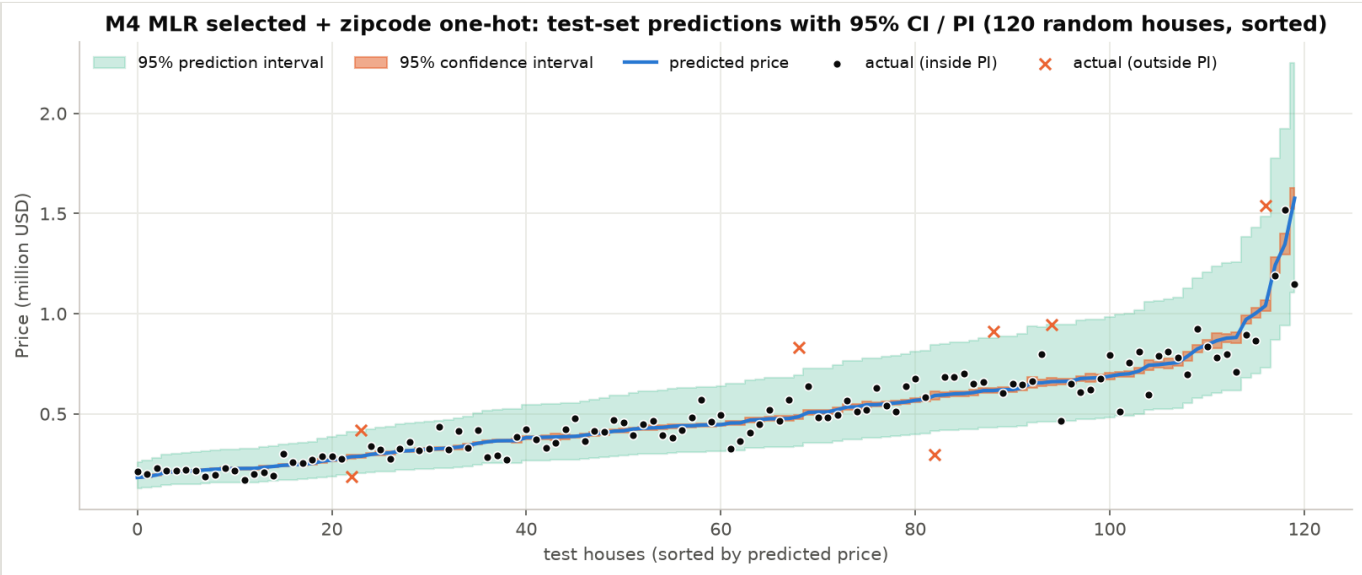


圖 12　M4（加 zipcode）預測圖：預測區間明顯變窄（中位寬度 $474K → $330K）

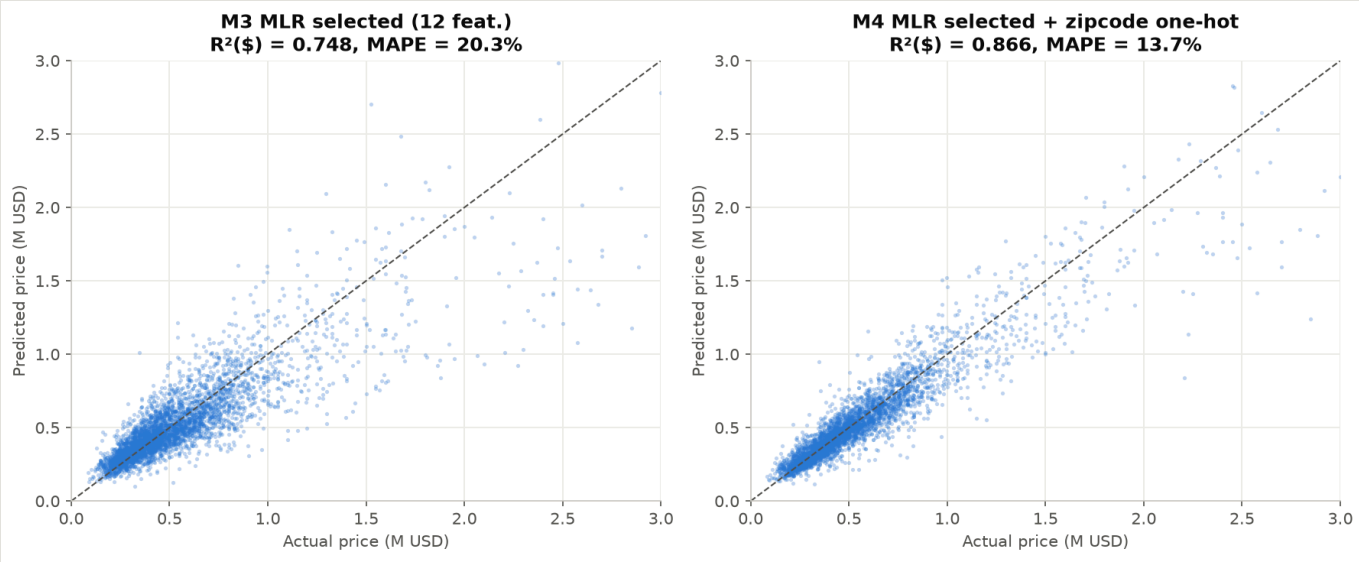


圖 13　實際 vs 預測（虛線為完美預測）

5.2 Overfit / Underfit 判斷（training 與 test 曲線）

依課程 L6 Step 4，畫出訓練與測試（驗證）的誤差曲線判斷模型是否 overfit 或 underfit：

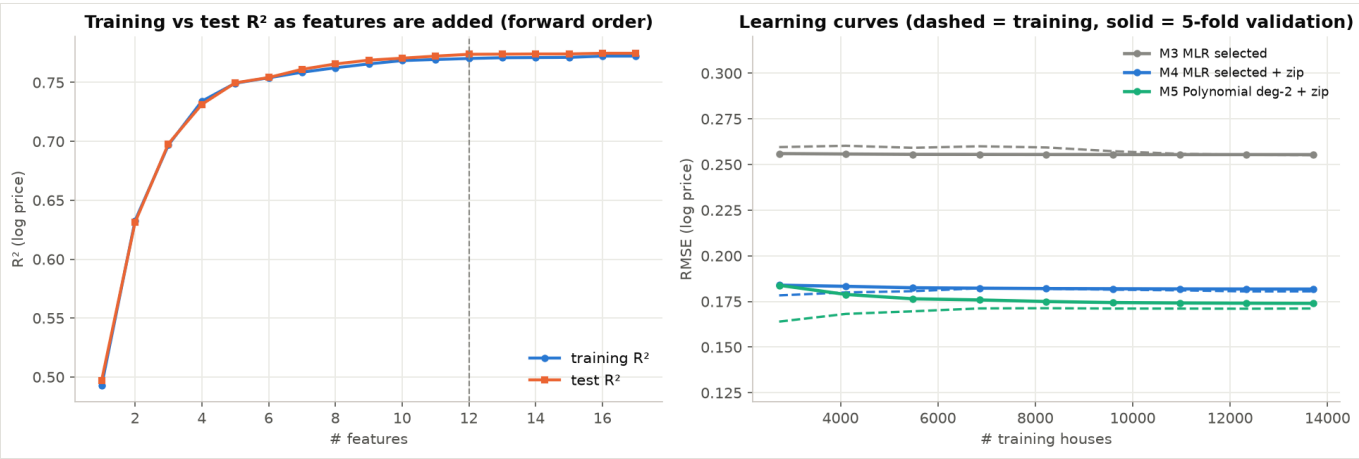


圖 14　左：依 Forward 順序加入特徵時的 training / test R²；右：學習曲線（虛線 = 訓練誤差，實線 = 5-fold 驗證誤差）

- **Underfit**：只用 1–4 個特徵時 R² 只有 0.50–0.73，訓練與測試都差，是典型的 underfit；加到 5 個以上才進入平穩區。
- **沒有 overfit**：每一步的 training R² 與 test R² 幾乎重疊（差距 < 0.004）。學習曲線上，M3、M4 的訓練誤差與驗證誤差從 2,741 筆起差距就在 0.006 以內，用全部資料時 M4 為 0.181 vs 0.182。
- **M5 較複雜**：只用 2,741 筆訓練時，訓練誤差（0.164）明顯低於驗證誤差（0.184），有輕微 overfit；資料增加到 13,708 筆後差距縮小到 0.171 vs 0.174。代表 156 個參數的模型需要足夠的資料，本資料集剛好夠用。

5.3 多元回歸五大假設檢查（M3，訓練集）

課程 L6 列出多元線性回歸的五個前提假設，逐一用統計檢定或圖形檢查：

假設	檢查方法	結果	判讀
1. Linearity（線性）	殘差 vs 預測值圖（圖 15 左）	殘差沿 0 上下分布，沒有明顯的彎曲趨勢	**通過**；面積取 log 後與 log(price) 呈線性
2. Homoscedasticity（變異數同質）	Breusch-Pagan	LM = 605，p < 0.001	**有異質變異** → 改用 HC3 穩健標準誤重新檢定：12 個係數中 11 個仍 p < 0.05（只有 log_sqft_lot 變成 p = 0.078），結論不受影響
3. Multivariate normality（殘差常態）	Jarque-Bera、Q-Q 圖（圖 15 右）	JB = 796，p < 0.001；偏態 0.15、峰度 4.0	**尾部略厚**；樣本 17,135 筆，依中央極限定理係數推論仍可靠
4. Independence of errors（誤差獨立）	Durbin-Watson	1.99	**通過**（接近 2 = 無自相關）
5. Lack of multicollinearity（無共線性）	VIF / 標準化條件數	最大 VIF 4.44；條件數 4.4	**通過**（VIF < 5、條件數 < 30）；這正是 M3 用 VIF ≤ 5 修剪特徵的原因

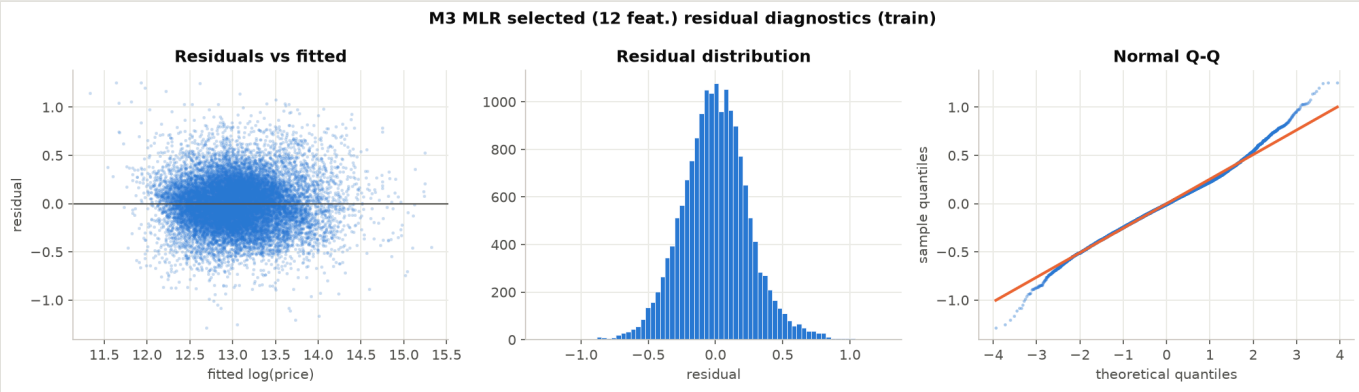


圖 15　M3 殘差診斷：殘差無明顯趨勢、近似常態（尾部略厚，峰度 4.0）

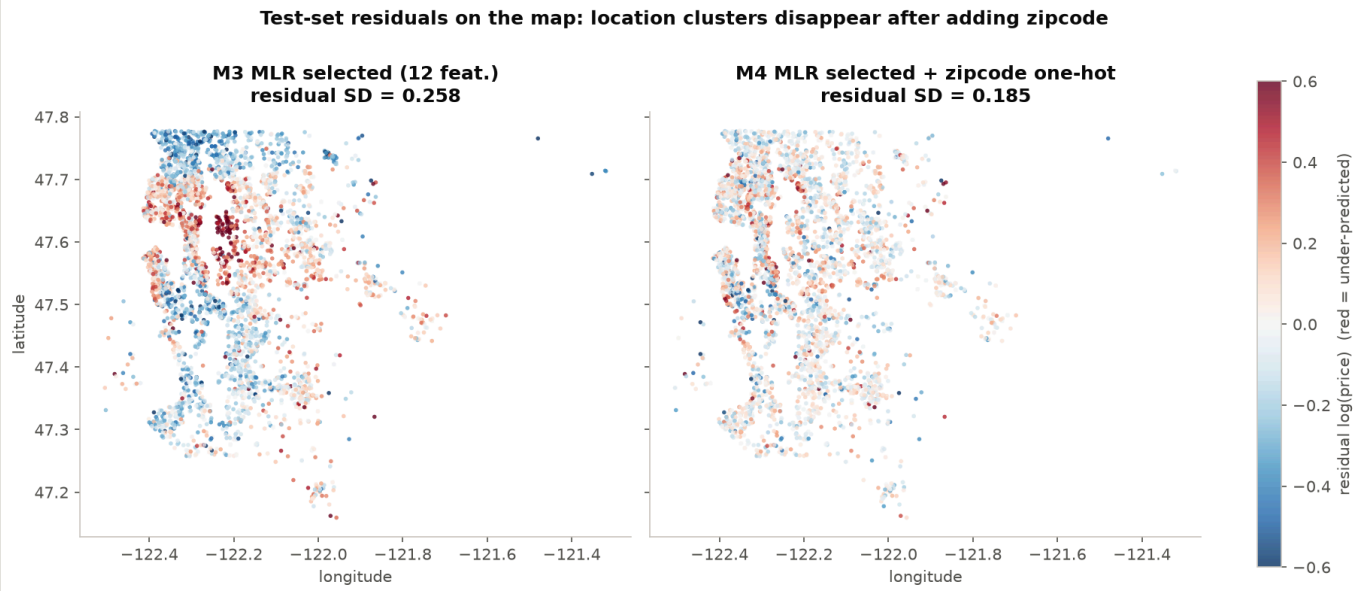


圖 16　測試集殘差地圖：M3（左）在西雅圖市區與 Bellevue、Mercer Island 一帶系統性低估（紅色群聚），在北邊 Shoreline 與南邊郊區高估（藍色群聚）；加入 zipcode 後（右）群聚消失，殘差標準差從 0.258 降到 0.185

5.4 預測區間校準

只看 95% 一個點不夠，所以再檢查 50%、68%、80%、90%、95%、99% 六種信賴水準下，測試集實際落在預測區間內的比例：

名目水準	50%	68%	80%	90%	95%	99%
M3 實際覆蓋率	52.6%	71.1%	81.7%	90.2%	94.4%	98.1%
M4 實際覆蓋率	57.4%	73.5%	83.4%	90.5%	94.0%	97.6%

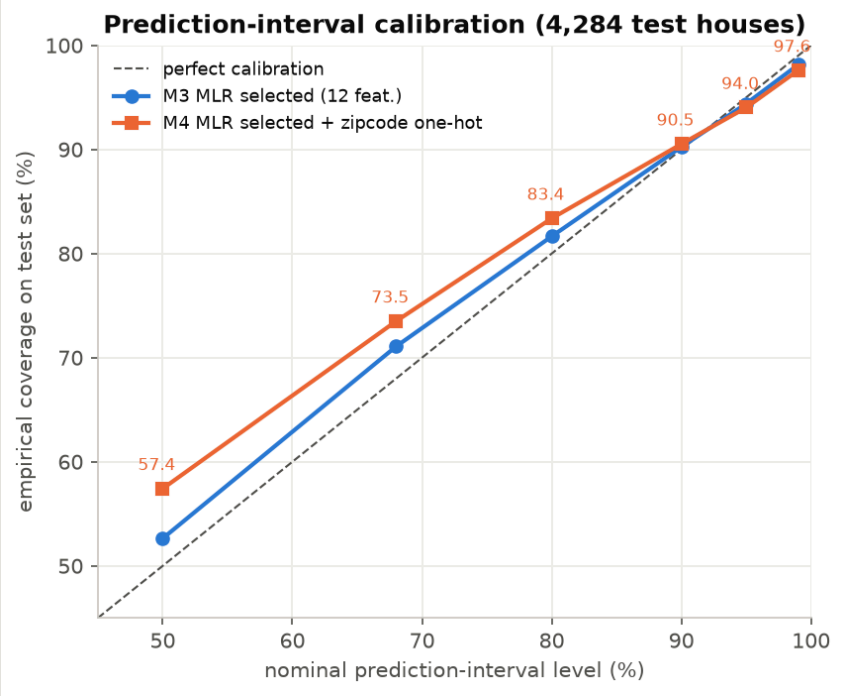


圖 17　預測區間校準圖：越接近虛線越準。90–95% 幾乎完全吻合；低水準時略為保守、99% 略不足，這和殘差「中間尖、尾部厚」（峰度 4.0）一致

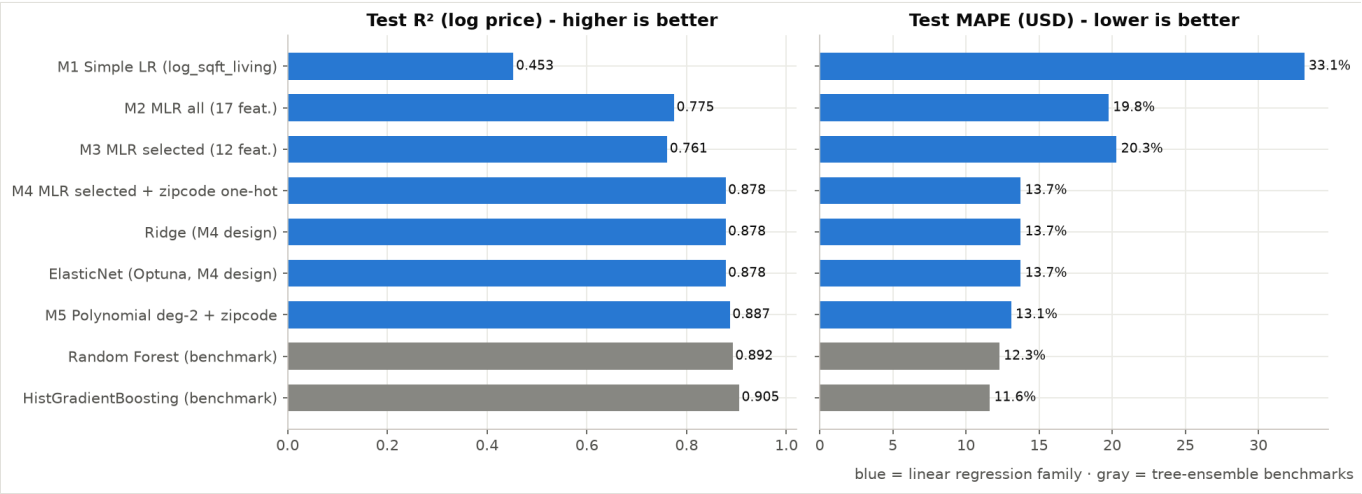


圖 18　模型比較（藍 = 線性回歸家族，灰 = 樹模型對照）

5.5 成功標準檢核（回到 Business Understanding）

成功標準	M3（12 特徵）	M4（+ zipcode）
測試集 $R^2 \geq 0.75$	✓ 0.761	✓ 0.878
MAPE ≤ 20%	✗ 20.3%（差 0.3 個百分點）	✓ 13.7%
95% PI 覆蓋率在 93–97%	✓ 94.4%	✓ 94.0%
CV 與測試一致（不過擬合）	✓ 0.761 vs 0.761	✓ 0.879 vs 0.878
係數方向符合常識	✓ 面積、等級、臨水、景觀皆為正	✓

結論：**M4 達成全部成功標準，作為部署模型**；M3 用來解釋「哪些因素影響房價」。

6. Deployment（部署）

- 執行主程式後，M4 模型（含特徵清單與 zipcode 類別）用 **pickle + gzip**（課程 L6 Step 5）存成 `model/house_price_mlr.pkl.gz`。先用 `remove_data()` 去掉 statsmodels 存的訓練資料（34 MB → 57 KB），再用 gzip 壓縮成 39 KB。
- `predict.py` 提供 `predict_price()` 函式與命令列介面，輸入房屋條件即輸出預測價與 95% CI / PI：

```
$ python predict.py --sqft_living 2000 --grade 8 --zipcode 98052 --lat 47.68
Predicted price : $553,994
95% CI (mean)   : $544,004 - $564,168
95% PI (house)  : $388,300 - $790,393
```

- 解讀：同條件房屋的**平均**價格約 $544K–$564K（CI，窄）；**單一一間**房子的成交價有 95% 機率落在 $388K–$790K（PI，寬，因為包含個別房屋的差異）。
- 程式在 macOS（python3）與 Windows（python）都測試過可以直接執行，執行紀錄會自動寫入 `results/run_log.txt`。
- 後續可沿用 HW1 的 Streamlit 架構做成網頁表單；並應定期以新成交資料重訓（本資料只涵蓋 2014–2015，房價已大幅變動）。

7. 網路主流解法比較與說明

此資料集在 Kaggle 是 Dataset（不是 Competition），**沒有排行榜名次**，所以改和網路上公開的解法（Kaggle Notebook、GitHub、論文，見第 9 節 NotebookLM 的 7 個來源）回報的 R^2 對照：

常見做法	網路上回報的 R^2	本作業對應結果
單純線性回歸（price ~ sqft_living）	≈ 0.49	M1：0.453（log 尺度，已移除錯誤資料）
多元線性回歸（原始 price、未處理共線性）	≈ 0.65–0.70	M2：0.775、M3：0.761
多項式 + Ridge 正則化	≈ 0.70–0.75	**M5 多項式：0.887**；Ridge / Elastic Net（Optuna）：0.878
log 轉換 + zipcode 虛擬變數	—	**M4：0.878、MAPE 13.7%**
樹模型（Random Forest、XGBoost、LightGBM）	≈ 0.85–0.87	RF：0.892、HistGradientBoosting：0.905

面向	多元線性回歸（M4）	梯度提升樹（HGB）
準確度	R^2 0.878、MAPE 13.7%	R^2 0.905、MAPE 11.6%
可解釋性	每個係數都可以讀成「百分比影響」，有 p 值與信賴區間	黑盒，需要 SHAP 等工具輔助
預測區間	理論公式直接給出，實測覆蓋率 94%，校準良好	需要額外的 quantile regression 或 conformal prediction
非線性、交互作用	需要人工設計（log、zipcode one-hot）	自動學習

比較結論：樹模型準確度最高，但 M4 線性回歸只差約 2–3 個百分點（R^2 0.878 vs 0.905），而且已經超過網路上常見的樹模型成績（0.85–0.87）；加上交互作用的 M5（R^2 0.887）在美元 RMSE 上甚至比 HistGradientBoosting 還低。線性回歸能做到這個程度，關鍵是三件事：log 轉換、系統化的特徵選擇、zipcode 地段固定效果。若目標是解釋與估價範圍，線性回歸更合適；若只求點預測準確度，則選梯度提升樹。

8. AI 輔助內容（Claude Code 對話過程）

> 學號 7115064191 ｜ 工具：Claude Code（Anthropic，Claude Opus 5.5），桌面版 Code 分頁 ｜ 日期：2026-10-07、2026-10-12
> 說明：本作業使用的 AI 輔助工具是 **Claude Code**（Anthropic），以下為對話過程整理（工具執行的細節已省略）。完整對話紀錄另附 `7115064191_ai_conversation.pdf`。作業分三段完成：第一段建立完整分析，第二段依評分標準補強，第三段對照課程講義補強。只收錄和作業內容有關的對話。

第一段：建立完整分析

> **學生**
> （貼上 HW2 作業說明的兩張截圖）HW2 要延伸自我的 HW1。

> **AI**
> 整理 HW2 的要求：Kaggle 資料集要有 10–20 個特徵、CRISP-DM 六個步驟、特徵選擇、模型評估、含預測區間的預測圖。查看 HW1「HW1-CWA-Weather」（台灣六大區域天氣預報：CWA API + SQLite + Streamlit）後，因為 HW1 不是回歸題目，提出兩個方向：(1) 天氣資料集，主題比較連貫；(2) 經典資料集，例如房價。

> **學生**
> 主題選房價預測。

> **AI**
> 建議用 Kaggle「House Sales in King County, USA」（21,613 筆、18 個特徵，目標 price）。因為沒有 Kaggle 金鑰，詢問下載方式和學號。

> **學生**
> 從 GitHub 鏡像下載；學號 7115064191。

> **AI**
> 下載 `kc_house_data.csv`，寫好並執行主程式 `7115064191_hw2.py`：
>
> - **資料理解**：沒有缺失值、有 177 筆重複成交；價格右偏（偏態 4.02），取 log 後變成 0.43；sqft_basement = sqft_living − sqft_above，完全共線。
> - **資料準備**：清理後剩 21,419 筆；建立 log_price、house_age、is_renovated、has_basement，面積取 log；zipcode 改為 one-hot；訓練/測試切 80/20。
> - **特徵選擇**：用了相關係數、VIF、Backward Elimination、RFECV、LassoCV。
>
> 第一次執行時發現 VIF 修剪的邏輯把最重要的 log_sqft_living 刪掉了，AI 自己找出問題並修正為「每次取 VIF 最高的特徵和它最相關的夥伴，刪掉其中和目標相關性較弱的那個」。最後選出 12 個特徵。

AI

模型結果（測試集）：

模型	R^2(log)	MAPE
M1 單純線性回歸	0.453	33.1%
M2 MLR 全部 17 個特徵	0.775	19.8%
M3 MLR 選出的 12 個特徵	0.761	20.3%
M4 M3 + zipcode	0.878	13.7%
HistGradientBoosting（對照）	0.905	11.6%

95% 預測區間在測試集的實際覆蓋率是 94.4%（M3）/ 94.0%（M4）。總共產出 11 張圖（含 CI/PI 預測圖）、`predict.py` 部署程式，以及 PDF 報告。另外發現模型檔有 34 MB（statsmodels 會存訓練資料），用 `remove_data()` 縮到 60 KB。

學生

在 NotebookLM 研究網路上同主題的解法，寫一份 100 字以上的摘要貼進報告。

AI

在 NotebookLM（Gemini Notebook）建立筆記本，加入 7 個網路來源（Kaggle 資料集頁、多個 GitHub / nbviewer 上的 King County 房價 Notebook、AI Planet 上的 Notebook、ITM Conferences 2025 的論文），請它整理主流解法並寫摘要，再把摘要貼進報告第 9 節。

第二段：依評分標準補強

學生

（貼上評分標準截圖）評分標準越完整越好，讓分數盡可能高。

AI

先在另一台電腦（Windows）重新執行主程式，數字和原本完全相同，確認結果可以重現；並修正 Windows 主控台印不出「²」的編碼問題，讓程式在 macOS 與 Windows 都能直接執行。

AI

對照評分標準逐項補強（不改變原本的特徵選擇與模型數字）：

- **特徵選擇與評估**：新增 Forward Stepwise（AIC/BIC）佐證圖：前 12 名有 9 個和我們的子集相同，差異的 3 個都是共線的面積欄位。新增 Breusch-Pagan、Jarque-Bera、條件數檢定；Breusch-Pagan 顯示有異質變異，所以改用 HC3 穩健標準誤重新檢定，12 個係數中 11 個仍顯著（只有 log_sqft_lot 變成 p = 0.078）。補上 Random Forest 的 5-fold CV（0.889 ± 0.004）。
- **結果說服力**：新增預測區間校準圖（50%–99% 六種水準，90–95% 幾乎與理想線重合），以及殘差地圖：M3 在市區有明顯的低估群聚，加入 zipcode 後群聚消失，殘差標準差從 0.258 降到 0.185。
- **Auto Regression**：用每週中位房價做 AR(3)，預測最後 8 週的 MAPE 是 4.6%，比 naive 預測（4.3%）還差。報告如實說明：橫斷面資料不適合用 AR，所以 AR 只當補充。
- **報告**：加上 CRISP-DM 流程圖、欄位字典、利害關係人表、成功標準檢核表（M4 全部達成，M3 的 MAPE 20.3% 差一點沒達到）、網路解法 R^2 對照表（此資料集在 Kaggle 是 Dataset，沒有排行榜）、結論與限制。

第三段：對照課程講義補強

學生

（打開課程 Notion 頁面）查看有關這次作業的相關東西，看看有沒有需要修正；「GPT 輔助內容」改成「AI 輔助內容」，填 Claude Code。

AI

讀了課程 L4-2（CRISP-DM、資料型態）、L5（Simple LR 到 Auto Regression）、L6（Multiple Linear Regression、50 Startup）以及老師的「50 STARTUP Kaggle Report」範例報告，對照後找出要補的地方：

- 範例報告把每一種特徵選擇方法**分開**訓練，用測試集的 MSE 與 R^2 比較；L6 Part 2 要列出選 1 到 N 個特徵的 RMSE / R^2 表。
- L6 Step 4 要用 training / test 曲線判斷 overfit / underfit，並用 **Optuna** 優化模型；Step 5 部署要用 **gzip + pickle**。
- L6 Part 4 列出多元回歸的五大假設（線性、變異數同質、常態、誤差獨立、無共線性）；Part 5 介紹 Score selection（暴力搜尋所有特徵組合）與 dummy variable trap。
- L5 列出多項式回歸、Elastic Net 等線性回歸形式；L4-2 要區分名目 / 順序 / 區間 / 比例四種資料型態。

AI

依講義補強（原本的 M1–M4 數字不變）：

- **特徵選擇比較**：新增暴力搜尋（$2^{17} - 1 = 131{,}071$ 組，用 Gram 矩陣約 3 秒算完）。Backward、Forward、RFECV、Lasso、暴力搜尋五種方法全部收斂到同一組 16 個特徵（只刪 long），測試 R^2 0.775，但最大 VIF 19.6；M3 加上 VIF ≤ 5 後只用 12 個特徵，R^2 0.761、VIF 4.4。另外發現 long 的 Lasso 係數其實是 −0.0002（接近 0，不是剛好 0），報告的說法跟著修正。
- **Overfit / Underfit**：1–4 個特徵時 underfit；每一步的 training 與 test R^2 差距都小於 0.004，沒有 overfit。學習曲線顯示 M5 在小樣本時有輕微 overfit，資料變多後消失。
- **Optuna**：對 Elastic Net 的 alpha 與 l1_ratio 搜尋 40 次，最佳結果 CV R^2 0.8789，和 OLS 完全相同，確認不需要正則化。第一次執行時一次訓練要 18 秒以上，改用預先計算 Gram 矩陣後降到 0.04 秒。
- **多項式回歸 M5**：12 個特徵的二次項與交互作用（87 項）加 zipcode，測試 R^2 0.887，美元 RMSE $134,921，比 HistGradientBoosting 還低。
- **報告**：加入 MSE 與各指標的定義、五大假設檢查表（補上線性假設）、資料型態欄位、dummy variable trap 說明、gzip 部署（57 KB → 39 KB）、CRISP-DM 總結表；「GPT 輔助內容」改為「AI 輔助內容（Claude Code）」。

9. NotebookLM 摘要

> 工具：Google NotebookLM（Gemini Notebook），筆記本「King County House Price Prediction Models」，2026-10-07。
> 來源（7 個）：Kaggle 資料集頁面；nbviewer christopherbronner/house-prices；GitHub raxshah/Simple-Linear-Regression-Python、ShamGit123/Predecting-House-Price-using-machine-learning-concepts、codewithchirag18/House-Sale-Analysis-EDA-Regression-Python；AI Planet「Predict the House Prices King County」；ITM Conferences KEIS 2025 論文（itmconf_keis2025_01023）。

常見資料前處理與特徵工程：主流解法多先處理缺失值（以中位數或平均值補值）、刪除不相關的 ID 欄位，並用 IQR 剔除極端離群值。房價呈右偏分布，會先做對數轉換與標準化；地理位置特徵（zipcode、lat、long）對價格影響很大，需要分組或類別編碼；也必須篩掉高度共線的面積欄位（如 sqft_living 與 sqft_above）。

使用模型與成效 (R^2)：單純線性回歸只能解釋約 49% 的變異（$R^2 \approx 0.49$）；多元線性回歸可提升到 $R^2 \approx 0.65$–0.70；加入二次多項式和 Ridge 正則化後約 0.70–0.75；樹狀集成模型（隨機森林、XGBoost/LightGBM）表現最好，R^2 可達 0.85–0.87。

線性模型與樹模型比較：線性模型結構簡單、計算快、可解釋性高，也能直接算出統計預測區間，但無法自動捕捉非線性交互作用和地理空間的差異。樹模型能擬合非線性關係與特徵交互作用，對共線性也較不敏感，但屬於黑盒模型（需搭配 SHAP 解釋），也很難直接輸出傳統的參數式預測區間。

對本作業的啟示：多元線性回歸是建構預測區間最直接的工具。要縮小和樹模型的準確度差距，前處理必須對房價做 log 轉換以符合殘差常態假設，用 VIF 或逐步回歸排除共線性變數，並對 zipcode 等區域特徵適當編碼，才能在保有區間估計優勢的同時達到最好的預測成效。

> **與本作業結果對照**：NotebookLM 整理的網路解法中，多元線性回歸 R^2 約 0.65–0.70、樹模型約 0.85–0.87。本作業依照這些建議做了 log 轉換、VIF + 多種方法的特徵選擇，以及 zipcode one-hot，線性模型 M4 達到 R^2 0.878，已追平網路上常見的樹模型水準；而且 95% 預測區間實測覆蓋率 94%，正好補上樹模型「難以給出預測區間」的缺點。

10. 結論與限制

CRISP-DM 流程總結

步驟	目的	本作業做了什麼	結果
Business Understanding	定義問題與成功標準	估價 + 95% 預測區間；訂出 R^2、MAPE、PI 覆蓋率標準	5 項成功標準（5.5 節檢核）
Data Understanding	認識資料與品質	欄位字典、資料型態、偏態、相關係數、共線性檢查	價格右偏、面積欄位共線、zipcode 是名目變數
Data Preparation	清理、轉換、切分	去除重複與錯誤資料、log 轉換、特徵工程、one-hot（避開 dummy trap）、80/20 切分	21,419 筆、17 個候選特徵
Modeling	選特徵、建模型	7 種特徵選擇方法比較；M1–M5、Ridge、Optuna Elastic Net、AR 補充、樹模型對照	12 個特徵；M4 R^2 0.878、M5 R^2 0.887
Evaluation	評估準確度與可信度	MSE / RMSE / MAE / MAPE / R^2、CV、overfit 曲線、五大假設、PI 校準	M4 達成全部成功標準；PI 覆蓋 94%
Deployment	讓模型可以被使用	pickle + gzip 存檔、`predict.py` 命令列工具	輸入房屋條件 → 預測價與 95% CI / PI

結論

1. **影響房價最大的因素**依序是建築等級、室內面積、地段（緯度 / zipcode）、臨水與景觀；所有係數方向都符合常識。
2. **特徵選擇**：Backward、Forward、RFECV、Lasso、暴力搜尋（131,071 組）五種方法都收斂到同一組 16 個特徵；再加上 VIF ≤ 5 的限制選出 12 個，R^2 只損失 0.014，卻消除了共線性。
3. **模型穩定**：training / test 曲線幾乎重疊，沒有 overfit；Optuna 調參確認不需要正則化。
4. **地段固定效果**（zipcode one-hot）是線性模型最大的進步來源：R^2 0.761 → 0.878，殘差地圖上的地段群聚因此消失。
5. **預測區間可信**：95% PI 實測覆蓋 94%，校準曲線在 90–95% 幾乎與理想線重合，可以直接用於估價範圍。

限制與未來改進

- 資料只涵蓋 2014/05–2015/05，現在的房價水準已經不同，實際使用前必須用新資料重訓。
- 殘差有異質變異（Breusch-Pagan $p < 0.001$），高價房的預測區間可能偏窄；可以改用加權最小平方法（WLS）或 conformal prediction 修正。
- M5 證明交互作用有幫助，但 156 個係數難以解讀；未來可以只挑少數有意義的交互項（例如「臨水 × 面積」），兼顧準確度與可解釋性。