HW2：King County 房價預測 — 多元線性回歸

學號 7115064191 ｜ 依循 CRISP-DM 流程 ｜ 主程式 `7115064191_hw2.py` ｜ 網站：hw2-mlr-yenkai.streamlit.app ｜ GitHub：A0966411725-png/HW2-Multiple-Linear-regression

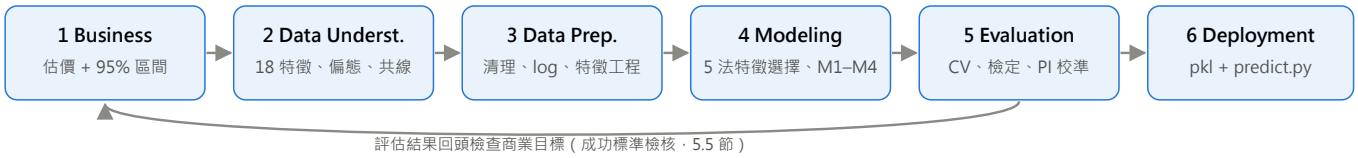
> **資料集來源**：House Sales in King County, USA（Kaggle，作者 harlfoxem，授權 CC0 公眾領域）
> 連結：https://www.kaggle.com/datasets/harlfoxem/housesalesprediction
> 內容：2014/05–2015/05 美國華盛頓州 King County（含西雅圖）21,613 筆房屋成交紀錄，**18 個特徵**，目標變數 `price`。特徵數同時符合作業要求的 10–20 個，以及作業頁補充建議的 14–39 個。（因為沒有 Kaggle API 金鑰，檔案改從 GitHub 鏡像 Shreyas3108/house-price-prediction 下載，筆數與欄位都和 Kaggle 原檔相同。）
> **研究脈絡**：本作業延伸自 HW1（台灣天氣預報資料管線，GitHub）。HW1 著重「資料取得與呈現」，HW2 進一步進入「建模與評估」：用線性回歸量化各因素對房價的影響，並給出帶有不確定性的預測。選房價是因為它是回歸的經典題目，網路上有大量公開解法可以對照（第 7、9 節）。

重點結果

模型	特徵數	Test R^2(log)	5-fold CV R^2	RMSE (USD)	MAPE	95% PI 覆蓋率
M1 單純線性回歸	1	0.453	0.455	296,181	33.1%	–
M2 多元線性回歸（全部）	17	0.775	0.772	187,262	19.8%	–
M3 多元線性回歸（特徵選擇後）	**12**	**0.761**	**0.761**	**195,199**	**20.3%**	**94.4%**
M4 = M3 + zipcode one-hot	**12+69**	**0.878**	**0.879**	**142,491**	**13.7%**	**94.0%**
M5 = 多項式回歸（二次項）+ zipcode	87+69	0.887	0.889	134,921	13.1%	–
HistGradientBoosting（主流解法對照）	18	0.905	0.903	137,215	11.6%	–

目錄

1. Business Understanding
2. Data Understanding
3. Data Preparation
4. Modeling（特徵選擇、方法比較、五種方法 × k、Optuna、多項式回歸、AR）
5. Evaluation（指標、overfit 判斷、五大假設、預測區間校準、成功標準）
6. Deployment（預測新樣本、解釋、網站）
7. 網路主流解法比較與說明
8. AI 輔助內容（Claude Code）
9. NotebookLM 摘要
10. 結論與限制



1. Business Understanding（商業理解）

問題：買方、賣方與仲介都需要一個「合理成交價」的參考。單一的點估計不夠，決策者還需要知道價格可能落在哪個範圍，才能判斷開價是否偏高、議價空間多大。

利害關係人	需求	模型提供的資訊
買方	判斷開價是否合理	預測價與 95% 預測區間；高於區間上限代表可能買貴
賣方 / 仲介	訂定開價、說明房屋價值來源	各因素的百分比影響（係數解讀），例如等級 +1 級約 +21%
估價 / 貸款機構	估價要可解釋、可稽核	線性模型的係數、p 值、信賴區間都可以逐項檢查

目標：以線性回歸建立可解釋的房價模型，回答：(1) 哪些因素最影響房價、影響多大？(2) 給定一間房子的條件，預測價格與 95% 預測區間。

成功標準（在第 5.5 節逐項檢核）：測試集 $R^2 \geq 0.75$、MAPE $\leq 20\%$；95% 預測區間的實際覆蓋率在 93–97% 之間；5-fold CV 與測試集結果一致（不過擬合）；係數方向符合常識。

2. Data Understanding（資料理解）

2.1 欄位字典（18 個特徵 + 目標）

欄位	意義	資料型態（L4-2 量尺）	範圍
price（目標）	成交價（美元）	比例（ratio）	$75K – $7.7M，中位數 $450K
bedrooms / bathrooms	臥室數 / 衛浴數（0.5 = 只有馬桶洗手台）	比例（離散計數）	0–33 / 0–8
sqft_living / sqft_lot	室內面積 / 土地面積（平方英尺）	比例	290–13,540 / 520–1.65M
sqft_above / sqft_basement	地上面積 / 地下室面積（兩者相加 = sqft_living）	比例	290–9,410 / 0–4,820
sqft_living15 / sqft_lot15	最近 15 戶鄰居的平均室內 / 土地面積	比例	399–6,210 / 651–871,200
floors	樓層數	比例（離散）	1–3.5
waterfront	是否臨水	名目（nominal，二元）	0/1（0.75% 為 1）
view	景觀評分	順序（ordinal）	0–4
condition	屋況	順序	1–5
grade	King County 建築品質等級	順序	1–13
yr_built / yr_renovated	建造年 / 翻修年（0 = 未翻修）	區間（interval，年份可加減、不可乘除）	1900–2015
zipcode	郵遞區號	**名目**（數字大小沒有意義 → 需 one-hot）	70 個區
lat / long	緯度 / 經度	區間	47.16–47.78 / −122.52 – −121.315

2.2 觀察

- 無缺失值；有 177 筆同一房屋重複成交（id 重複）；有 33 房、0 衛浴等明顯錯誤資料。
- 價格嚴重右偏（偏態 4.02），取 log 後接近常態（偏態 0.43），因此以 `log(price)` 為建模目標。
- 與價格相關最高的是 `sqft_living` (0.70)、`grade` (0.67)、`sqft_above` (0.61)、`sqft_living15` (0.59)、`bathrooms` (0.53)。
- `sqft_basement = sqft_living − sqft_above` 為完全共線，需處理多重共線性。
- zipcode 雖然是數字，但大小沒有意義（名目變數），不能直接當數值放進回歸。

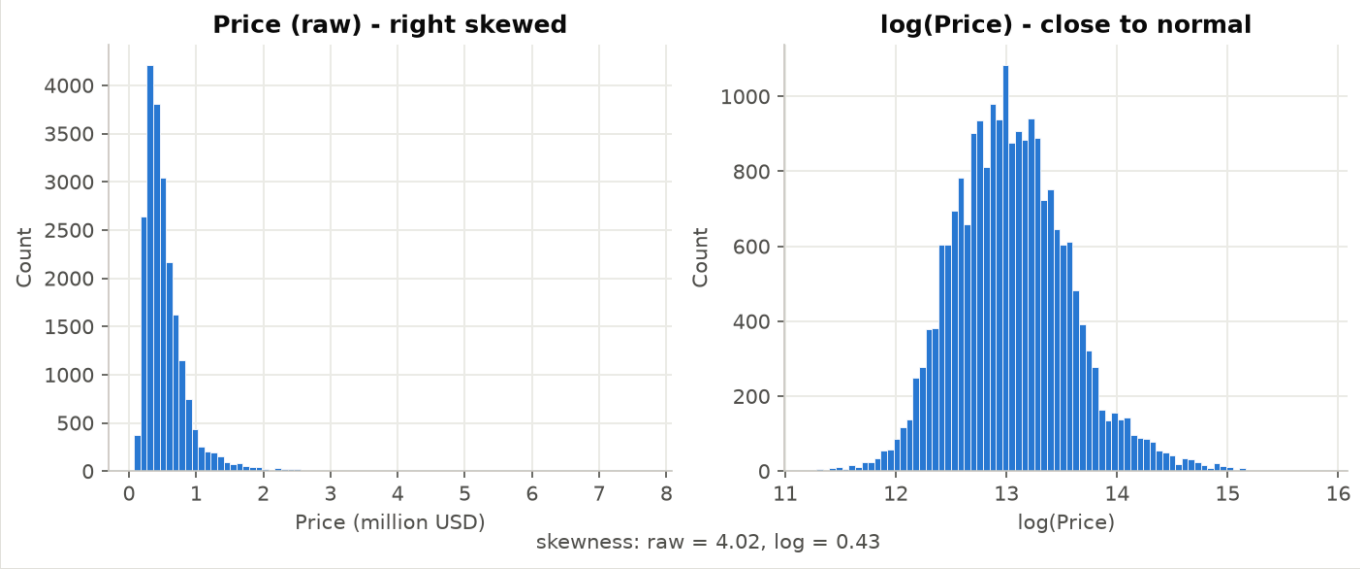


圖 1　價格分佈：原始值右偏，取 log 後接近常態

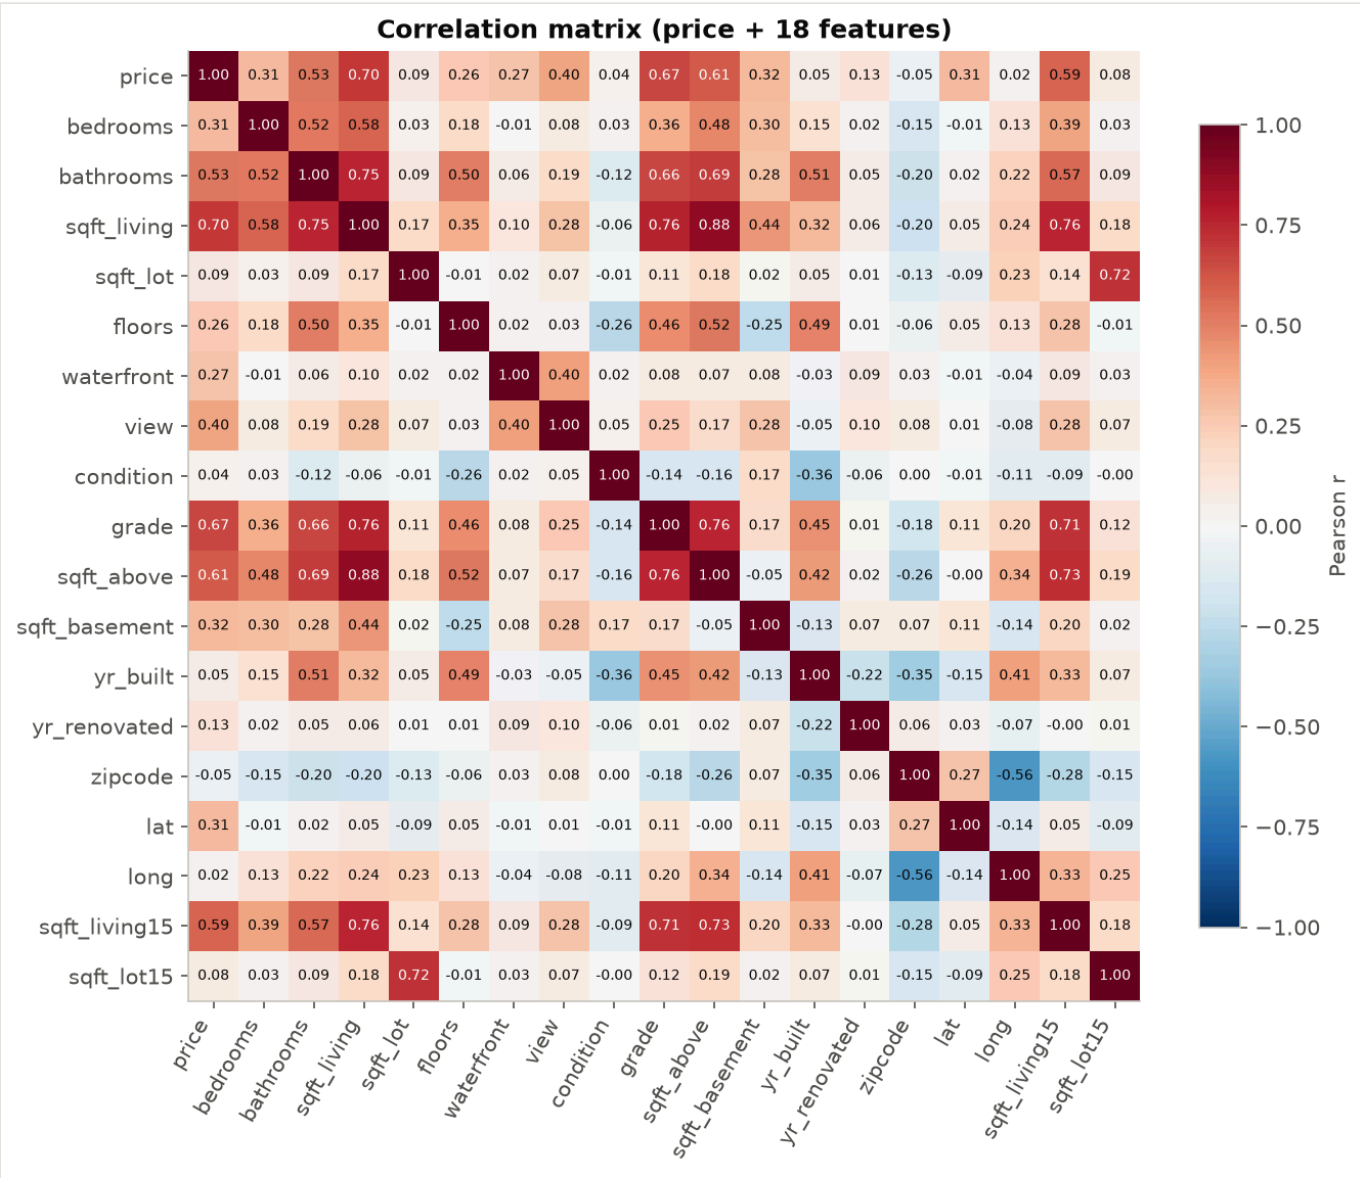


圖 2　18 個特徵與價格的相關係數矩陣

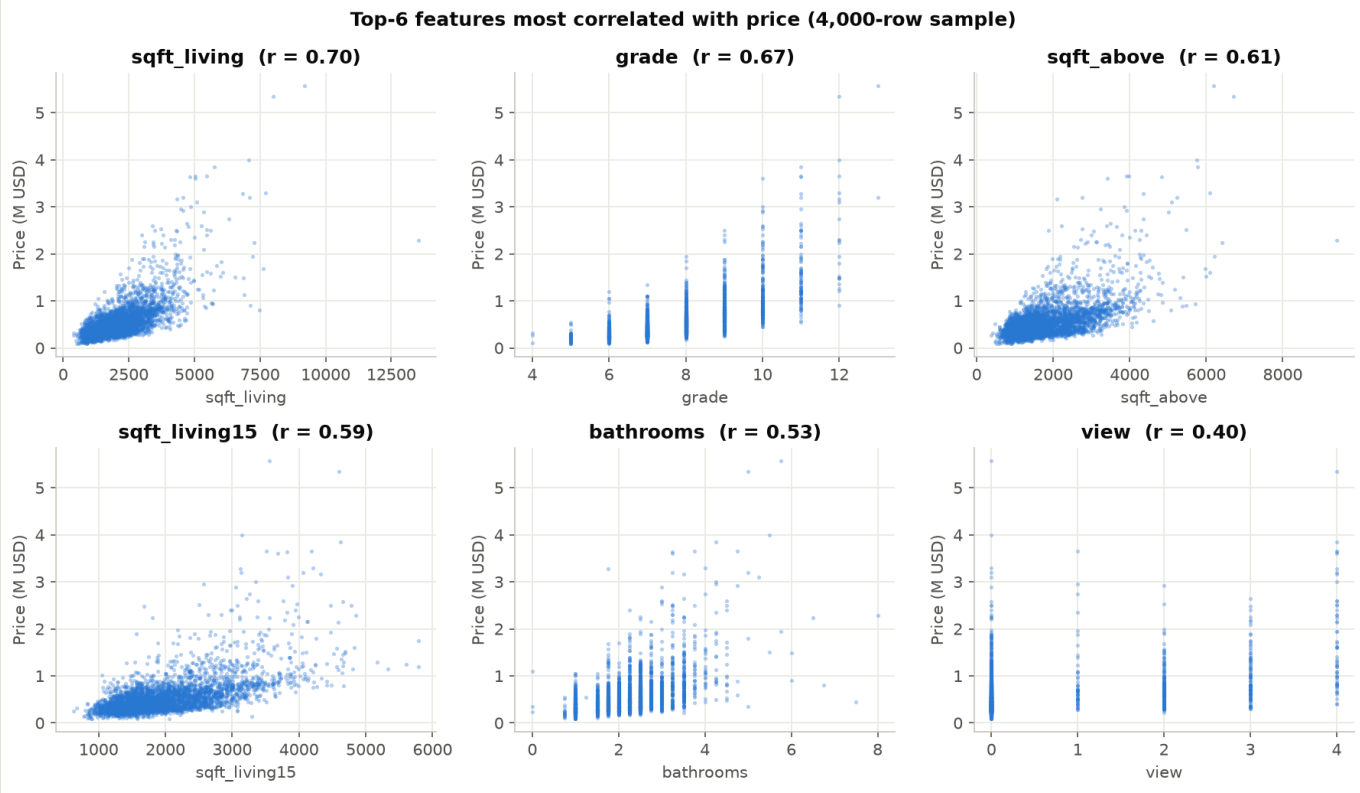


圖 3　與價格相關最高的 6 個特徵散佈圖

3. Data Preparation（資料準備）

1. **清理**：同一房屋只保留最新一次成交；移除 bedrooms = 0 或 ≥ 15、bathrooms = 0 的錯誤資料（21,613 → 21,419 筆）。
2. **目標轉換**：`log_price = log(price)`，讓殘差較接近常態、變異數較穩定，係數可解讀為「百分比變化」。
3. **特徵工程**：`house_age = 成交年 − yr_built`；`is_renovated = yr_renovated > 0`；`has_basement = sqft_basement > 0`；面積欄位全部取 log。
4. **類別變數**：zipcode 是名目變數，在 M4 改為 one-hot 虛擬變數。70 個區只放 69 個（`drop_first=True`），避開 **dummy variable trap**：若 70 個都放，最後一個會等於 1 減去其他所有虛擬變數，和截距完全共線。順序變數（grade、condition、view）保留數值，因為大小有意義。
5. **切分**：80% 訓練（17,135）/ 20% 測試（4,284），random_state = 42；所有特徵選擇只在訓練集上進行，避免資料洩漏。

處理後共有 17 個數值候選特徵：bedrooms, bathrooms, log_sqft_living, log_sqft_lot, floors, waterfront, view, condition, grade, log_sqft_above, has_basement, house_age, is_renovated, lat, long, log_sqft_living15, log_sqft_lot15。

4. Modeling（建模）

4.1 特徵選擇（Feature Selection）

對 17 個候選特徵，使用課程 L6 介紹的各類方法（All-in、Stepwise、Score selection、Lasso）交叉驗證：

方法	做法	結果
相關分析	|r| 與 log_price	grade、log_sqft_living、log_sqft_living15 最強
VIF	變異數膨脹因子 > 5 代表共線	log_sqft_living / log_sqft_above (≈19.6)、log_sqft_lot / lot15 (≈6.9)
Backward Elimination	OLS 逐步移除 p > 0.05	移除 long（p = 0.81）
RFECV	遞迴特徵消除 + 5-fold CV	最佳 16 個；12 個以後 CV R^2 幾乎不再增加
LassoCV	L1 正則化（α = 0.00037）	long 係數被壓到接近 0（−0.0002）
Forward Stepwise（佐證）	每步加入讓 AIC 最低的特徵	前 4 名 grade → lat → log_sqft_living → house_age；第 12 個之後 Adj R^2 只再增加 0.002
Best subset（Score selection，佐證）	暴力搜尋：$2^{17} - 1$ = 131,071 組特徵全部用 OLS 擬合，選 BIC 最低	BIC 最佳為 16 個（只刪 long）；用 Gram 矩陣求解，131,071 次擬合約 3 秒

決策規則：三種方法（Backward、RFECV、Lasso）中至少 2 票保留 → 再以 VIF ≤ 5 迭代修剪：每次取 VIF 最高的特徵與其最相關的夥伴，刪掉與目標相關較弱者。Forward Stepwise 與 Best subset 不參與投票，只用來檢查「留多少個特徵才划算」。

> **最終 12 個特徵**：bedrooms, log_sqft_living, log_sqft_lot, floors, waterfront, view, condition, grade, has_basement, house_age, is_renovated, lat
> **刪除**：long（不顯著）、log_sqft_above（與 living 共線）、bathrooms、log_sqft_living15（與 living 高度相關）、log_sqft_lot15（與 lot 共線）

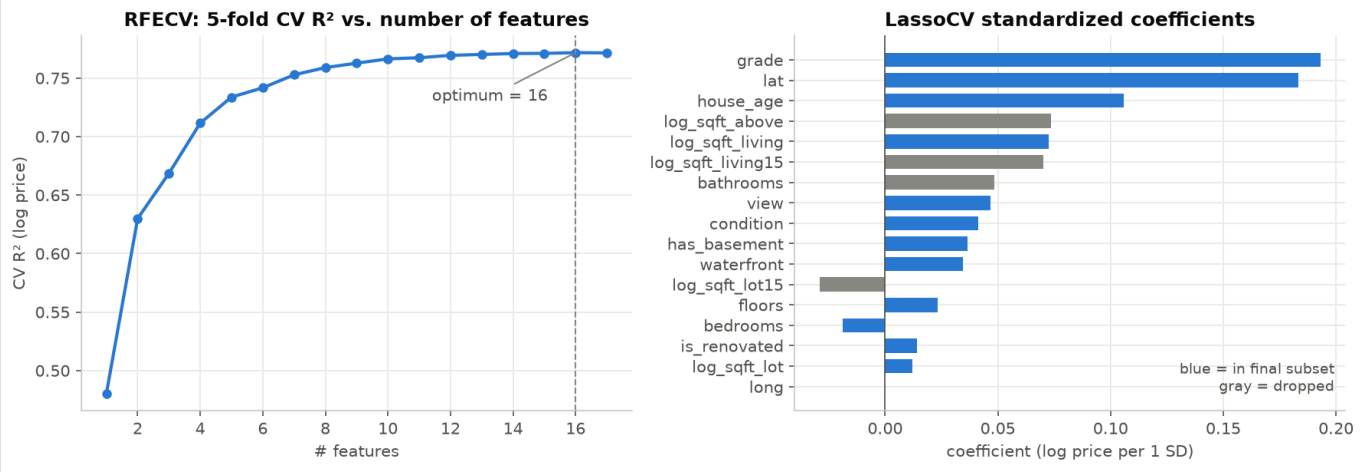


圖 4　左：RFECV 特徵數 vs CV R²；右：Lasso 標準化係數（藍 = 最終保留）

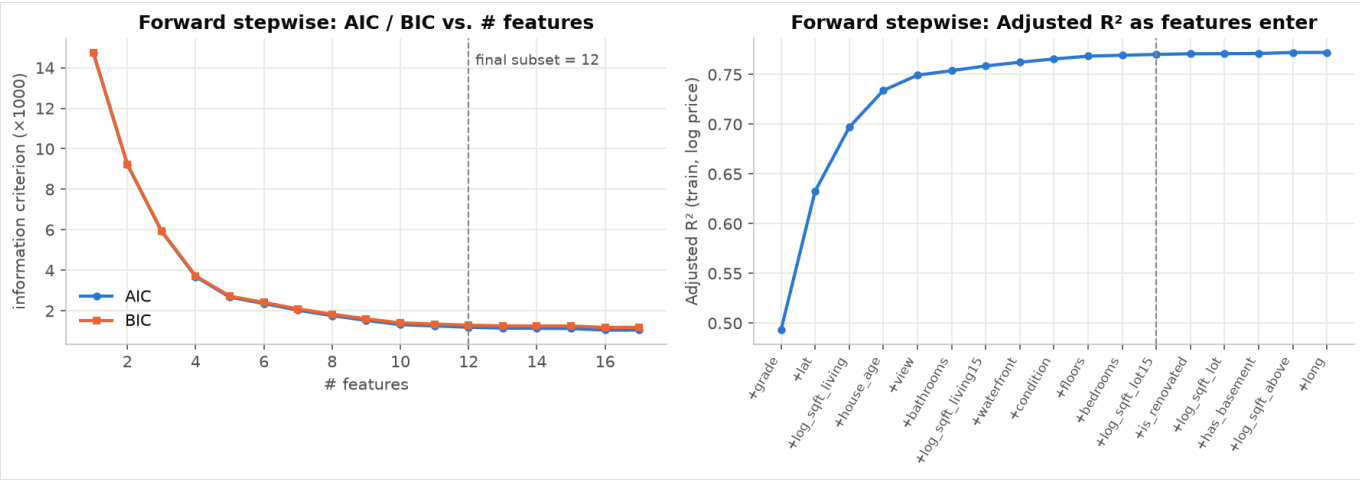


圖 5　Forward Stepwise：左為 AIC/BIC，右為 Adjusted R² 隨特徵加入的變化。12 個特徵之後曲線已經平了

和 Forward Stepwise 的比較：Forward Stepwise 挑出的前 12 個特徵裡有 9 個和我們的子集相同；差別在它選了 bathrooms、log_sqft_living15、log_sqft_lot15，這三個都和已選的面積欄位高度相關。它的 12 特徵模型訓練集 Adj R² 是 0.770，我們的 M3 是 0.761，只差 0.009，但 M3 的最大 VIF 只有 4.4，係數比較穩定、也比較好解讀。我們選擇犧牲一點點擬合度，換取可解釋性。

4.2 各特徵選擇方法在測試集上的比較

參考課程「50 Startup」範例報告的格式，把每一種方法選出的特徵**分別**訓練線性回歸，用同一份測試集比較 MSE 與 R²：

方法	刪除的特徵	特徵數	MSE (log)	RMSE (USD)	R^2 (log)	最大 VIF
All-in（不做選擇）	-	17	0.0630	187,262	0.775	19.6
Backward Elimination（p < 0.05）	long	16	0.0630	187,284	0.775	19.6
Forward Selection（BIC 最佳）	long	16	0.0630	187,284	0.775	19.6
RFECV	long	16	0.0630	187,284	0.775	19.6
LassoCV（|係數| > 0.01）	long	16	0.0630	187,284	0.775	19.6
Best subset（暴力搜尋，BIC 最佳）	long	16	0.0630	187,284	0.775	19.6
投票 + VIF ≤ 5（本作業 M3）	**bathrooms, log_sqft_above, long, log_sqft_living15, log_sqft_lot15**	**12**	**0.0668**	**195,199**	**0.761**	**4.4**

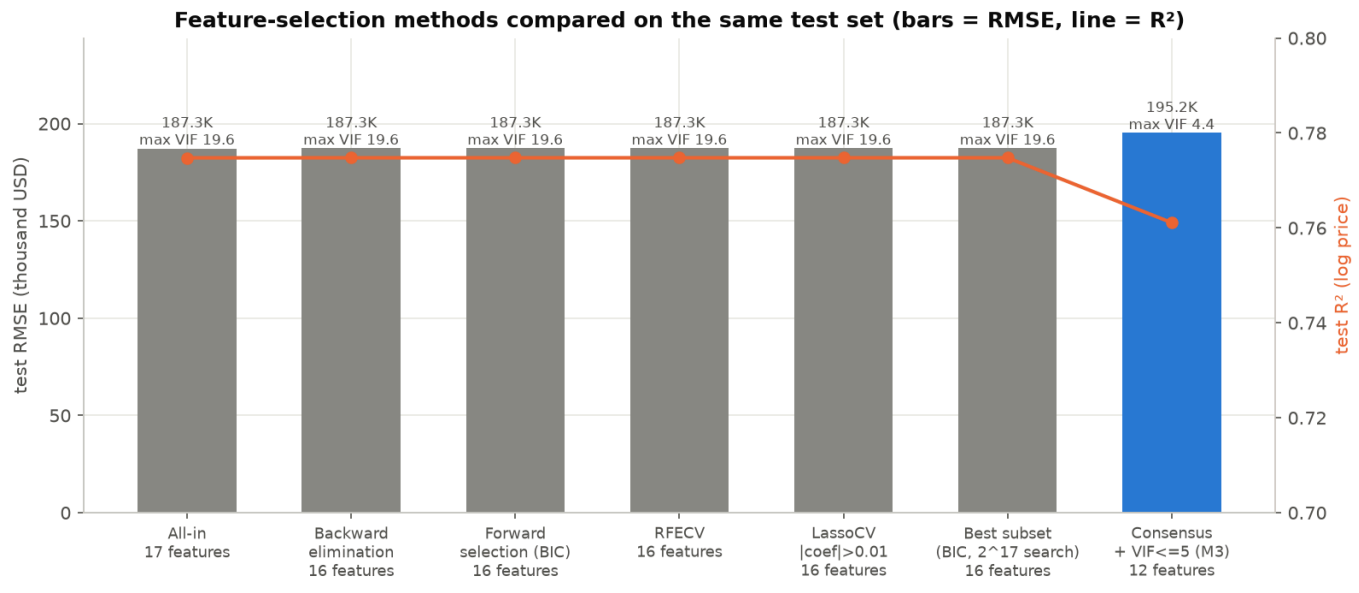


圖 6　各特徵選擇方法在測試集上的 RMSE（長條）與 R^2（折線），上方標註最大 VIF

解讀：五種「純資料導向」的方法（Backward、Forward、RFECV、Lasso、暴力搜尋）全部收斂到**同一組 16 個特徵**（只刪掉 long），測試 R^2 0.775；但它們都同時保留 log_sqft_living 與 log_sqft_above 這類共線組合，最大 VIF 高達 19.6，係數無法單獨解讀。M3 多加了 VIF ≤ 5 的限制，只用 12 個特徵，R^2 少 0.014（RMSE 多約 $7.9K），換來每個係數都穩定、可解讀。準確度的缺口則靠加入 zipcode（M4，R^2 +0.117）補回來，效果遠大於這 0.014。

下表依 L6 Part 2 的格式，列出 Forward Selection 依序加入 1 到 17 個特徵時的訓練 / 測試結果：

特徵數	加入的特徵	Train R^2	Test R^2	Test RMSE (USD)
1	+ grade	0.4930	0.4972	276,099
2	+ lat	0.6327	0.6313	261,097
3	+ log_sqft_living	0.6970	0.6980	242,637
4	+ house_age	0.7341	0.7314	219,473
5	+ view	0.7494	0.7497	202,827
6	+ bathrooms (不在 M3)	0.7539	0.7542	195,379
7	+ log_sqft_living15 (不在 M3)	0.7587	0.7612	194,863
8	+ waterfront	0.7624	0.7657	188,809
9	+ condition	0.7657	0.7689	187,501
10	+ floors	0.7686	0.7706	189,245
11	+ bedrooms	0.7695	0.7723	188,634
12	+ log_sqft_lot15 (不在 M3)	0.7704	0.7739	188,007
13	+ is_renovated	0.7710	0.7740	187,911
14	+ log_sqft_lot	0.7711	0.7742	188,113
15	+ has_basement	0.7713	0.7742	188,326
16	+ log_sqft_above (不在 M3)	0.7724	0.7748	187,284
17	+ long (不在 M3)	0.7724	0.7748	187,262

前 5 個特徵（grade、lat、面積、屋齡、景觀）測試 R^2 就到 0.750；第 12 個之後測試 R^2 只再增加 0.001，RMSE 幾乎不變。訓練與測試 R^2 在每一步都幾乎相同，代表沒有 overfit（見 5.2 節）。

4.3 作業頁建議的五種方法 × 不同特徵數

作業頁建議比較 **SelectKBest、RFE、Sequential Feature Selection、Lasso、permutation importance**，並選出不同數量的特徵，**只使用訓練資料**。本資料集處理後有 17 個候選特徵，所以比較 k = 5, 8, 12, 14 個。每格上方是測試集 R^2（log），下方是該子集的最大 VIF：

方法（做法）	k = 5	k = 8	k = 12	k = 14
SelectKBest 單變量 F 檢定（f_regression），挑和目標相關最強的 k 個	0.562 VIF 5.6	0.732 VIF 6.8	0.738 VIF 19.4	0.742 VIF 19.4
RFE 線性回歸反覆刪掉係數最小的特徵，直到剩 k 個	0.735 VIF 2.5	0.761 VIF 4.4	0.771 VIF 19.3	0.774 VIF 19.6
Sequential FS sklearn SequentialFeatureSelector，每步加入讓 5-fold CV R^2 最高的特徵	0.750 VIF 2.6	0.766 VIF 4.1	0.774 VIF 5.2	0.774 VIF 6.7
Lasso LassoCV 標準化係數絕對值最大的 k 個	0.731 VIF 4.7	0.761 VIF 6.2	0.773 VIF 17.8	0.774 VIF 19.6
Permutation importance 在訓練集內再切 25% 驗證，打亂某特徵後 R^2 下降越多越重要	0.718 VIF 2.8	0.761 VIF 6.2	0.773 VIF 17.8	0.774 VIF 19.6
本作業 M3（三法投票 + VIF ≤ 5）			**0.761** **VIF 4.4**	

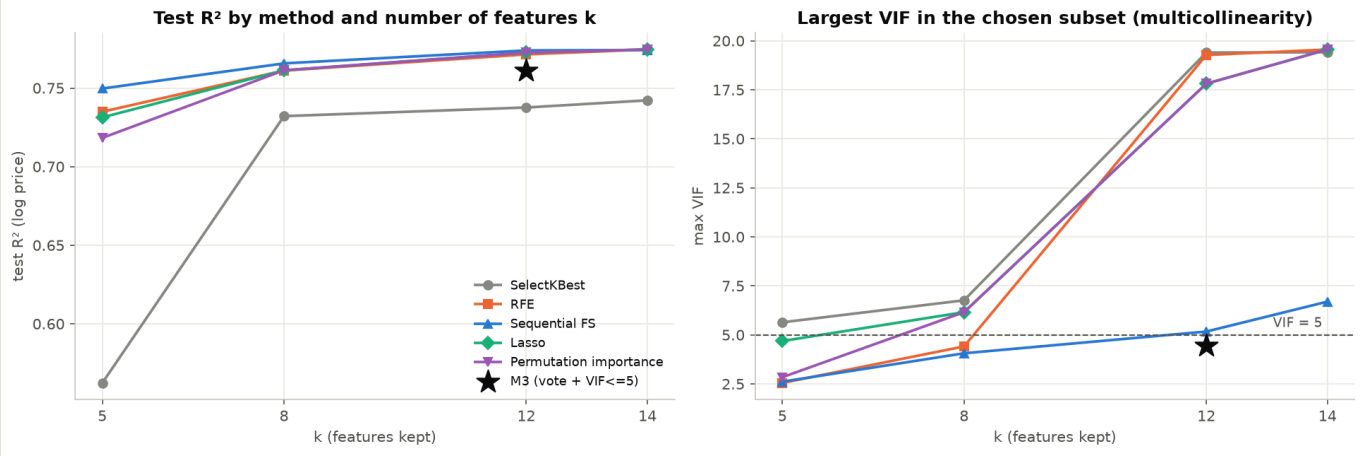


圖 7　五種方法在不同 k 的測試 R^2（左）與最大 VIF（右）；黑色星號為本作業的 M3

- **SelectKBest 最差**：k = 12 時 R^2 只有 0.738。它逐一看每個特徵和價格的相關，會一次挑進好幾個彼此高度相關的面積欄位，卻漏掉「控制面積後才顯現」的屋齡（house_age）。
- **其他四種方法到 k = 8 就有 R^2 0.76 左右**，k ≥ 12 後幾乎不再進步（0.77），和 4.2 節「12 個之後曲線變平」一致。
- **共線性是關鍵差別**：RFE、Lasso、permutation importance、SelectKBest 在 k = 12 時最大 VIF 都在 17.8–19.4 之間（同時保留 log_sqft_living 與 log_sqft_above）。只有 Sequential FS 在 k = 12 時 R^2 0.774、最大 VIF 5.2，最接近 VIF ≤ 5 的門檻；它選出的 12 個特徵和 4.2 節 Forward Stepwise 的前 12 名完全相同。
- **為什麼仍選 M3**：Sequential FS 的子集 R^2 高 0.013，但用了 log_sqft_living15、log_sqft_lot15 這兩個「鄰居平均面積」，和房屋本身的面積相關，VIF 也略超過 5。M3 嚴格守住 VIF ≤ 5，係數都可單獨解讀；需要更高準確度時，改由加入 zipcode 的 M4 達成（R^2 0.878）。

4.4 模型

- **M1 單純線性回歸**：log(price) ~ log(sqft_living)，作為基準。
- **M2 多元線性回歸（全部 17 特徵）**：檢查特徵選擇是否損失太多。
- **M3 多元線性回歸（12 特徵）**：主要的可解釋模型，所有變數 $p < 0.05$、VIF ≤ 5。
- **M4 = M3 + zipcode one-hot**：加入地段固定效果，仍是線性回歸。
- **正則化**：Ridge（RidgeCV 自動選 α）、Lasso（LassoCV 自動選 α）與 Elastic Net（用 **Optuna** 調參，4.6 節），設計與 M4 相同。
- **M5 多項式回歸**：M3 的 12 個特徵加上二次項與兩兩交互作用，再加 zipcode（4.7 節）。
- **對照**：Random Forest、HistGradientBoosting（Kaggle 上常見的樹模型解法）。

4.5 M3 係數解讀（log-linear）

特徵	係數	解讀
log_sqft_living	0.460	室內面積 +10% → 房價約 +4.5%（彈性）
grade	0.191	建築等級每 +1 級 → 房價約 +21%
waterfront	0.397	臨水 → 房價約 +49%
lat	1.337	緯度 +0.1°（往北、接近西雅圖市區）→ 約 +14%
view	0.071	景觀評分每 +1 → 約 +7%
floors	0.069	每多一層樓 → 約 +7%
condition	0.060	屋況每 +1 → 約 +6%
is_renovated	0.074	曾翻修 → 約 +8%
house_age	0.0032	控制品質後，老屋略貴（多位於成熟市區）
bedrooms	−0.018	面積固定下房間越多 → 每間越小，價格略降

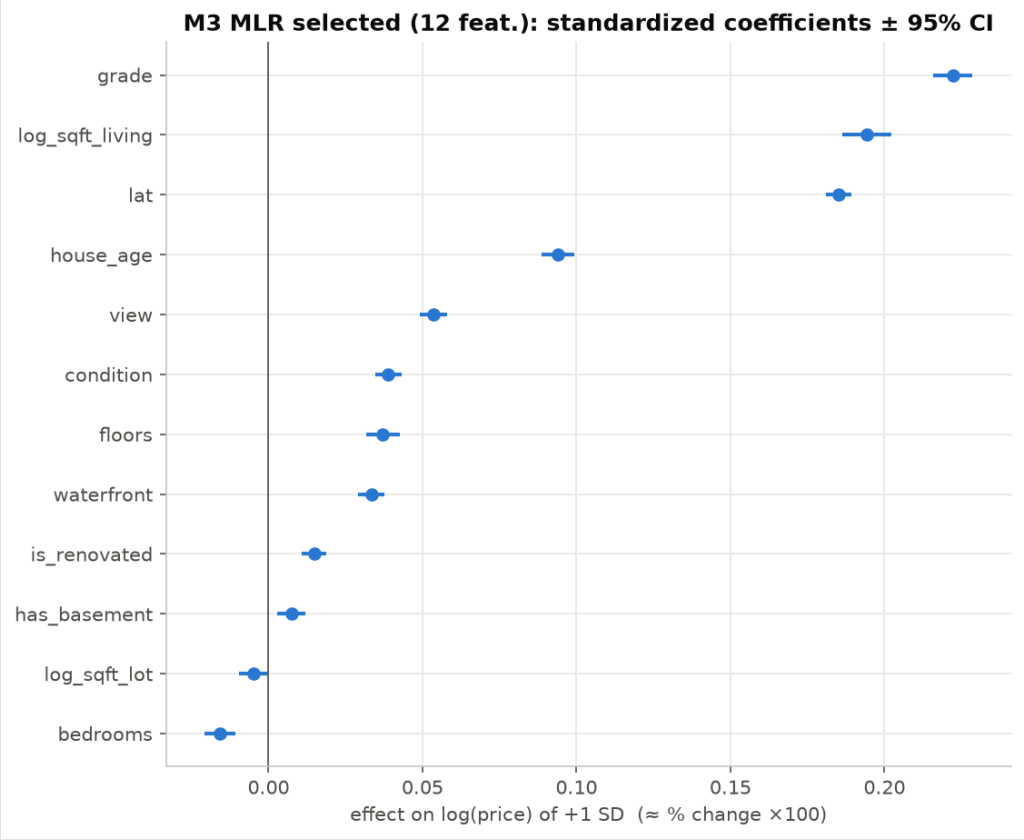


圖 8　M3 標準化係數與 95% 信賴區間（所有區間皆不跨 0）

4.6 用 Optuna 優化模型（Elastic Net）

課程 L6 Step 4 要求用 Optuna 優化模型。線性回歸本身沒有超參數，所以對 M4 的設計改用 **Elastic Net**（同時含 L1 與 L2 懲罰），讓 Optuna 的 TPE 演算法在 40 次試驗中搜尋兩個參數，目標是 5-fold CV R^2 最大：

- `alpha`（正則化強度）：10^{-5} – 10^{-1}，對數尺度
- `l1_ratio`：0（純 Ridge）– 1（純 Lasso）

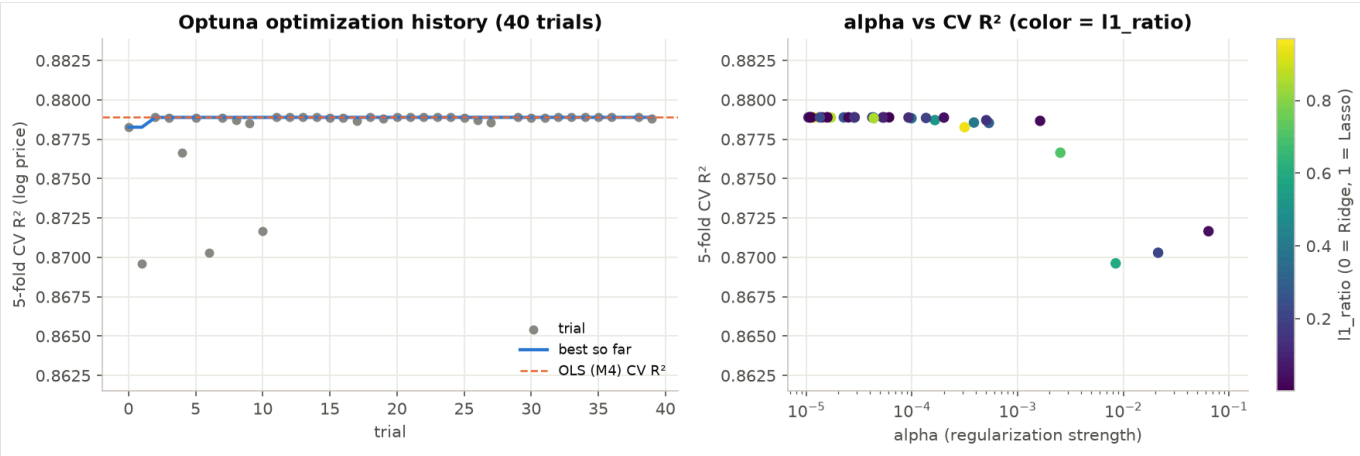


圖 9　Optuna 搜尋過程：左為 40 次試驗的 CV R^2（藍線 = 目前最佳，橘色虛線 = OLS），右為 alpha 與 CV R^2 的關係

結果：最佳參數為 alpha = 1.1×10^{-5}、l1_ratio ≈ 0，CV R^2 0.8789，和不加懲罰的 OLS（0.8789）完全相同；alpha 越大 R^2 越低。也就是說，**Optuna 確認 M4 不需要正則化**：資料有 17,135 筆、特徵已經過 VIF 篩選，OLS 本身就沒有 overfit。（技術細節：Elastic Net 預先計算 Gram 矩陣後，每次訓練從約 18.7 秒降到 0.04 秒，整個主程式 1–2 分鐘跑完。）

4.7 多項式回歸（M5）

課程 L5 列出的線性回歸形式還包含**多項式回歸**。M5 把 M3 的 12 個特徵（先減去平均值）展開成二次項：12 個一次項 + 9 個平方項 + 66 個兩兩交互項（3 個 0/1 變數的平方等於自己，已去除），共 87 項，再加 69 個 zipcode 虛擬變數。模型對「參數」仍是線性的，所以仍屬於線性回歸，用 OLS 求解。

結果：測試 R^2 0.887、CV R^2 0.889、RMSE $134,921、MAPE 13.1%。比 M4 再進步（R^2 +0.009、RMSE −$7.6K），而且**美元尺度的 RMSE 比 HistGradientBoosting（$137,215）還低**。代價是 156 個係數難以逐一解讀，所以部署仍選 M4，M5 用來證明「線性模型加上交互作用後，可以追上樹模型」。

4.8 補充：Auto Regression 試驗

作業允許嘗試 Auto Regression，所以我們也做了測試。不過 AR 是時間序列模型，用變數自己過去的值預測未來；本資料是「每間房子一筆」的橫斷面資料，AR 沒辦法預測個別房屋，只能預測整體市場的價格走勢。做法：把成交價彙總成**每週中位數**（55 週），用前 47 週訓練、AIC 選出落後階數 p = 3，預測最後 8 週。

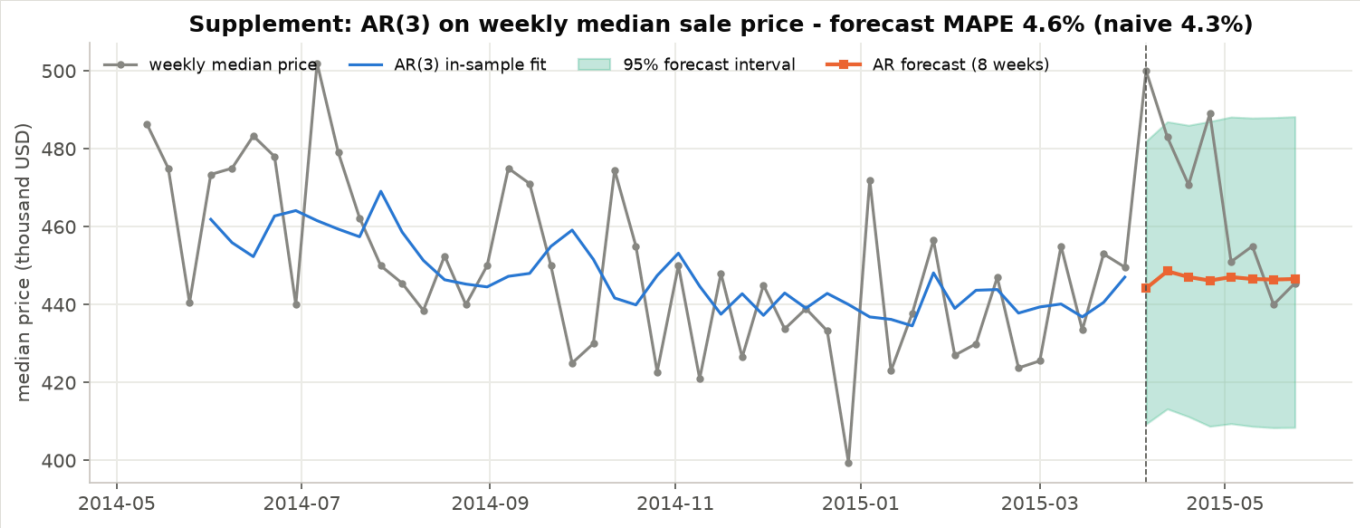


圖 10　AR(3) 預測每週中位房價：MAPE 4.6%，比「直接沿用上週值」的 naive 預測（4.3%）還差；95% 預測區間只涵蓋 8 週中的 6 週（75%）

結論：每週中位數的波動主要是雜訊，加上 2015 年 4 月的春季旺季跳升，這種季節性只有 55 週的資料學不出來，所以 AR 贏不了 naive 預測。房價主要由房屋本身的條件決定，因此主模型採用多元線性回歸，AR 只作為補充。

5. Evaluation（評估）

5.1 評估指標

指標	意義	解讀
MSE	平均平方誤差 = mean((y − ŷ)²)	越小越好；誤差平方，對大誤差特別敏感
RMSE	√MSE，和目標同單位（美元）	越小越好；「典型」預測誤差的大小
MAE	平均絕對誤差 = mean(|y − ŷ|)	越小越好；不受少數極端值影響
MAPE	平均絕對百分比誤差	越小越好；不同價位的房子可以公平比較
R^2 / Adj R^2	模型解釋的變異比例；Adj R^2 會扣除特徵數的影響	越接近 1 越好；Adj R^2 避免「特徵越多 R^2 越高」的假象
5-fold CV R^2	訓練集切 5 份輪流驗證的平均 R^2	和測試 R^2 接近 → 結果穩定、沒有 overfit

模型以 log(price) 訓練，所以 R^2 與 MSE 同時報告 log 尺度，RMSE、MAE、MAPE 則還原成美元。

模型	R^2(log)	Adj R^2	CV R^2 (mean±sd)	MSE(log)	R^2(USD)	RMSE	MAE	MAPE
M1 Simple LR	0.453	0.453	0.455±0.008	0.1530	0.420	296,181	173,926	33.1%
M2 MLR all (17)	0.775	0.774	0.772±0.006	0.0630	0.768	187,262	110,553	19.8%
M3 MLR selected (12)	**0.761**	**0.760**	**0.761±0.006**	**0.0668**	**0.748**	**195,199**	**113,288**	**20.3%**
M4 MLR + zipcode	**0.878**	**0.876**	**0.879±0.003**	**0.0341**	**0.866**	**142,491**	**76,678**	**13.7%**
Ridge (M4 design)	0.878	–	0.879±0.003	0.0341	0.866	142,496	76,681	13.7%
Lasso (M4 design)	0.877	–	0.878±0.003	0.0343	0.865	143,021	77,072	13.8%
Elastic Net（Optuna）	0.878	–	0.879±0.003	0.0341	0.866	142,493	76,679	13.7%
M5 多項式 + zipcode	0.887	0.882	0.889±0.003	0.0317	0.880	134,921	73,295	13.1%
Random Forest	0.892	–	0.889±0.004	0.0301	0.861	144,842	70,493	12.3%
HistGradientBoosting	0.905	–	0.903±0.002	0.0265	0.876	137,215	64,868	11.6%

- **特徵選擇有效**：M3 用 12 個特徵（少 5 個），R^2 只比 M2 低 0.014，但所有係數顯著、無共線性，可解釋性大幅提高。
- **地段是最大缺口**：加入 zipcode 後 R^2 從 0.761 升到 0.878、MAPE 從 20.3% 降到 13.7%，「Location, location, location」（圖 17 的殘差地圖可以直接看到）。
- **穩定性**：CV R^2 的標準差 ≤ 0.008，且 CV 與測試集結果一致，沒有過擬合。Ridge、Lasso（R^2 0.877，81 個係數中有 79 個非零）、Optuna 調出的 Elastic Net 與 OLS 幾乎相同，也表示共線性已處理好、不需要正則化。
- **多項式回歸再進一步**：M5 的 R^2 0.887，美元尺度的 RMSE（$134,921）與 R^2(USD)（0.880）是所有模型中最好的，連樹模型都贏；log 尺度的 R^2 與 MAPE 則仍是 HistGradientBoosting 最好。
- **美元尺度上 M4 的 RMSE 比 Random Forest 還低**（142,491 vs 144,842），只輸給 M5 和 HistGradientBoosting。

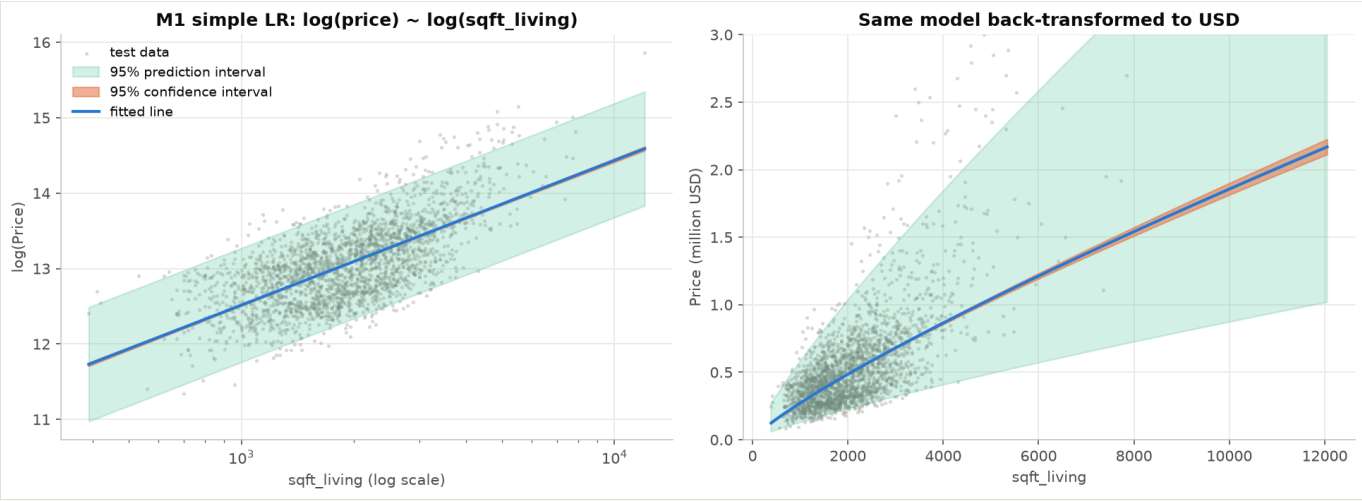


圖 11　M1 單純線性回歸：擬合線、95% 信賴區間（橘，平均價格的不確定性）與 95% 預測區間（綠，單一房屋的不確定性）

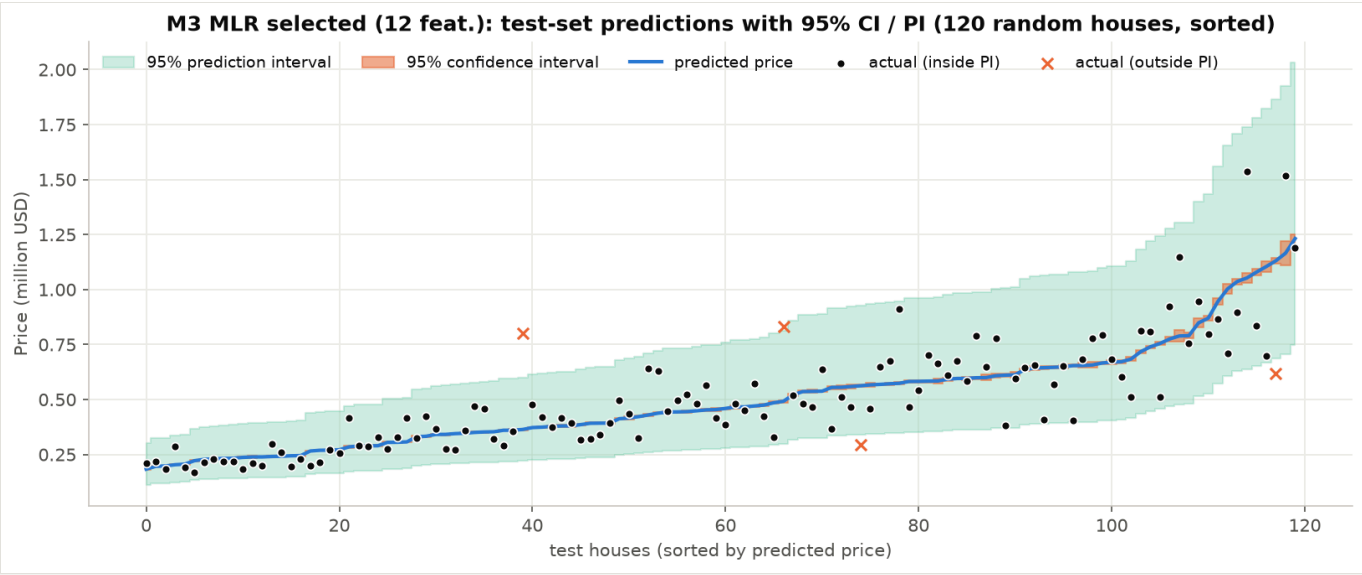


圖 12　M3 預測圖：隨機 120 間測試房屋，依預測值排序；× 為落在 95% PI 外的房屋

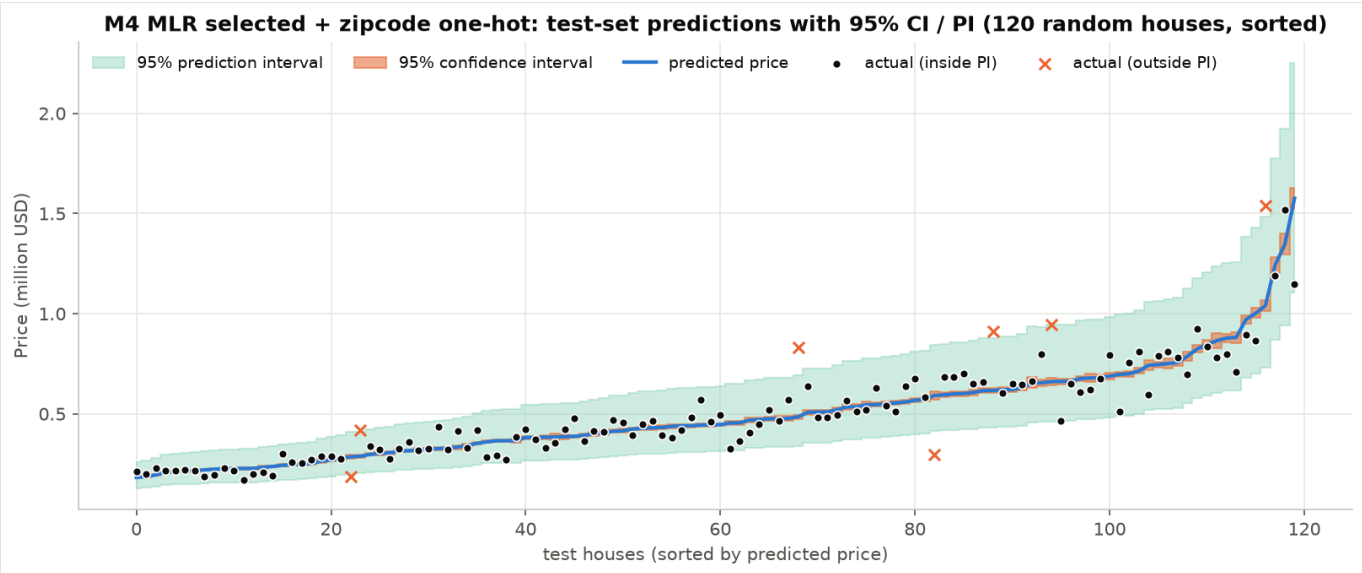


圖 13　M4（加 zipcode）預測圖：預測區間明顯變窄（中位寬度 $474K → $330K）

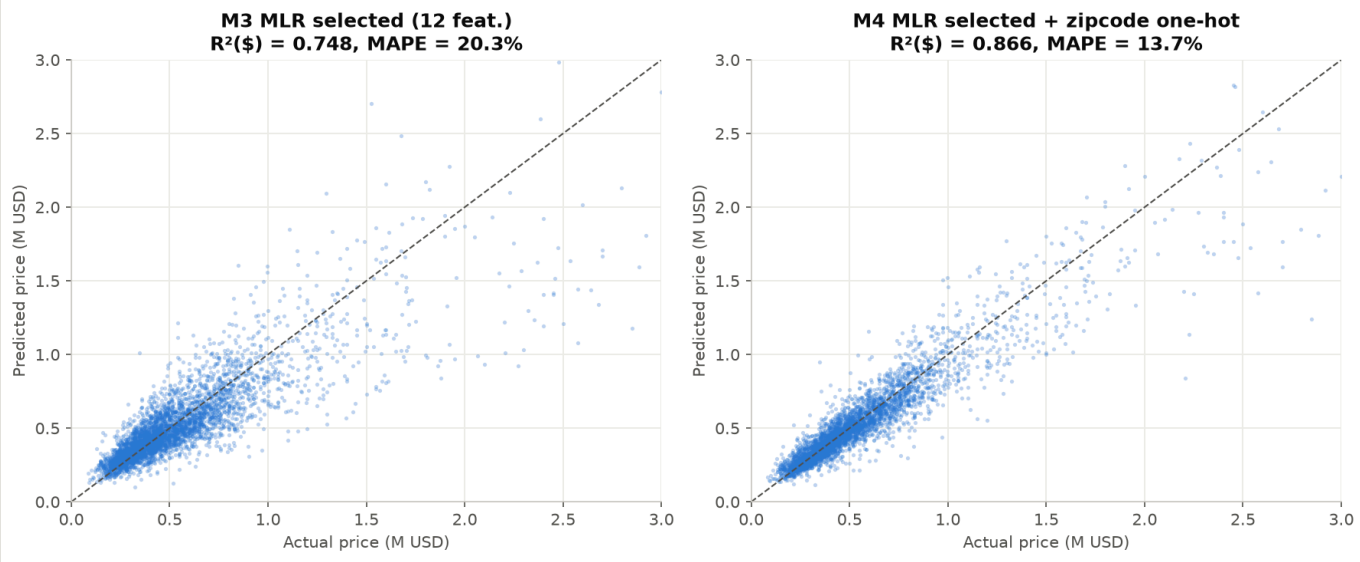


圖 14　實際 vs 預測（虛線為完美預測）

5.2 Overfit / Underfit 判斷（training 與 test 曲線）

依課程 L6 Step 4，畫出訓練與測試（驗證）的誤差曲線判斷模型是否 overfit 或 underfit：

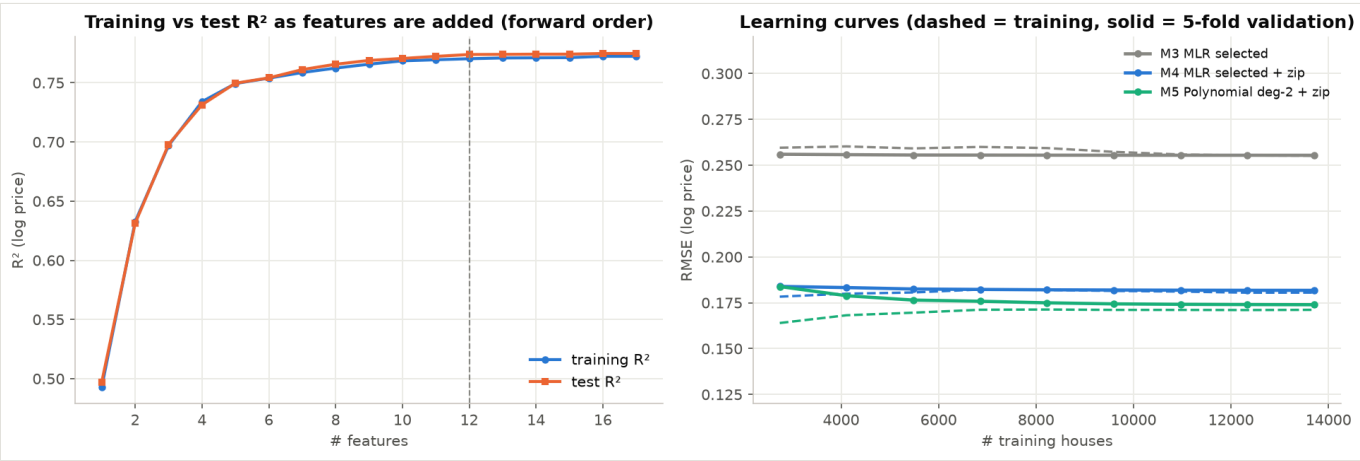


圖 15　左：依 Forward 順序加入特徵時的 training / test R²；右：學習曲線（虛線 = 訓練誤差，實線 = 5-fold 驗證誤差）

- **Underfit**：只用 1–4 個特徵時 R² 只有 0.50–0.73，訓練與測試都差，是典型的 underfit；加到 5 個以上才進入平穩區。
- **沒有 overfit**：每一步的 training R² 與 test R² 幾乎重疊（差距 < 0.004）。學習曲線上，M3、M4 的訓練誤差與驗證誤差從 2,741 筆起差距就在 0.006 以內，用全部資料時 M4 為 0.181 vs 0.182。
- **M5 較複雜**：只用 2,741 筆訓練時，訓練誤差（0.164）明顯低於驗證誤差（0.184），有輕微 overfit；資料增加到 13,708 筆後差距縮小到 0.171 vs 0.174。代表 156 個參數的模型需要足夠的資料，本資料集剛好夠用。

5.3 多元回歸五大假設檢查（M3，訓練集）

課程 L6 列出多元線性回歸的五個前提假設，逐一用統計檢定或圖形檢查：

假設	檢查方法	結果	判讀
1. Linearity（線性）	殘差 vs 預測值圖（圖 16 左）	殘差沿 0 上下分布，沒有明顯的彎曲趨勢	**通過**；面積取 log 後與 log(price) 呈線性
2. Homoscedasticity（變異數同質）	Breusch-Pagan	LM = 605，p < 0.001	**有異質變異** → 改用 HC3 穩健標準誤重新檢定：12 個係數中 11 個仍 p < 0.05（只有 log_sqft_lot 變成 p = 0.078），結論不受影響
3. Multivariate normality（殘差常態）	Jarque-Bera、Q-Q 圖（圖 16 右）	JB = 796，p < 0.001；偏態 0.15、峰度 4.0	**尾部略厚**；樣本 17,135 筆，依中央極限定理係數推論仍可靠
4. Independence of errors（誤差獨立）	Durbin-Watson	1.99	**通過**（接近 2 = 無自相關）
5. Lack of multicollinearity（無共線性）	VIF / 標準化條件數	最大 VIF 4.44；條件數 4.4	**通過**（VIF < 5、條件數 < 30）；這正是 M3 用 VIF ≤ 5 修剪特徵的原因

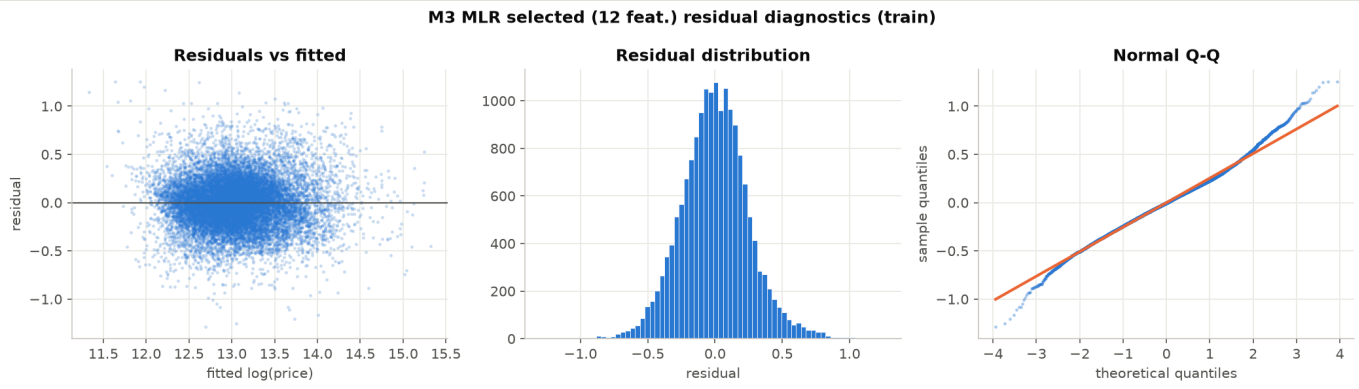


圖 16　M3 殘差診斷：殘差無明顯趨勢、近似常態（尾部略厚，峰度 4.0）

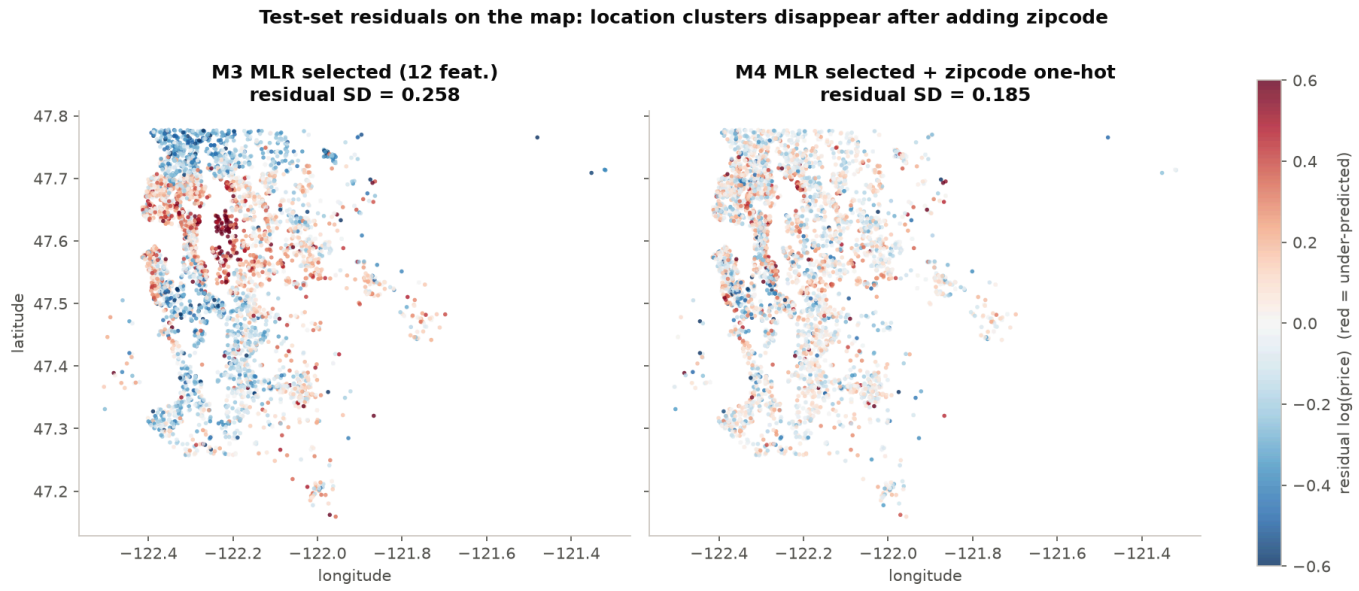


圖 17　測試集殘差地圖：M3（左）在西雅圖市區與 Bellevue、Mercer Island 一帶系統性低估（紅色群聚），在北邊 Shoreline 與南邊郊區高估（藍色群聚）；加入 zipcode 後（右）群聚消失，殘差標準差從 0.258 降到 0.185

5.4 預測區間校準

只看 95% 一個點不夠，所以再檢查 50%、68%、80%、90%、95%、99% 六種信賴水準下，測試集實際落在預測區間內的比例：

名目水準	50%	68%	80%	90%	95%	99%
M3 實際覆蓋率	52.6%	71.1%	81.7%	90.2%	94.4%	98.1%
M4 實際覆蓋率	57.4%	73.5%	83.4%	90.5%	94.0%	97.6%

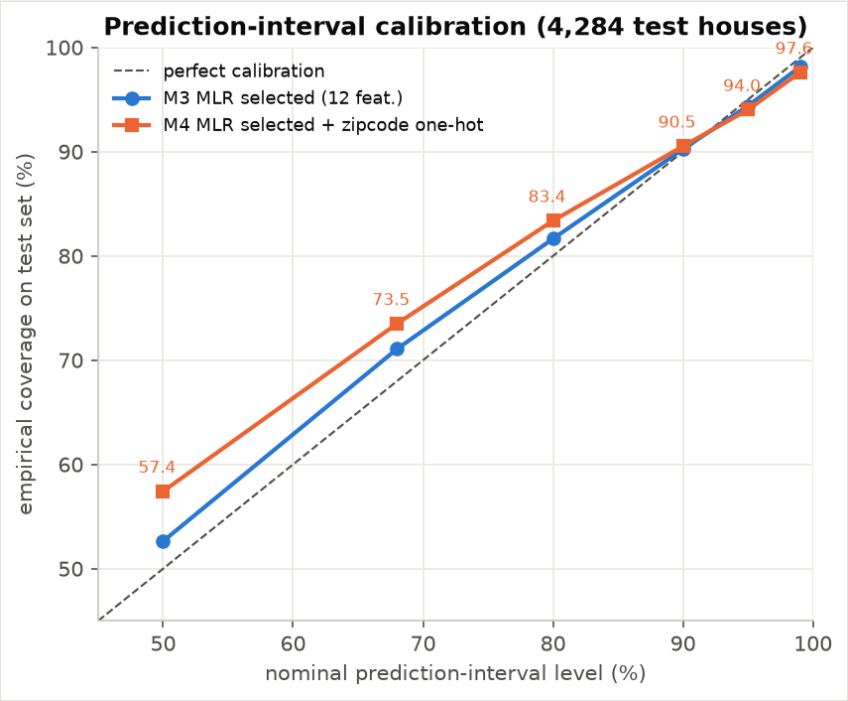


圖 18　預測區間校準圖：越接近虛線越準。90–95% 幾乎完全吻合；低水準時略為保守、99% 略不足，這和殘差「中間尖、尾部厚」（峰度 4.0）一致

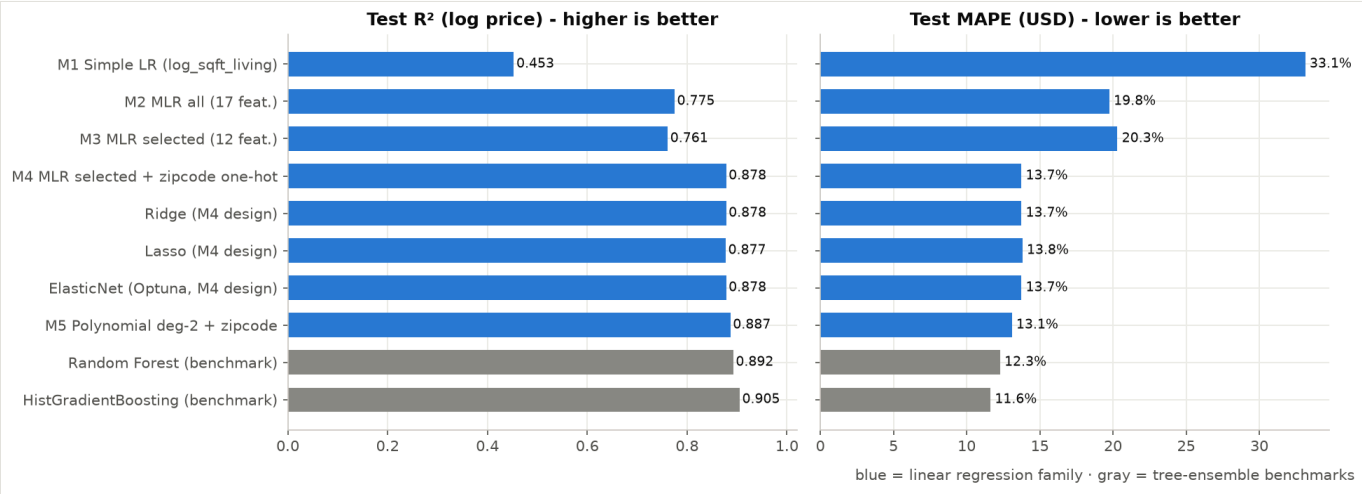


圖 19　模型比較（藍 = 線性回歸家族，灰 = 樹模型對照）

5.5 成功標準檢核（回到 Business Understanding）

成功標準	M3（12 特徵）	M4（+ zipcode）
測試集 $R^2 \geq 0.75$	✓ 0.761	✓ 0.878
MAPE ≤ 20%	✗ 20.3%（差 0.3 個百分點）	✓ 13.7%
95% PI 覆蓋率在 93–97%	✓ 94.4%	✓ 94.0%
CV 與測試一致（不過擬合）	✓ 0.761 vs 0.761	✓ 0.879 vs 0.878
係數方向符合常識	✓ 面積、等級、臨水、景觀皆為正	✓

結論：**M4 達成全部成功標準，作為部署模型**；M3 用來解釋「哪些因素影響房價」。

6. Deployment（部署）

- 執行主程式後，M4 模型（含特徵清單與 zipcode 類別）用 **pickle + gzip**（課程 L6 Step 5）存成 `model/house_price_mlr.pkl.gz`。先用 `remove_data()` 去掉 statsmodels 存的訓練資料（34 MB → 58 KB，含解釋預測用的訓練集平均值），再用 gzip 壓縮成 40 KB。
- `predict.py` 提供 `predict_price()` 函式與命令列介面，輸入房屋條件即輸出預測價與 95% CI / PI：

```
$ python predict.py --sqft_living 2000 --grade 8 --zipcode 98052 --lat 47.68
Predicted price : $553,994
95% CI (mean)   : $544,004 - $564,168
95% PI (house)  : $388,300 - $790,393
```

- 解讀：同條件房屋的**平均**價格約 $544K–$564K（CI，窄）；**單一一間**房子的成交價有 95% 機率落在 $388K–$790K（PI，寬，因為包含個別房屋的差異）。

6.1 預測新樣本

依作業頁建議，用部署程式預測三間不在資料集裡的新房子：

新房子	主要條件	預測價	95% 預測區間
A 一般住宅（Redmond）	2,000 sqft、grade 8、3 房、1990 年建、zipcode 98052	$553,994	$388,300 – $790,393
B 臨水豪宅（Mercer Island）	3,500 sqft、grade 10、臨水、景觀 4、zipcode 98040	$2,615,671	$1,830,105 – $3,738,438
C 小型老屋（南區）	1,100 sqft、grade 6、2 房、1955 年建、zipcode 98168	$193,660	$135,683 – $276,412

6.2 解釋模型的預測（`predict.py --explain`）

因為模型是 log(price) 的線性回歸，預測價可以**精確拆解**成「一般房子的價格 × 每個特徵造成的百分比變化」。一般房子指所有特徵都在訓練集平均值、zipcode 效果也取平均，價格為 $465,592。以臨水豪宅 B 為例：

```
$ python predict.py --sqft_living 3500 --sqft_lot 15000 --grade 10 --waterfront 1 --view 4 \
      --condition 4 --floors 2.0 --sqft_basement 1000 --yr_built 1985 --zipcode 98040 --lat 47.56 --bedrooms 4 --explain
Why? Typical King County house (all features at the training average): $465,592
  waterfront           +62.4%   -> $756,049
  zipcode 98040        +49.9%   -> $1,133,128
  log_sqft_living      +33.9%   -> $1,517,097
  grade                +30.3%   -> $1,976,300
  view                 +27.8%   -> $2,525,050
  ...（其餘 8 個特徵各自影響都在 ±5% 以內）
  = predicted price $2,615,671
```

這間房子比一般房子貴 5.6 倍，主要來自臨水（+62%）、Mercer Island 的地段（+50%）、面積（+34%）、建築等級（+30%）與景觀（+28%），其餘特徵影響都很小。這種逐項拆解是線性回歸相對於樹模型最大的優勢：估價結果可以向買賣雙方說明「貴在哪裡」。

6.3 部署成網站（Streamlit）

網址：https://hw2-mlr-yenkai.streamlit.app/（程式 `app.py`、`generic_mlr.py`，部署在 Streamlit Community Cloud）。左側**下拉選單可以切換三種 problem**：

Problem	內容
① King County 房價（主模型）	輸入房屋條件（選 zipcode 自動帶入緯度），即時顯示預測價、95% 預測區間與信賴區間，並用長條圖逐項解釋每個條件對價格的影響（同 6.2 節）。
② 50 Startups 利潤	課程範例資料集（老師提供的 CSV 網址），用同一套通用流程分析。
③ 自行輸入資料集	**任意輸入 Dataset**：貼上 CSV 網址或上傳檔案，選擇目標欄位與特徵後自動完成 CRISP-DM：資料理解（筆數、欄位、缺失值）→ 資料準備（中位數補值、one-hot 並避開 dummy trap、train/test split）→ 特徵選擇（SelectKBest、RFE、Sequential FS、Lasso、permutation importance，只用訓練資料，可調 k）→ 多元線性回歸（係數、p 值、95% CI）→ 評估（MAE、MSE、RMSE、R^2、Adjusted R^2、overfit 判斷、含 95% 預測區間的預測圖）→ 預測新樣本。



圖 20　網站 Problem ①：King County 房價估算

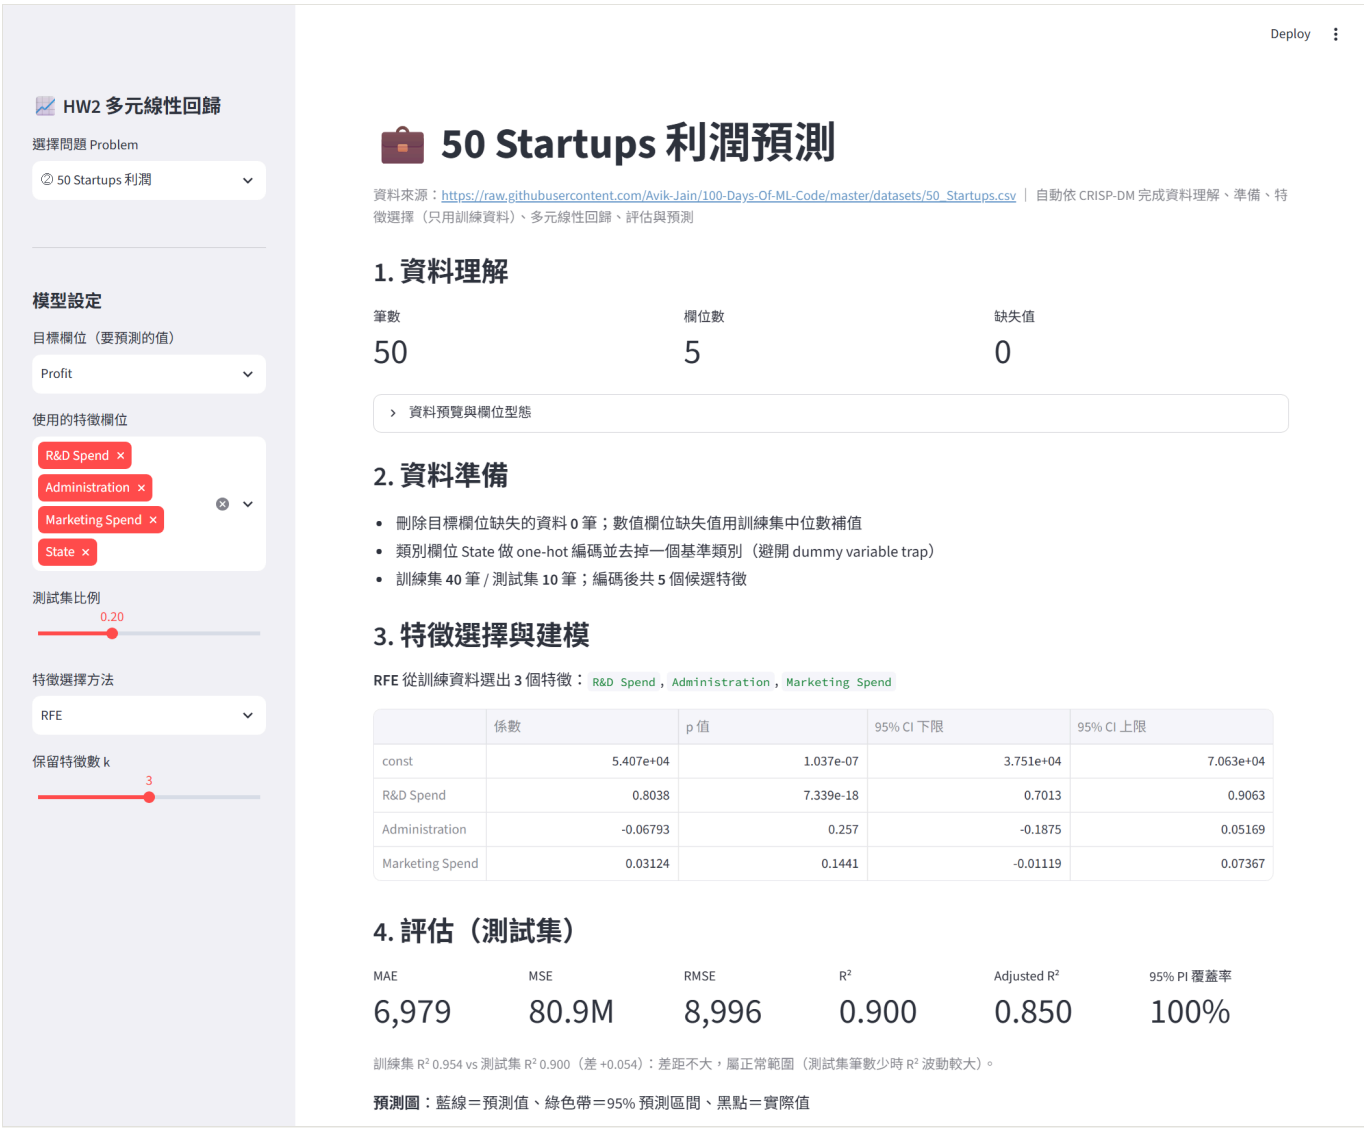


圖 21　網站 Problem ②：50 Startups 利潤預測（Problem ③ 使用同一套流程，可輸入任意 CSV）

- 程式在 macOS（python3）與 Windows（python）上都執行過，結果一致（加入 Optuna 的最新版本在 Windows 上驗證）。執行紀錄會自動寫入 `results/run_log.txt`。
- 後續可沿用 HW1 的 Streamlit 架構做成網頁表單；並應定期以新成交資料重訓（本資料只涵蓋 2014–2015，房價已大幅變動）。

7. 網路主流解法比較與說明

此資料集在 Kaggle 是 Dataset（不是 Competition），**沒有排行榜名次**，所以改和網路上公開的解法（Kaggle Notebook、GitHub、論文，見第 9 節 NotebookLM 的 7 個來源）回報的 R^2 對照：

常見做法	網路上回報的 R^2	本作業對應結果
單純線性回歸（price ~ sqft_living）	≈ 0.49	M1：0.453（log 尺度，已移除錯誤資料）
多元線性回歸（原始 price、未處理共線性）	≈ 0.65–0.70	M2：0.775、M3：0.761
多項式 + Ridge 正則化	≈ 0.70–0.75	**M5 多項式：0.887**；Ridge / Elastic Net（Optuna）：0.878
log 轉換 + zipcode 虛擬變數	—	**M4：0.878、MAPE 13.7%**
樹模型（Random Forest、XGBoost、LightGBM）	≈ 0.85–0.87	RF：0.892、HistGradientBoosting：0.905

面向	多元線性回歸（M4）	梯度提升樹（HGB）
準確度	R^2 0.878、MAPE 13.7%	R^2 0.905、MAPE 11.6%
可解釋性	每個係數都可以讀成「百分比影響」，有 p 值與信賴區間	黑盒，需要 SHAP 等工具輔助
預測區間	理論公式直接給出，實測覆蓋率 94%，校準良好	需要額外的 quantile regression 或 conformal prediction
非線性、交互作用	需要人工設計（log、zipcode one-hot）	自動學習

比較結論：樹模型準確度最高，但 M4 線性回歸只差約 2–3 個百分點（R^2 0.878 vs 0.905），而且已經超過網路上常見的樹模型成績（0.85–0.87）；加上交互作用的 M5（R^2 0.887）在美元 RMSE 上甚至比 HistGradientBoosting 還低。線性回歸能做到這個程度，關鍵是三件事：log 轉換、系統化的特徵選擇、zipcode 地段固定效果。若目標是解釋與估價範圍，線性回歸更合適；若只求點預測準確度，則選梯度提升樹。

8. AI 輔助內容（Claude Code 對話過程）

> 學號 7115064191 ｜ 工具：Claude Code（Anthropic，Claude Opus 5.5），桌面版 Code 分頁 ｜ 日期：2026-10-07 – 2026-10-21
> 說明：本作業使用的 AI 輔助工具是 **Claude Code**（Anthropic），以下為對話過程整理（工具執行的細節已省略）。完整對話紀錄另附 `7115064191_ai_conversation.pdf`。作業分六段完成：建立分析 → 依評分標準補強 → 對照課程講義 → 對照作業頁建議 → 做成網站 → 依老師更新的要求補上加分項目並部署。只收錄和作業內容有關的對話。

第一段：建立完整分析

> 學生
> （貼上 HW2 作業說明的兩張截圖）HW2 要延伸自我的 HW1。

> AI
> 整理 HW2 的要求：Kaggle 資料集要有 10–20 個特徵、CRISP-DM 六個步驟、特徵選擇、模型評估、含預測區間的預測圖。查看 HW1「HW1-CWA-Weather」（台灣六大區域天氣預報：CWA API + SQLite + Streamlit）後，因為 HW1 不是回歸題目，提出兩個方向：(1) 天氣資料集，主題比較連貫；(2) 經典資料集，例如房價。

> 學生
> 主題選房價預測。

> AI
> 建議用 Kaggle「House Sales in King County, USA」（21,613 筆、18 個特徵，目標 price）。因為沒有 Kaggle 金鑰，詢問下載方式和學號。

> 學生
> 從 GitHub 鏡像下載；學號 7115064191。

> AI
> 下載 `kc_house_data.csv`，寫好並執行主程式 `7115064191_hw2.py`：
>
> - **資料理解**：沒有缺失值、有 177 筆重複成交；價格右偏（偏態 4.02），取 log 後變成 0.43；sqft_basement = sqft_living − sqft_above，完全共線。
> - **資料準備**：清理後剩 21,419 筆；建立 log_price、house_age、is_renovated、has_basement，面積取 log；zipcode 改為 one-hot；訓練/測試切 80/20。
> - **特徵選擇**：用了相關係數、VIF、Backward Elimination、RFECV、LassoCV。
>
> 第一次執行時發現 VIF 修剪的邏輯把最重要的 log_sqft_living 刪掉了，AI 自己找出問題並修正為「每次取 VIF 最高的特徵和它最相關的夥伴，刪掉其中和目標相關性較弱的那個」。最後選出 12 個特徵。

AI

模型結果（測試集）：

模型	R^2(log)	MAPE
M1 單純線性回歸	0.453	33.1%
M2 MLR 全部 17 個特徵	0.775	19.8%
M3 MLR 選出的 12 個特徵	0.761	20.3%
M4 M3 + zipcode	0.878	13.7%
HistGradientBoosting（對照）	0.905	11.6%

95% 預測區間在測試集的實際覆蓋率是 94.4%（M3）/ 94.0%（M4）。總共產出 11 張圖（含 CI/PI 預測圖）、`predict.py` 部署程式，以及 PDF 報告。另外發現模型檔有 34 MB（statsmodels 會存訓練資料），用 `remove_data()` 縮到 60 KB。

學生

在 NotebookLM 研究網路上同主題的解法，寫一份 100 字以上的摘要貼進報告。

AI

在 NotebookLM（Gemini Notebook）建立筆記本，加入 7 個網路來源（Kaggle 資料集頁、多個 GitHub / nbviewer 上的 King County 房價 Notebook、AI Planet 上的 Notebook、ITM Conferences 2025 的論文），請它整理主流解法並寫摘要，再把摘要貼進報告第 9 節。

第二段：依評分標準補強

學生

（貼上評分標準截圖）評分標準越完整越好，讓分數盡可能高。

AI

先在另一台電腦（Windows）重新執行主程式，數字和原本完全相同，確認結果可以重現；並修正 Windows 主控台印不出「²」的編碼問題，讓程式在 macOS 與 Windows 都能直接執行。

AI

對照評分標準逐項補強（不改變原本的特徵選擇與模型數字）：

- **特徵選擇與評估**：新增 Forward Stepwise（AIC/BIC）佐證圖：前 12 名有 9 個和我們的子集相同，差異的 3 個都是共線的面積欄位。新增 Breusch-Pagan、Jarque-Bera、條件數檢定；Breusch-Pagan 顯示有異質變異，所以改用 HC3 穩健標準誤重新檢定，12 個係數中 11 個仍顯著（只有 log_sqft_lot 變成 p = 0.078）。補上 Random Forest 的 5-fold CV（0.889 ± 0.004）。
- **結果說服力**：新增預測區間校準圖（50%–99% 六種水準，90–95% 幾乎與理想線重合），以及殘差地圖：M3 在市區有明顯的低估群聚，加入 zipcode 後群聚消失，殘差標準差從 0.258 降到 0.185。
- **Auto Regression**：用每週中位房價做 AR(3)，預測最後 8 週的 MAPE 是 4.6%，比 naive 預測（4.3%）還差。報告如實說明：橫斷面資料不適合用 AR，所以 AR 只當補充。
- **報告**：加上 CRISP-DM 流程圖、欄位字典、利害關係人表、成功標準檢核表（M4 全部達成，M3 的 MAPE 20.3% 差一點沒達到）、網路解法 R^2 對照表（此資料集在 Kaggle 是 Dataset，沒有排行榜）、結論與限制。

第三段：對照課程講義補強

學生

（打開課程 Notion 頁面）查看有關這次作業的相關東西，看看有沒有需要修正；「GPT 輔助內容」改成「AI 輔助內容」，填 Claude Code。

AI

讀了課程 L4-2（CRISP-DM、資料型態）、L5（Simple LR 到 Auto Regression）、L6（Multiple Linear Regression、50 Startup）以及老師的「50 STARTUP Kaggle Report」範例報告，對照後找出要補的地方：

- 範例報告把每一種特徵選擇方法**分開**訓練，用測試集的 MSE 與 R^2 比較；L6 Part 2 要列出選 1 到 N 個特徵的 RMSE / R^2 表。
- L6 Step 4 要用 training / test 曲線判斷 overfit / underfit，並用 **Optuna** 優化模型；Step 5 部署要用 **gzip + pickle**。
- L6 Part 4 列出多元回歸的五大假設（線性、變異數同質、常態、誤差獨立、無共線性）；Part 5 介紹 Score selection（暴力搜尋所有特徵組合）與 dummy variable trap。
- L5 列出多項式回歸、Elastic Net 等線性回歸形式；L4-2 要區分名目 / 順序 / 區間 / 比例四種資料型態。

AI

依講義補強（原本的 M1–M4 數字不變）：

- **特徵選擇比較**：新增暴力搜尋（$2^{17} - 1 = 131{,}071$ 組，用 Gram 矩陣約 3 秒算完）。Backward、Forward、RFECV、Lasso、暴力搜尋五種方法全部收斂到同一組 16 個特徵（只刪 long），測試 R^2 0.775，但最大 VIF 19.6；M3 加上 VIF ≤ 5 後只用 12 個特徵，R^2 0.761、VIF 4.4。另外發現 long 的 Lasso 係數其實是 −0.0002（接近 0，不是剛好 0），報告的說法跟著修正。
- **Overfit / Underfit**：1–4 個特徵時 underfit；每一步的 training 與 test R^2 差距都小於 0.004，沒有 overfit。學習曲線顯示 M5 在小樣本時有輕微 overfit，資料變多後消失。
- **Optuna**：對 Elastic Net 的 alpha 與 l1_ratio 搜尋 40 次，最佳結果 CV R^2 0.8789，和 OLS 完全相同，確認不需要正則化。第一次執行時一次訓練要 18 秒以上，改用預先計算 Gram 矩陣後降到 0.04 秒。
- **多項式回歸 M5**：12 個特徵的二次項與交互作用（87 項）加 zipcode，測試 R^2 0.887，美元 RMSE $134,921，比 HistGradientBoosting 還低。
- **報告**：加入 MSE 與各指標的定義、五大假設檢查表（補上線性假設）、資料型態欄位、dummy variable trap 說明、gzip 部署（57 KB → 39 KB）、CRISP-DM 總結表；「GPT 輔助內容」改為「AI 輔助內容（Claude Code）」。

第四段：對照作業頁新增的建議

學生

（貼上 iLearning 作業頁截圖，頁面下方新增了「Kaggle Multiple Linear Regression Problems（14–39 Features）」與「Suggested Assignment: CRISP-DM + Feature Selection」）看看要怎麼整理，處理好。

AI

對照作業頁新增的建議逐項檢查：

- **特徵數 14–39 個**：本資料集 18 個特徵，同時符合原本的 10–20 個，不用換資料集。
- **Evaluation 要比較 MAE、MSE、RMSE、R^2、Adjusted R^2，並檢查五大假設**：已經有了。
- **還缺三項**：(1) Feature Selection 要比較 SelectKBest、RFE、Sequential Feature Selection、Lasso、permutation importance，選不同數量的特徵，只用訓練資料；(2) Modeling 要同時訓練 LinearRegression、Ridge 和 Lasso，原本缺 Lasso；(3) Deployment 要預測新樣本並解釋模型。

AI

補上這三項（原本的模型數字不變）：

- **五種方法 × k = 5、8、12、14**：SelectKBest 最差（k = 12 時 R^2 0.738），因為只看單變量相關，會挑進一堆共線的面積欄位。其他四種方法到 k = 8 就有 R^2 0.76，k ≥ 12 後停在 0.77。共線性是關鍵差別：k = 12 時只有 Sequential FS 的最大 VIF 接近 5（5.2，R^2 0.774），其餘都在 17.8–19.4。Sequential FS 選出的 12 個特徵和 Forward Stepwise 前 12 名完全相同。報告如實寫出它比 M3 準 0.013，以及仍選 M3 的理由（嚴格 VIF ≤ 5、不用鄰居平均面積）。
- **Lasso 模型**：LassoCV 在 M4 設計上 R^2 0.877，81 個係數中 79 個非零，和 OLS 幾乎相同。
- **預測並解釋新樣本**：`predict.py` 加上 `--explain`，把預測價精確拆成「一般房子 $465,592 × 每個特徵的百分比影響」。以 Mercer Island 臨水豪宅為例：預測 $2,615,671，主要來自臨水 +62%、地段 +50%、面積 +34%、等級 +30%、景觀 +28%。報告另列三間新房子的預測與 95% 預測區間。第一次執行時，因為 `remove_data()` 之後係數失去欄位名稱而出錯，改成在 `remove_data()` 之前先算好 zipcode 平均效果。

第五段：部署成網站

學生

README 最上面記得放網站的截圖。

AI

參考 HW1 的 README（最上面是 Streamlit 網站截圖），HW2 原本只有命令列工具，所以延續 HW1 的架構，把 M4 模型做成 Streamlit 網站 `app.py`：

- 左側輸入房屋條件；選 zipcode 時自動帶入該區的緯度，使用者不用自己查經緯度。
- 右側即時顯示預測價、95% 預測區間與信賴區間，並用長條圖逐項解釋各條件對價格的影響，以及各 zipcode 的位置與中位房價。
- 修正兩個顯示問題：金額裡有兩個「$」時，Streamlit 會把中間的文字當成數學公式，所以把「$」跳脫；線上地圖在截圖時無法載入，改用 Altair 畫各區位置圖。

截圖放在 README 最上面，並加入報告 6.3 節。

第六段：依老師更新的要求補上加分項目並部署

學生

（貼上更新後的作業說明截圖）老師作業要求有改，主要繳交改成「跟 DIC2 一樣 github and web」，另外有加分：下拉視窗呈現兩種 problem（+1）、可任意輸入 Dataset（+2）。

AI

對照新要求：資料集 18 個特徵符合「大於 13 個」；報告、對話、圖表改為選繳但都已具備；缺的是兩個加分項目與公開網站。網站改成左側下拉選單切換三種 problem：① King County 房價（主模型 M4）、② 50 Startups 利潤（老師提供的 CSV 網址）、③ 自行輸入資料集（CSV 網址或上傳）。②③ 共用新寫的 `generic_mlr.py`：自動補缺值、one-hot 編碼（避開 dummy trap）、只用訓練資料做特徵選擇（SelectKBest、RFE、Sequential FS、Lasso、permutation importance）、OLS、MAE / MSE / RMSE / R^2 / Adjusted R^2、含 95% 預測區間的預測圖與新樣本預測。用 King County 原始資料測試時，發現 date 欄位會被展開成 386 個虛擬變數、id 也被當成特徵，因此預設排除 id 欄位和類別值超過 30 種的文字欄位。

學生

（登入 Streamlit Community Cloud）幫我填，按 Deploy。

AI

部署到 https://hw2-mlr-yenkai.streamlit.app/。雲端裝的是 pandas 3.0，文字欄位的型態從 object 改成新的字串型態，導致 50 Startups 的 State 沒有被當成類別；改成「非數值就視為類別」後兩個版本都正確。Problem ① 雲端與本機的預測值完全相同（$555,052）。README 最上面放上網站連結與截圖。

9. NotebookLM 摘要

> 工具：Google NotebookLM（Gemini Notebook），筆記本「King County House Price Prediction Models」，2026-10-07。
> 來源（7 個）：Kaggle 資料集頁面；nbviewer christopherbronner/house-prices；GitHub raxshah/Simple-Linear-Regression-Python、ShamGit123/Predecting-House-Price-using-machine-learning-concepts、codewithchirag18/House-Sale-Analysis-EDA-Regression-Python；AI Planet「Predict the House Prices King County」；ITM Conferences KEIS 2025 論文（itmconf_keis2025_01023）。

常見資料前處理與特徵工程：主流解法多先處理缺失值（以中位數或平均值補值）、刪除不相關的 ID 欄位，並用 IQR 剔除極端離群值。房價呈右偏分布，會先做對數轉換與標準化；地理位置特徵（zipcode、lat、long）對價格影響很大，需要分組或類別編碼；也必須篩掉高度共線的面積欄位（如 sqft_living 與 sqft_above）。

使用模型與成效 (R^2)：單純線性回歸只能解釋約 49% 的變異（$R^2 \approx 0.49$）；多元線性回歸可提升到 $R^2 \approx 0.65$–0.70；加入二次多項式和 Ridge 正則化後約 0.70–0.75；樹狀集成模型（隨機森林、XGBoost/LightGBM）表現最好，R^2 可達 0.85–0.87。

線性模型與樹模型比較：線性模型結構簡單、計算快、可解釋性高，也能直接算出統計預測區間，但無法自動捕捉非線性交互作用和地理空間的差異。樹模型能擬合非線性關係與特徵交互作用，對共線性也較不敏感，但屬於黑盒模型（需搭配 SHAP 解釋），也很難直接輸出傳統的參數式預測區間。

對本作業的啟示：多元線性回歸是建構預測區間最直接的工具。要縮小和樹模型的準確度差距，前處理必須對房價做 log 轉換以符合殘差常態假設，用 VIF 或逐步回歸排除共線性變數，並對 zipcode 等區域特徵適當編碼，才能在保有區間估計優勢的同時達到最好的預測成效。

> **與本作業結果對照**：NotebookLM 整理的網路解法中，多元線性回歸 R^2 約 0.65–0.70、樹模型約 0.85–0.87。本作業依照這些建議做了 log 轉換、VIF + 多種方法的特徵選擇，以及 zipcode one-hot，線性模型 M4 達到 R^2 0.878，已追平網路上常見的樹模型水準；而且 95% 預測區間實測覆蓋率 94%，正好補上樹模型「難以給出預測區間」的缺點。

10. 結論與限制

CRISP-DM 流程總結

步驟	目的	本作業做了什麼	結果
Business Understanding	定義問題與成功標準	估價 + 95% 預測區間；訂出 R^2、MAPE、PI 覆蓋率標準	5 項成功標準（5.5 節檢核）
Data Understanding	認識資料與品質	欄位字典、資料型態、偏態、相關係數、共線性檢查	價格右偏、面積欄位共線、zipcode 是名目變數
Data Preparation	清理、轉換、切分	去除重複與錯誤資料、log 轉換、特徵工程、one-hot（避開 dummy trap）、80/20 切分	21,419 筆、17 個候選特徵
Modeling	選特徵、建模型	十種以上特徵選擇方法比較（含作業頁建議的 SelectKBest、RFE、SFS、Lasso、permutation importance）；M1–M5、Ridge、Lasso、Optuna Elastic Net、AR 補充、樹模型對照	12 個特徵；M4 R^2 0.878、M5 R^2 0.887
Evaluation	評估準確度與可信度	MSE / RMSE / MAE / MAPE / R^2、CV、overfit 曲線、五大假設、PI 校準	M4 達成全部成功標準；PI 覆蓋 94%
Deployment	讓模型可以被使用	pickle + gzip 存檔、`predict.py` 命令列工具、Streamlit 網站（三種 problem、任意資料集）	輸入房屋條件 → 預測價與 95% CI / PI

結論

1. **影響房價最大的因素**依序是建築等級、室內面積、地段（緯度 / zipcode）、臨水與景觀；所有係數方向都符合常識。
2. **特徵選擇**：Backward、Forward、RFECV、Lasso、暴力搜尋（131,071 組）五種方法都收斂到同一組 16 個特徵；再加上 VIF ≤ 5 的限制選出 12 個，R^2 只損失 0.014，卻消除了共線性。作業頁建議的五種方法在 $k = 12$ 時，除了 Sequential FS 以外，最大 VIF 都超過 17。
3. **模型穩定**：training / test 曲線幾乎重疊，沒有 overfit；Optuna 調參確認不需要正則化。
4. **地段固定效果**（zipcode one-hot）是線性模型最大的進步來源：R^2 0.761 → 0.878，殘差地圖上的地段群聚因此消失。
5. **預測區間可信**：95% PI 實測覆蓋 94%，校準曲線在 90–95% 幾乎與理想線重合，可以直接用於估價範圍。

限制與未來改進

- 資料只涵蓋 2014/05–2015/05，現在的房價水準已經不同，實際使用前必須用新資料重訓。
- 殘差有異質變異（Breusch-Pagan $p < 0.001$），高價房的預測區間可能偏窄；可以改用加權最小平方法（WLS）或 conformal prediction 修正。
- M5 證明交互作用有幫助，但 156 個係數難以解讀；未來可以只挑少數有意義的交互項（例如「臨水 × 面積」），兼顧準確度與可解釋性。